國立中興大學資訊管理學系
碩士學位論文

情境感知驅動的智慧穿搭推薦系統
A Context-Aware Intelligent Outfit Recommendation System

指導教授：林冠成 Kuan-Cheng Lin

研究生：吳旻臻 Min-Chen Wu

中華民國一百一十五年八月

國立中興大學資訊管理學系

碩士學位論文

題目：情境感知驅動的智慧穿搭推薦系統

姓名：吳旻臻　　學號：7113029049

經 口 試 通 過 特 此 證 明

論文指導教授 林冠成

論文考試委員 林冠成

岳啟寧

葉宏松

中華民國 115 年 7 月 23 日

誌謝辭

從準備報考研究所到完成碩士學業的這段期間，受到很多人的幫助。首先要謝謝爸爸媽媽一路以來的金援，也謝謝阿公和外婆總是默默關心我，偶爾還會偷偷塞紅包給我。除此之外，也很感謝家人與朋友們一路上的陪伴與鼓勵，無論是在論文卡住、進度不順，或只是單純想抱怨一下的時候，都有人願意聽我說話。也要謝謝男友不時的斗內與陪伴，在忙碌和壓力大的時候，陪我出門走走。

在研究所期間也很幸運認識了一個很好的朋友圉廷。研究所生活有不少壓力，也常常各自在忙自己的事情，因此很謝謝有一個可以隨時聊天、分享生活大小事，也能一起抱怨和耍廢的朋友，讓這兩年的生活多了很多輕鬆有趣的回憶。

也很感謝實驗室其他同學這段時間的幫忙。因為平常比較少進實驗室，有時候遇到需要繳交公文、列印文件等等，常常需要麻煩剛好在學校的同學協助。雖然都是一些看起來很日常的小事，但確實替我省下不少來回奔波的時間，也讓很多事情能夠順利完成，在這裡也想好好謝謝大家這兩年來的互相幫忙與照顧。

在研究過程中，也很感謝近年 AI 模型的快速發展。相比過去需要花大量時間自己撰寫程式碼、整理資料與查找文獻，這些工具的出現確實大幅提升了我的工作效率，也陪我完成了不少研究上的大小任務。

最後，最想感謝的是林冠成教授這兩年來的指導。從研究方向的討論、實驗設計，到論文內容與簡報呈現，老師都給了我很多實際且重要的建議，也提供相當充足的研究資源。除了研究能力之外，我也在老師一次次的簡報修改與討論中，慢慢學會如何把複雜的內容整理得更有邏輯。這些訓練對我來說不只幫助我完成這篇論文，也讓我在表達、思考與面對問題的方式上都有不少成長。

也很感謝吳君怡教授在研究與論文上的協助與建議，從不同角度提供了許多值得思考的方向，讓我能進一步檢查研究內容是否完整，也讓這篇論文在最後修改的過程中更加扎實。

回頭看這兩年的研究所生活，過程中經歷了不少壓力、挫折與自我懷疑，也有很多趕進度、改論文、準備簡報到很累的時候，但現在回頭看，這些過程也都變成了很難忘的經驗。很感謝一路上遇到的人、得到的幫助，以及那些看似微小但其實很重要的陪伴。能夠順利走到這裡，靠的不只是自己，也包含很多人的支持與善意。最後，不忘皮卡丘所言：「皮卡皮卡丘，皮卡皮皮皮皮卡丘，chaa 皮卡皮卡丘。」

摘要

現有服裝推薦系統仍多以商業導向為設計目標，應用於電商場域，著重於推薦熱門或視覺相似的商品以提高轉換率，缺乏關注使用者實際生活情境與即時需求。本研究提出**情境感知驅動的智慧穿搭推薦系統**，將天氣、場合與風格的情境感知因素轉換為可供模型學習的文字條件，模擬日常穿搭中的情境需求，並分析其對穿搭推薦效能的影響。

在技術架構上，本研究沿用基於**混合注意力層**的文字條件式穿搭推薦模型，維持推薦架構與訓練流程一致，使研究重點集中於**情境感知文字條件**的資料建構與驗證。在資料層面，本研究彙整熱舒適度相關資料，透過大語言模型推估套裝層級之**衣物保暖指數**與活動類型，再依活動類型對應**活動代謝率**，並採用 **D. A. McIntyre 基於 Fanger 熱舒適模型的簡化公式**，將相關物理數值轉換為以攝氏溫度表示的**主觀舒適溫度**參考值。接著使用大語言模型依據上述情境條件，覆寫 Polyvore 資料集套裝描述欄位，再透過 **LLM-as-a-Judge** 進行生成品質評估。最後將具備情境感知語意的資料集用於重新訓練推薦模型，以驗證情境感知文字條件對推薦效能的影響。

使用情境感知改寫描述後的實驗結果顯示，模型於相容性預測任務中，曲線下面積由 0.9292 提升至 0.9454，填空式搭配準確率由 0.6374 提升至 0.6478；於套裝推薦任務中，Recall@10 由 0.0780 提升至 0.0921，Recall@50 由 0.2303 提升至 0.2518。消融實驗更顯示，移除風格資訊後，相容性預測任務中曲線下面積下降 0.0154，套裝推薦任務中 Recall@50 下降 0.0241，說明風格條件是支撐穿搭語意對齊與推薦排序品質的主要因素，而天氣與場合資訊則能提供額外的情境限制。

整體而言，本研究將**熱舒適度推估**納入情境感知文字條件的建構，形成一套可追溯、可檢核且可重現的資料建構與驗證流程，並驗證其有助於提升文字條件式穿搭推薦對天氣、場合與風格需求的回應能力，為後續發展更貼近日常生活情境的穿搭推薦提供資料與評估基礎。

關鍵字：**情境感知穿搭推薦、情境感知文字條件、熱舒適度推估、LLM-as-a-Judge**

Abstract

As global digitalization accelerates, clothing recommendation systems remain largely oriented toward e-commerce, prioritizing popular or visually similar products while paying limited attention to users' everyday contexts and immediate needs. This study proposes a context-aware intelligent outfit recommendation system that converts weather, occasion, and style into textual conditions for model learning, thereby simulating everyday dressing contexts and examining their effects on outfit recommendation performance.

In terms of the technical architecture, this study adopts an existing text-conditioned outfit recommendation model based on a hybrid attention layer. By keeping the recommendation architecture and training procedure unchanged, the study focuses on the construction and validation of context-aware textual conditions.

At the data level, this study compiles thermal comfort-related data and uses a large language model to estimate outfit-level clothing insulation values and activity types. The activity types are mapped to the corresponding metabolic equivalent of task values, and D. A. McIntyre's simplified formula based on Fanger's thermal comfort model is applied to estimate subjective comfort temperature reference values in degrees Celsius. A large language model then overwrites the outfit description field in the Polyvore dataset according to these contextual conditions, and the generated descriptions are evaluated using LLM-as-a-Judge. The resulting dataset is used to retrain the recommendation model and assess the effects of context-aware textual conditions on recommendation performance.

Experimental results show that context-aware rewritten descriptions improve compatibility prediction, with the area under the receiver operating characteristic curve increasing from 0.9292 to 0.9454 and fill-in-the-blank accuracy from 0.6374 to 0.6478. In outfit recommendation, Recall@10 increases from 0.0780 to 0.0921 and Recall@50 from 0.2303 to 0.2518. Ablation analysis further shows that removing style information decreases the area under the receiver operating characteristic curve for compatibility prediction by 0.0154 and Recall@50 for outfit recommendation by 0.0241. These results indicate that style supports semantic alignment and recommendation ranking quality, while weather and occasion provide additional contextual constraints.

Overall, this study integrates thermal comfort estimation into a traceable, verifiable, and reproducible process for constructing and validating context-aware textual conditions. This process improves the responsiveness of text-conditioned outfit recommendation to weather, occasion, and style requirements and provides a foundation for future context-aware outfit recommendation systems that more closely reflect everyday contexts.

Keywords: context-aware outfit recommendation, context-aware textual conditions, thermal comfort estimation, LLM-as-a-Judge

目次

摘要 i
Abstract ii
表目次 v
圖目次 vi
第一章、 前言 1
1.1 研究背景 1
1.2 研究動機 1
1.3 研究目的 2
1.4 研究貢獻 3
1.5 論文章節安排 4
第二章、 文獻回顧與探討 5
2.1 推薦系統概論與技術發展 5
2.2 近代服裝推薦系統演進 7
2.2.1 早期服裝推薦：行為訊號與淺層特徵的偏好建模 7
2.2.2 個人化推薦系統（2010-2015）：引入社交與屬性資訊 8
2.2.3 多模態推薦系統（2015-2020）：引入圖像與深度學習 8
2.2.4 生成式推薦系統（2020 - 2024）：語意對齊與條件生成 9
2.2.5 近期發展（2024 年至今） 9
2.3 綜合比較與討論 10
2.4 研究缺口與本文定位 12
第三章、 研究方法 14
3.1 研究問題定義與系統目標 14
3.2 研究流程 15
3.3 資料工程 17
3.3.1 衣物保暖指數 (Clothing Insulation, CLO) 18
3.3.2 活動代謝率 (Metabolic Equivalent of Task, MET) 19
3.3.3 熱舒適度推估：基於 McIntyre 主觀舒適溫度的簡化模型 21
3.3.4 套裝描述改寫：將客觀量化條件注入原始語意情境 22
3.4 資料建構控管與可重現性 23
3.4.1 資料建構流程與分工 24
3.4.2 生成條件與輸出限制 24
3.4.3 代理變數檢查與錯誤處理 25
3.4.4 提示詞調整與正式資料設定 26
3.5 生成資料有效性評估設計 27
3.5.1 文字長度影響分析 28
3.5.2 目標單品線索檢查 29
3.5.3 生成描述品質評估 29
3.6 推薦模型與實驗評估設計 33
3.6.1 文字條件式穿搭推薦模型 33
3.6.2 任務一：穿搭相容性預測 (Compatibility Prediction, CP) 35
3.6.3 任務二：套裝推薦 (Outfit Recommendation, OR) 36

3.6.4 消融實驗：條件因子貢獻度分析 37
第四章、 研究成果 40
4.1 實驗設置 40
4.1.1 資料集與實驗樣本 40
4.1.2 實驗環境設置 40
4.1.3 模型訓練超參數與資料切分 41
4.2 生成資料有效性檢查 41
4.2.1 代理變數合理性檢查 41
4.2.2 文字長度影響分析 43
4.2.3 目標單品線索洩漏檢查 44
4.2.4 生成描述品質評估 45
4.3 推薦任務實驗結果 49
4.3.1 任務一：CP 實驗結果 50
4.3.2 任務二：OR 實驗結果 50
4.4 消融實驗：條件因子貢獻度分析 52
4.4.1 公平比較子集再驗證 52
4.4.2 各因子貢獻度 53
4.5 單品類別與情境子集表現分析 54
4.5.1 天氣因子對類別效能的影響 57
4.5.2 場合因子對類別效能的影響 58
4.5.3 風格因子對類別效能的影響 59
4.6 個案分析 60
4.6.1 描述改善與排序變化案例 60
4.6.2 顏色偏移改善案例 61
4.6.3 失敗案例與限制 63
4.7 綜合討論 63
第五章、 結論與未來研究 65
5.1 研究結論 65
5.2 研究限制 65
5.3 未來研究方向 66
參考文獻 67
附錄 A 70
附錄 B 72
附錄 C 76
附錄 D 77
附錄 E 83
附錄 F 88
附錄 G 93
附錄 H 103
附錄 I 104
附錄 J 105

表目次

表 2 - 1、服裝推薦系統演進 11
表 3 - 1、2024 Adult Compendium of Physical Activities 主類別分布情況 20
表 3 - 2、前五筆排序後 MET 值與活動對照表 21
表 3 - 3、各因子的操作型定義 38
表 4 - 1、實驗環境與主要軟硬體配置 41
表 4 - 2、CP 任務的訓練設定 41
表 4 - 3、CLO、MET 與主觀舒適溫度參考值之分布 42
表 4 - 4、文字長度差與檢索表現變化之相關分析 43
表 4 - 5、相近文字長度子集之 Hit@10 與排名改善結果 43
表 4 - 6、生成描述與原始文字條件之目標單品線索洩漏檢查結果 44
表 4 - 7、兩位評分者低分樣本集合重疊分析 47
表 4 - 8、兩位評分者之提示詞穩健性檢查結果 47
表 4 - 9、30 筆人工稽核樣本之情境覆蓋情形 48
表 4 - 10、30 筆人工稽核之模型與人工分數比較結果 48
表 4 - 11、CP 任務 - 成對 t 檢定 50
表 4 - 12、OR 任務 - 成對 t 檢定 51
表 4 - 13、縮減子集 CP 任務 - 成對 t 檢定 52
表 4 - 14、縮減子集 OR 任務 - 成對 t 檢定 53
表 4 - 15、CP 任務 – 消融實驗 53
表 4 - 16、OR 任務 – 消融實驗 54
表 4 - 17、案例一 - 各描述版本的檢索排名比較 60
表 4 - 18、案例二 - 各描述版本的檢索排名比較 61
表 4 - 19、顏色偏移改善分析結果 62
表 4 - 20、失敗案例各描述版本的檢索排名比較 63

圖目次

圖 3 - 1、研究流程圖 17
圖 3 - 2、提示詞模板 19
圖 3 - 3、活動生成模板 21
圖 3 - 4、完整資料工程示意圖 23
圖 3 - 5、清單示意圖 31
圖 3 - 6、推薦流程 35
圖 3 - 7、天氣、場合與風格因子移除示意圖 38
圖 4 - 1、兩位評分者的分數分布 45
圖 4 - 2、不同相似度門檻下的評估標準一致性分析 46
圖 4 - 3、低分樣本敏感度分析 47
圖 4 - 4、人工判斷與 LLM-as-a-Judge 之加權題項分歧 49
圖 4 - 5、CP 任務實驗結果比較 50
圖 4 - 6、OR 任務實驗結果比較 51
圖 4 - 7、各因子相對貢獻度 54
圖 4 - 8、不同目標單品類別於改寫描述下的 ΔHit@10 55
圖 4 - 9、不同情境子集下 Original 與 Context-aware 的 Hit@10 比較 56
圖 4 - 10、不同情境子集下的 Median Rank 改善幅度 56
圖 4 - 11、天氣因子對不同類別與語意條件的影響 57
圖 4 - 12、場合因子對不同類別與語意條件的影響 58
圖 4 - 13、風格因子對不同類別與語意條件的影響 59
圖 4 - 14、顏色偏移改善案例 62

第一章、前言

人工智慧 (Artificial Intelligence, AI) 技術的蓬勃發展，驅動了個人助理應用的轉型，由支援語音互動與排程管理，逐漸拓展至日常生活情境的決策支援。其中，每日穿搭作為一項兼具實用性、風格展現與社會互動意義的高頻率決策活動，因而成為智慧生活服務中具發展潛力的關鍵切入點。本章首先說明智慧穿搭推薦的研究背景，其次分析現有方法於情境條件整合上的限制，接著提出本研究的目的與貢獻，最後說明本論文的章節安排。

1.1 研究背景

早期個人助理多以語音互動、資訊查詢與排程管理為主要功能，近年則逐漸拓展至行程建議、健康追蹤、智慧家居與個人化推薦等日常生活情境。在此趨勢下，推薦系統的角色也逐漸由單純根據歷史紀錄推送內容，轉向協助使用者因應當下情境做出決策。相較於一般商品推薦，日常穿搭推薦即屬於此類情境化決策應用之一，不僅涉及使用者對服裝的偏好，也與當日天氣、活動安排與社會情境密切相關。因此，穿搭決策並非單一偏好的靜態延伸，而是一種會隨外在條件與生活情境調整的複合決策行為。

隨著社群媒體在現代社會中的普及，讓時尚資訊與穿搭技巧已不再侷限於特定的族群或專業領域，而是逐漸普及於一般大眾，穿搭行為不僅反映個體對風格與自我形象的偏好，亦是個體因應外在環境條件與社會情境要求、維持心理安全感與社會適應的重要途徑。這不僅反映了服裝的外顯功能，也點出穿搭在日常生活中扮演著心理調節與社會互動的雙重角色[17]。對於穿搭決策的重視與心理需求，亦非僅限於特定性別群體。過去社會常以刻板印象區分不同性別對服裝的關注重點，例如認為女性較重視外觀，男性則較重視實用功能。然而，在實際穿搭決策中，外觀、形象與情境契合度皆可能是不同使用者共同關注的面向，不應被視為特定性別的專屬特質[8]。綜上所述，服裝儀容是現代人經營自我形象與回應社會情境的重要方式，不論性別都可能在日常生活中重視自身穿著表現。因此，本研究希望透過語意條件與情境感知資訊的整合，辨識使用者需求中所隱含的風格傾向、情境限制與場合要求，進一步提供更符合實際生活情境的穿搭建議，協助使用者在多變的生活領域中，建構屬於自己的社會保護色。

1.2 研究動機

過去的服裝推薦系統多半聚焦於單品行銷與購物推播，推薦內容往往是根據使用者的消費紀錄或熱門商品產生，此類方法雖能支援商品探索與購買決策，但若應用於每日穿搭情境，仍難以完整回應使用者當下所面臨的環境與場合需求。實際影響穿搭決策的因素遠比這些靜態資料更為多元且複雜，像是價格考量、穿著場合、當日行程，甚至使用者的情緒狀態等，都可能左右其選擇。因此，本研究關注

的問題並非僅是如何推薦使用者可能喜歡的服飾單品，而是如何使推薦結果能夠符合實際生活情境中的穿著需求。

環境條件的變化亦是穿搭決策中不可忽視的關鍵因素。例如，氣溫上升與濕度變化會顯著影響使用者對布料材質與服裝顏色的選擇偏好，天氣涼爽時傾向柔軟或保暖材質，潮濕悶熱時則偏好透氣、輕盈的質感。而天氣變因像是在不同氣溫、濕度與風速等氣候條件下，會影響消費者對服裝選擇的偏好，在寒冷地區戶外量測與問卷資料建立的服裝預測模型發現，戶外服裝熱阻與氣溫呈顯著負相關，部分族群的服裝熱阻亦會受到相對濕度與風速影響，且過去數日的歷史氣溫仍會影響當下所選擇的服裝熱阻，顯示個體會依據近期的溫度經驗調整戶外衣著[23]。期望透過推薦系統動態捕捉這些外在條件，避免出現與使用者體感落差甚大的搭配建議。另一方面，天氣亦會形塑視覺與情緒層面的偏好，在較高體感溫度與濕度條件下，消費者會更傾向選擇冷色系服飾，而在較低體感溫度或風速較高時，則以暖色系服飾為選擇[7]。

此外，不同社會互動情境下的穿搭需求差異顯著，評估標準不僅在於單品風格是否協調，更需兼顧場合所要求的禮儀與正式度。以連身休閒運動套裝為例，其在度假情境中或許合宜，但若直接沿用至婚禮、雞尾酒會或正式職場，則可能引發不適切的觀感。現有多數穿搭與服飾推薦方法多著重於單品風格的相容性或使用者偏好，較少明確處理場合所帶來的情境要求，在實際使用情境中，場合本身即會左右整體造型的正式度、色彩選擇與單品搭配幅度[41]。場合在穿搭中可視為與天氣同等重要的情境因素，對穿搭適切性具有實質影響力。

1.3 研究目的

承接前述研究背景與動機，本研究旨在建構一套情境感知驅動的智慧穿搭推薦流程，使穿搭推薦模型能將天氣、場合與風格需求納入條件表示，模擬日常穿搭中的情境需求，並分析其對推薦效能的影響。具體而言，本研究以 Polyvore 穿搭資料集為基礎，建構包含天氣、場合與風格的情境感知文字條件，並透過生成品質評估與文字條件式穿搭推薦實驗，分別檢視生成描述的品質，以及驗證情境感知文字條件對推薦效能的影響。其核心目的如下：

1. **情境語意建構與資料準備**：以 Polyvore 穿搭資料集[19]為基礎，運用多模態大型語言模型推估套裝層級之衣物保暖指數 (Clothing Insulation, CLO) 與活動類型，再依活動類型對應活動代謝率 (Metabolic Equivalent of Task, MET) [14]，並透過 McIntyre 基於 Fanger 熱舒適模型的簡化公式 [32]，依 CLO 與 MET 計算以攝氏溫度表示的主觀舒適溫度參考值；再由大型語言模型重新構寫納入情境條件的套裝文字描述。

2. **LLM-as-a-Judge 機制**：透過多模態大型語言模型建立三階段式評估流程，前兩階段建立檢查清單，第三階段依據該檢查清單對生成結果進行評分，以完成生成語句的自動化品質評估與問題診斷，檢視描述是否反映天氣、場合與風格等情境語意，並分析描述偏移或條件不一致的可能情形。

3. **多模態特徵表示建構**：利用預訓練 FashionCLIP 對單品圖像與情境感知語意文字進行編碼，將服飾外觀特徵與具情境感知語意的描述嵌入共同向量空間，作為後續文字條件穿搭推薦模型的輸入特徵表示。

4. **採用既有混合注意力推薦模型**：採用 Wang 與 Zhong [43] 所提出、基於混合注意力層（Hybrid Attention Layer）的 Transformer 解碼架構，使模型於推薦過程中同時關注文字條件與已選單品特徵，作為驗證本文所建構情境感知文字條件之下游推薦模型。

5. **情境化評估與成效驗證**：設計以天氣、場合與風格為條件的推薦情境，從條件符合度與檢索表現驗證方法成效，並與未納入情境感知語意的基準模型進行比較分析，以驗證情境感知條件對穿搭推薦結果的影響。

綜合上述，本研究不僅著重於穿搭描述的生成，更強調如何將使用者的情境需求轉換為可計算、可控制且可解釋的條件表示，並進一步檢驗該條件表示是否能有效提升推薦模型對天氣、場合與風格需求的回應能力。透過上述設計，本研究期望縮減自然語言需求與模型可計算條件之間的落差，並為日常穿搭決策提供更具情境契合度與實用性的推薦依據。

1.4 研究貢獻

基於上述研究目的與整體設計，本研究的貢獻可分為方法建構、條件表示、生成品質評估與實證驗證四個面向，說明如下。

一、建立情境感知語意建構流程。

本研究提出一套以情境條件為核心的穿搭語意建構流程，將天氣、場合與風格等日常穿搭需求轉換為可供模型處理的文字條件表示。該流程涵蓋資料蒐集與整理、條件推導、描述改寫與資料建構紀錄，其中包含 CLO 值來源與 MET 活動清單的整理，使原本以靜態搭配資訊為主的穿搭資料，得以擴充為具情境資訊的情境感知資料。此一貢獻的重要性在於，現有服裝推薦研究多偏重視覺相容性與單品搭配關係，較少處理使用者實際生活情境中的多重限制。本研究所建立的流程，有助於縮減自然語言需求與模型可計算條件之間的落差，並為後續情境化穿搭推薦提供可重現的資料基礎。

二、導入 CLO 與 MET 作為可比較的中介尺度。

本研究導入衣物保暖指數與活動代謝率作為中介尺度，並結合熱舒適推估，建立具一致性的量化基礎，使天氣感受與活動需求能由抽象語意轉換為較具物理意義且可解釋的情境條件。此一作法可使推薦條件不僅停留於主觀語意層次，而具備可比較、可追溯與可解釋的特性。相較於僅依賴自由文字生成的方法，CLO 與 MET 的引入使本研究在舒適度約束上具備更穩定的中介基礎，亦提升後續條件生成與結果解釋的合理性。

三、建立 LLM-as-a-Judge 生成資料品質評估機制。

本研究於條件化描述生成後，導入 LLM-as-a-Judge 作為生成品質評估工具，透過清單式檢核方式，判斷生成描述是否符合圖片內容、天氣、場合與風格等條件要求。此機制主要用於分析生成描述是否存在語意偏移、條件不一致或圖片無法支持的內容，並作為後續生成品質分析與案例檢視的依據。透過此一評估流程，生成描述的問題類型能被更清楚地追蹤與說明，進而提升生成資料分析的可解釋性與可追溯性。

四、以穿搭相容性預測 (Compatibility Prediction, CP)、套裝推薦 (Outfit Recommendation, OR) 及消融實驗驗證方法有效性。

本研究以 CP 與 OR 兩項任務，驗證情境感知語意條件對文字條件式穿搭推薦模型的影響，並透過消融實驗分析天氣、場合與風格等因子的貢獻。此外，本研究亦加入縮減子集再驗證與案例分析，以更完整檢視方法在不同情境下的表現。此一貢獻的重要性在於，本研究並非僅提出一套資料建構流程，而是進一步驗證其對下游推薦任務具有實質效益。透過多層次的實驗設計，本文得以更具體說明方法何以有效、哪些因素較具影響力，以及方法於不同情境下的表現差異。

1.5 論文章節安排

本論文共分為五章。第一章為前言，說明研究背景、研究動機、研究目的與研究貢獻，並概述本論文的整體架構。第二章為文獻探討，回顧推薦系統與近代服裝推薦系統的發展脈絡，並整理相關研究在情境條件整合、語意增強與方法驗證上的缺口，進一步說明本文的研究定位。第三章為研究方法，說明本研究的資料建構流程、CLO 與 MET 條件推導、情境感知語意描述生成、LLM-as-a-Judge 生成品質評估流程，以及情境感知穿搭推薦模型的設計。第四章為實驗結果與分析，呈現實驗設定、評估任務、比較結果、消融實驗、縮減子集再驗證與案例分析。第五章為結論與未來研究，總結本研究的主要發現與貢獻，並說明研究限制及後續可延伸方向。

第二章、 文獻回顧與探討

當今的推薦系統藉由整合使用者互動紀錄、偏好訊號與物品特徵，協助使用者在大量候選項目中降低搜尋與比較成本，並完成決策。推薦技術自早期協同過濾與矩陣分解，逐步發展至深度學習、序列建模與多模態特徵表示，任務範疇從偏好預測擴展至語意理解與組合式決策。而服裝推薦也承接此演進，除刻畫個人偏好外，還需處理衣物之間的搭配相容性與風格一致性，並面對文字條件與情境限制等語意訊號的表達問題。相較於一般單品排序，日常穿搭同時具有多目標與多限制特性（協調性、正式度、舒適度與場合切換等），使得僅依賴相似度或互動率的推薦邏輯容易出現可看但不夠可穿的落差。基於上述背景，本章回顧推薦系統核心概念與技術演進，並整理近代服裝推薦在資料型態與建模取向的轉折，作為後續研究方法設計的基礎。

2.1 推薦系統概論與技術發展

Ricci、Rokach 與 Shapira (2011) 於《Recommender Systems Handbook》中定義推薦系統 (Recommender Systems, RSs) 係指「為使用者提供有用項目建議的軟體工具與技術」[36]。其核心價值在於輔助決策，例如在大量候選方案中協助選擇應購買的商品、聆聽的音樂，或閱讀的線上新聞。隨著網路服務與電子商務擴張，商品選項與資訊量快速成長，人工檢索與比較成本隨之提升，使推薦系統成為重要的資訊過濾與決策支援工具。

以輸出形式而言，個人化推薦常以排序清單呈現，系統需整合多元偏好訊號以推估使用者與項目的匹配程度，包含使用者明確表達的回饋，例如對商品的評分，也包含系統透過使用者行為推論的隱性訊號，例如瀏覽或點選特定商品頁面可被視為偏好線索。在資料層面則概括為三類物件，分別是單品 (items)、使用者與描述使用者與單品連結的交易關係，也就是使用者與商品之間的關聯。其中「交易」可理解為使用者與系統互動期間產生的重要資訊，可能包含使用者選擇的單品、當下需求或情境描述，以及是否提供評分等回饋。在早期的推薦系統架構中，最具代表性的兩種主流技術方法為內容導向 (Content-Based, CB) 與協同過濾 (Collaborative Filtering, CF) 奠定了推薦系統的核心邏輯，並長期作為推進後續多數推薦系統設計的基礎。

CB 的推薦方法係基於使用者過去的行為資料（如瀏覽紀錄、購物紀錄與評分行為）進行個人化建模，透過分析單品本身的特徵與描述內容，計算與使用者偏好最相近的項目作為推薦對象。此方法強調物品間的相似性，即若一名使用者喜歡某商品 A，則系統將推薦在內容特徵上與 A 相似的商品 B。例如，在音樂推薦場景中，若使用者偏好鋼琴曲風，CB 推薦系統將推薦其他同類型的鋼琴演奏曲目。優點在於其推薦邏輯容易解釋，且不須依賴其他使用者的行為資料，可直接針對使用者進行個人化建議。但同時，CB 方法也常面臨推薦過於保守與冷啟動問題 (Cold-

Start Problem) 的挑戰，系統傾向推薦與使用者已評價過物品相似的內容，缺乏內建機制去發掘意料之外但可能有興趣的項目，此外，若其推薦在使用者回饋不足時較難可靠地掌握其偏好，而難以提供穩定的個人化推薦。

CF 則是另一類主流推薦方法，其核心邏輯是基於使用者之間的行為相似性，而非物品本身的內容。CF 的典型作法為鄰里方法 (Neighborhood Methods)，透過建構「使用者-單品」的互動矩陣，找出與當前使用者行為相似的其他使用者，並推薦這些使用者曾喜歡過的單品。早在 1992 年，Goldberg 等人便在郵件過濾系統 Tapestry 中提出類似概念的原型[16]，後來被 Netflix、Amazon 等電商平台廣泛採用。隨著電商平台提供的商品選項大幅增加，其資料稀疏性 (data sparsity) 與擴展性問題日益嚴峻，Linden et al. (2003) 在 Amazon.com 的應用研究中提出以單品為基礎 (Item-based) 的協同過濾邏輯，不再找尋相似使用者，而是根據使用者過去的商品評價推估其對其他單品的偏好或評分，從而改善資料稀疏性與可擴展性問題[29]。Koren et al. (2009) 則結合模型基礎方法 (Model-based Approaches) 中的矩陣分解 (Matrix Factorization) 技術與潛在因子模型 (Latent Factor Models)，提出 Factorization Models[24]，在大規模資料下有效學習使用者與單品之間的潛在關聯，並於當時被 Netflix Prize 採納並取得優異表現。

整體而言， CF 方法能透過與目標使用者有相似品味的社群集體智慧來推薦項目，更能推薦使用者可能感興趣卻從未見過的內容，因而具備更高的新穎性，但同樣面臨一些關鍵挑戰。其一為冷啟動問題，即當新使用者或新單品進入系統時，因缺乏互動紀錄而難以進行準確推薦；其二則為資料稀疏性，由於實際上大多數使用者僅與極少數項目產生互動，使得行為矩陣極度稀疏，造成模型學習困難。此外，協同過濾方法也難以處理具語意性質或視覺特徵的推薦任務，對非結構化資料（如圖片、文字）支援度有限。

為克服上述兩類方法的不足，後續研究逐漸發展出混合式推薦方法 (Hybrid Recommendation)，融合內容特徵與協同訊號，強化推薦系統的適應能力與表現穩定性。常見的混合策略包括加權融合 (Weighted Hybrid) 與級聯架構 (Cascading Hybrid)，可因應不同情境下的推薦需求：加權融合用於整合多種推薦技術的輸出，將各方法所產生的評分以加權方式合併為單一分數；而級聯架構則屬於分階段的結合策略，先以其中一種方法縮小候選項目集合，再由另一種方法進一步篩選與排序，因而在實務上往往較加權融合更具運算效率與可擴展性。總而言之，推薦系統在 2010 年以前的發展主要著重於使用者與單品互動的結構化資料，其架構相對簡單且演算法可解釋性高，成功應用於郵件過濾、電子商務與影音推薦等多個早期應用領域。儘管如此，這些傳統方法在處理視覺、語意與情境資料上的能力仍有限，也未能針對當下情境變數（如天氣、活動）做出即時判斷，為後續深度學習與多模態推薦技術的興起鋪陳了發展基礎。

隨著使用者需求日趨多元，商品類型愈趨豐富，以及非結構化資料（如圖像、語意描述）的大量出現，傳統推薦方法已難以全面滿足實際應用場景的需求。特別是在服裝領域中，穿搭不僅涉及風格偏好，更牽涉到視覺搭配、社會情境與即時環境等語意情境因素，使得推薦系統必須具備更高層次的語意理解與情境適應能力

[5]。為因應這些挑戰，近年來服裝推薦研究逐步朝向多模態融合、個人化語意建模與生成式推薦發展，發展出多種技術結構與模型架構。下一節將說明近代服裝推薦系統的演進路徑，並回顧代表性方法與應用實例。

2.2 近代服裝推薦系統演進

隨著深度學習與資料處理能力提升，服裝推薦系統 (Fashion Recommendation Systems, FRS) 的設計與應用也歷經了多次技術躍進，從早期以使用者行為為依據的靜態推薦，逐漸朝向融合視覺、語意與情境等多模態資訊的智慧型系統邁進。本研究參考 Chakraborty et al. (2021) 的文獻回顧整理[5]，及近年相關研究，以「主流資料型態與建模取向」作為分期依據，將技術發展歸納為四個階段：早期服裝推薦（2010 年以前）、個人化推薦（2010-2015）、多模態推薦（2015-2020）與生成式推薦（2020 年至今）。其中，2024 年後相關研究進一步受到大型語言模型、視覺語言模型與生成式基礎模型的影響，逐漸由單純的穿搭相容性建模與生成結果輸出，延伸至語意條件理解、多模態任務整合與條件化推薦控制。本節將依序介紹各階段的代表性研究，並說明其如何推進服裝推薦系統在風格理解、個人偏好、情境語意與推薦條件控制等層面的能力。

2.2.1 早期服裝推薦：行為訊號與淺層特徵的偏好建模

在服裝推薦的早期研究中多沿用傳統 RS 架構，主要以使用者與單品互動紀錄和結構化欄位作為訊號來源（例如評分、購買紀錄，以及類別、品牌、顏色等屬性），以進行偏好推估與排序任務。然而，服裝作為高度視覺化且強烈依賴語意脈絡的商品類別，其風格差異、材質觀感、版型輪廓與單品間的搭配相容性，往往難以被有限的結構化欄位完整捕捉。Deldjoo et al. (2023) [9] 研究中提到時尚產品的龐大詞彙量、高周轉率和購買資料稀疏性等挑戰，使得在此階段僅單純依賴使用者-商品互動矩陣 (U-I matrix) 的協同過濾方法，容易停留在相似商品重複推薦或無法解釋搭配合適性。因此，多數工作開始引入輔助訊號（淺層視覺特徵、文字描述、評論等），以部分緩解冷啟動與稀疏性，但仍多以「單品偏好」為核心，對「套裝搭配」的整體一致性缺乏顯式建模。

因此大多數研究工作都會納入較易取得的輔助訊號，例如商品外觀的淺層視覺特徵、文字描述或顧客評論，以提升對風格差異與搭配關係的特徵表示能力，並部分緩解冷啟動與稀疏性問題。Jagadeesh et al. (2014) [22] 探討以視覺特徵為核心的大規模服裝推薦問題，提出確定式服裝推薦模型 (Deterministic Fashion Recommender, DFR) 與隨機式服裝推薦模型 (Stochastic Fashion Recommender, SFR)，利用顏色特徵與最近鄰搜尋推薦互補服裝，並考量使用者偏好差異。此外，Agarwal et al. (2018) [1] 亦應用 Bayesian Personalized Ranking Matrix Factorization (BPR-MF) 框架處理大規模商品推薦問題，但此類方法雖能處理互動資料稀疏問題，對服飾搭配的語境理解仍有限。傳統單模態推薦在視覺風格、搭配語意與情境感知上表現不足，尤其面對無法單靠數值特徵表達的資訊（如場景需求、情緒氛圍），易造成推薦結果缺乏搭配相容性 (compatibility) 與風格一致性 (coherence)，

推動後續研究開始導入圖像、文字與語意向量作為模型輸入，開啟多模態推薦的發展階段。

2.2.2 個人化推薦系統（2010-2015）：引入社交與屬性資訊

隨著 Facebook、Instagram 等社群平台陸續問世並累積大量使用者後，使用者在網路上分享穿搭照片、評論與互動紀錄等數位足跡，成為推薦系統理解使用者偏好的重要資料來源。此外，電商平台技術也逐漸發展成熟，能更加有效地蒐集與分析使用者的行為資料，促使推薦系統由通用化建議轉向情境感知 (Context-aware-based) 與即時個人化 (instant-personalization-based) 的發展階段。系統開始關注使用者的即時選擇與環境因素，並將個人屬性與社交互動納入建模考量，此時期多為以社群網路為基礎的推薦系統 (social-network-based FRSs)，開始將使用者的社交圈、時尚產品屬性、圖像解析、流行趨勢與風格一致性等因素視為影響購買決策的關鍵變數。

Vogiatzis et al. (2012) [42] 提出一套結合專家知識與社群資料的穿搭風格建議系統，透過建構以服裝、本人體型、臉部特徵與場合為核心的時尚本體論 (fashion ontology)，並結合使用者購買行為所挖掘的社群共現模式，同時提供專家導向與社群導向的個人化穿搭建議。Liu et al. (2012) [30] 則透過 Magic Closet 系統，根據使用者的外觀特徵與場合需求推薦服飾，進一步探討社交影響與個人化建議的互動效果。這一階段的推薦模型與傳統推薦系統最大的區別在於使用更完整的使用者側寫 (user profile)，採用屬性匹配、模糊邏輯 (Fuzzy Logic) 與模糊數學 (fuzzy mathematics) 和貝氏網路 (Bayesian Networks) 等方法，儘管推薦結果與使用者需求的符合度有所提升，但面對日益複雜的非結構化資料（如服飾圖片、搭配語意），仍難以有效擷取其中的語義與視覺脈絡關係，在規則與屬性設計往往需要高度人工介入，難以擴展至大規模與即時應用。

2.2.3 多模態推薦系統（2015-2020）：引入圖像與深度學習

自從 AlexNet[25] 於 2012 年的 ImageNet 競賽中脫穎而出後，深度學習在電腦視覺領域中迅速崛起。其中，卷積神經網路 (Convolutional Neural Networks, CNN) [33] 展現強大的圖像特徵提取能力，能夠自動學習圖片中的紋理、形狀與語義資訊。此一技術突破推動深度學習逐步擴散至各類應用場景，時尚產業亦不例外，基於圖像的 FRSs (Image-based FRSs) 因此受到快時尚零售商的高度關注。

He & McAuley 於 2016 年首度將 CNN 提取的視覺特徵整合至排序模型中 [20]，提出 Visual-based recommendation method (VBPR)，使系統能從圖像中理解使用者對於材質、剪裁、顏色等視覺屬性的偏好，進而提升推薦精準度。Zhang et al. (2017) [49] 則進一步導入場景感知能力，為首篇引入地理/地點屬性 (Location attributes) 至時尚分析的研究，其方法先以 multilabel convolutional neural network (mCNN) 識別服裝屬性，再透過 Support Vector Machine (SVM) 建立地點類型（如文化遺產、自然風光）與穿搭的對應關係，強調穿搭語意需能隨情境調整，例如辦

公室與戶外旅遊在著裝需求上的差異。Yu et al. (2018) [48] 提出動態協同過濾模型 (Dynamic Collaborative Filtering model using both aesthetic features and CNN features, DCFA)，透過預訓練的美學評估網路結合時間序列分析，捕捉使用者審美偏好隨潮流演變的動態過程，並融合美學特徵與 CNN 視覺特徵，從而實現更具層次與感官連結的個人化推薦。

整體而言，此階段的推薦邏輯逐漸不再侷限於「使用者偏好」或「商品屬性」等單一層級，而是轉向納入環境脈絡與風格關係。服裝推薦亦不應僅聚焦於單品排序，更需同時考量整體穿搭 (outfit) 的協調性與相容性。因而，如何透過深度學習模型捕捉單品之間的視覺相容性與風格一致性，便為後續生成式推薦研究奠定了重要基礎。

2.2.4 生成式推薦系統（2020 - 2024）：語意對齊與條件生成

隨著以 Transformer[40] 架構為基礎的預訓練語言模型（如 BERT[10]）快速發展，加上 GPU／TPU 等高效能運算資源的普及，以及大規模資料驅動訓練策略逐漸成熟，深度學習研究的重心已由早期以單一模態為主的特徵表示學習，逐步轉向多模態的語意理解與內容生成。尤其自 2021 年後，Diffusion Model[47] 等生成技術出現，在影像生成的視覺品質與條件可控性方面皆顯著提升，也促使服裝推薦系統朝向以語意建模與條件生成為核心的新階段發展，提供更符合使用者需求與風格一致性的完整穿搭建議。

在此脈絡下， Ding et al. (2023) [11] 提出 Template-guided Outfit Generation (TOG) 方法，以圖神經推薦模型學習穿搭模板結構（如「上衣、褲子與配件」），模型先預測使用者可能偏好的模板，再依模板中的類別位置進行類別感知的單品重排序以填入對應單品，最後結合穿搭相容性評分進行排序，以產生更符合使用者偏好且整體更協調的穿搭建議。Wang & Zhong (2024) [43] 則進一步引入自然語言描述作為穿搭條件，透過混合注意力機制同時建模文字與服飾單品之間的語意對齊關係，以及單品之間的內部相容性，並採用 Transformer 架構逐步生成穿搭組合，使推薦結果在語意情境與整體搭配一致性上皆有所提升，成為文字條件穿搭推薦的重要代表性工作之一。Xu et al. (2024) 首次將 Diffusion Model 引入穿搭推薦，提出 DiFashion 模型並定義 Generative Outfit Recommendation (GOR) 任務[45]，透過類別條件、穿搭內部相互關係與使用者歷史偏好等多重條件，推薦系統能跳脫既有服飾商品的限制，直接生成符合使用者偏好且彼此相容的全新穿搭影像。

2.2.5 近期發展（2024 年至今）

近年服裝推薦研究進一步受到多模態大型語言模型 (Multimodal Large Language Model, MLLM) 與視覺語言模型 (Vision-Language Model, VLM) 發展的影響，推薦系統的重點逐漸由單純的相容性分數預測，延伸至多模態語意理解、使用者偏好整合、互動式推薦與多任務生成。相較於早期方法多以影像特徵、單品關係或固定候選集排序為核心，近期研究更強調模型能否同時理解服飾影像、文字查

詢、風格偏好與使用者回饋，並將這些條件轉換為可操作的穿搭建議。Pang et al. (2025) [34] 提出 Multimodal, Multitask, and Multiround Fashion Assistant (FashionM3)，將視覺語言模型微調為多模態、多任務與多輪互動的服裝推薦助理，使系統能處理自然語言與影像輸入，並支援個人化推薦、替代單品建議、商品影像生成與虛擬試穿等任務，顯示服裝推薦已從傳統 ranking-based 方法逐漸轉向互動式與生成式的推薦架構。

在大型多模態模型的應用方面，Chang et al. (2025) [6] 則以 Gemini 進行視覺問答，從服飾影像中抽取顏色、風格、適合年齡、性別與場合等語意關鍵詞，再結合 BERT Pre-Training of Image Transformers 3 (Beit3) 進行深度多模態特徵融合，以預測上衣與下身單品之間的相容性。此研究雖主要聚焦於上衣與下著的搭配和諧性，而非完整的多任務服裝助理，但其價值在於展示大型多模態模型可作為語意抽取工具，降低對人工標註文字、類別標籤與額外輔助資料的依賴。

此外，Sohn et al. (2026) [38] 提出 Multi-modal Deep Learning-based Fashion Recommendation (MDL-FR)，透過 Style-Identifiable Multi-Modality Compatibility Network (SI-MMCN) 同時學習穿搭相容性分數與風格特徵表示，使推薦結果不僅考量單品之間是否相容，也能反映使用者偏好的風格方向。雖然此研究並非直接以大型語言模型或視覺語言模型為核心，但其將多模態資訊、風格條件與穿搭生成整合於同一推薦框架中，可視為近期服裝推薦由相容性建模走向條件化、多任務與偏好導向推薦的重要銜接。整體而言，近期的服裝推薦研究已不再只追求相容性預測準確率，而是更重視模型能否理解使用者查詢、提取語意條件、整合風格與偏好，並以互動式或生成式方式提供更符合實際情境的穿搭建議。

2.3 綜合比較與討論

綜觀近代服裝推薦系統的演進，可從資料來源、建模策略與輸出型態三個層面加以歸納，如表 2-1 所示。在資料來源層面，早期方法主要依賴使用者與商品的互動紀錄，例如評分、瀏覽與購買行為，透過協同過濾、矩陣分解或內容導向方法推估使用者偏好。隨著社群平台與電商資料累積，研究開始納入使用者側寫、社群互動、專家知識與商品屬性，使推薦結果能更貼近個人偏好與使用情境。其後，深度學習與電腦視覺技術的發展，使服裝推薦逐漸從單品偏好預測擴展至圖像特徵學習、風格辨識與套裝相容性建模。在多模態與生成式推薦階段，服裝推薦的核心任務進一步從推薦使用者可能喜歡的商品，轉向兼具協調性且符合使用者需求的穿搭組合。因此，相關研究開始重視圖像與文字之間的語意對齊、單品之間的搭配關係，以及使用者需求對推薦結果的控制能力。2024 年後，隨著 MLLM 與 VLM 被引入服裝推薦，研究焦點逐漸延伸至語意抽取、互動式回應與多任務處理。此一發展顯示，影像與文字不再只是輔助特徵，也逐漸成為理解使用者需求、建構推薦條件與控制生成結果的重要依據，使服裝推薦由單一相容性預測，進一步走向多任務、互動式與條件化推薦架構。

除了模型架構本身的進展外，近期推薦系統研究也開始關注 LLM 在資料補強與語意理解上的輔助價值。LLM 具備高品質文字特徵表示與廣泛外部知識，能協助系統更有效理解使用者查詢、商品描述與其他文字資料；從推薦流程角度來

看，LLM 亦可介入特徵工程階段，根據商品描述、使用者側寫與行為資料產生輔助文字特徵，以提升資料可用性與使用者／商品表徵品質[28, 44]。然而，將 LLM 直接作為推薦系統仍存在實務限制與風險。一方面，LLM 推論成本與延遲較高，若在推薦階段直接參與排序或生成，可能增加推論延遲與計算成本；另一方面，LLM 生成內容可能出現看似合理但缺乏事實基礎的幻覺問題，若錯誤屬性或描述被納入後續推薦模型，反而可能誤導模型判斷並降低推薦表現[28]。因此，本文並非將 LLM 作為主要推薦模型，而是將其定位為情境化描述生成與資料品質強化的輔助工具，並透過結構化條件、檢核規則與 LLM-as-a-Judge 輔助評估機制，降低生成內容不穩定與幻覺所帶來的風險。雖然 LLM-as-a-Judge 可用於複雜任務評估，但其可靠性仍需透過標準化流程、額外驗證、校準、偏誤控制與穩健性檢核加以強化，因此本文後續亦不完全依賴 LLM 判斷，而是將其作為品質評估流程中的輔助環節[18]。

表 2 - 1、服裝推薦系統演進

發展階段		主要資料來源	核心技術	代表研究／模型	限制與挑戰
早期		結構化資料	協同過濾、內容導向	DFR 與 SFR[22]、BPR-MF[1]	無法理解圖像與語意情境，缺乏搭配性的判斷
個人化	2010-2015	使用者屬性、社交訊息	屬性匹配、規則導向建模、知識導向推薦	Magic Closet[30]	缺乏視覺理解能力，對非結構化資料支援有限
多模態	2015-2020	商品圖像、服飾屬性、應用場景	CNN、視覺排序模型、搭配一致性建模	VBPR[20]、DCFA[48]	語意對齊能力不足，語言輸入處理有限
生成式	2020-2024	語言描述、穿搭圖像、使用者需求	CLIP、Transformer、LLM	TOG[11]、DiFashion[45]	訓練資料需求高，語意情境控制精準度有待改善
多任務	2024 至今	服飾影像、文字查詢、使用者偏好、多輪對話資料	LLM、VLM、MLLM	FashionM3[34]、MDL-FR[38]	依賴資料庫與互動紀錄品質，語意抽取穩定性仍有限

基於上述分析，近代服裝推薦研究已顯著提升推薦結果在視覺協調性、語意理解與個人化表現上的能力。然而，若將應用場景聚焦於日常穿搭決策，使用者實際需要的並不只是外觀協調的穿搭結果，也包括該穿搭是否符合當日天氣、場合需

求、活動強度與穿著舒適度。因此，服裝推薦系統若要進一步貼近真實使用情境，除了提升搭配相容性與個人化程度外，仍需建立一套能將日常情境需求轉換為模型可理解、可計算且可檢核的推薦依據的流程。此問題即為本文後續研究缺口與方法設計的主要出發點。

2.4 研究缺口與本文定位

日常穿搭並非單純的商品偏好選擇，而是同時受到外在環境條件、社會場合與整體造型風格影響的複合決策。為避免將風格誤解為物理環境因素，本文將影響日常穿搭決策的條件區分為三個面向：天氣 (Weather) 屬於外在物理環境條件，用以描述氣候、體感與穿著舒適需求；場合 (Occasion)，屬於活動與社會情境條件，用以描述活動目的、場域、時段、正式程度與社會互動需求；風格 (Style)，用以描述整體穿搭氛圍、審美方向與視覺偏好。本文後續將天氣、場合與風格三者統稱為情境感知條件，並將其轉換為可供模型學習的文字條件表示。其中，天氣因素指影響穿著舒適度與衣物選擇的外在氣候與體感條件，例如溫度、季節、冷暖感受、降雨情形與穿著保暖需求。對日常穿搭而言，天氣不只是背景資訊，而是會直接影響衣物厚薄、保暖程度與穿著舒適性的判斷依據。既有天氣導向服裝推薦研究也將溫度、濕度、風力、日照、降雨與降雪等資訊納入推薦條件，說明氣候條件可作為服裝推薦的重要依據[31]。場合因素指穿著行為所對應的活動目的、場域、時段與社會互動情境，例如通勤、約會、旅行、婚禮或正式工作場合。不同場合會改變穿搭所需的正式度、功能性與社會合宜性。例如婚禮場合通常需要較正式的穿搭，紅洋裝搭配高跟鞋也比搭配球鞋更符合婚禮情境，顯示場合資訊可視為影響穿搭相容性與推薦結果適切性的關鍵條件[41]。相較於天氣與場合，風格並非直接來自外在物理環境，而是由服裝輪廓、材質、色彩、圖樣、單品組合與配件等視覺線索共同形成的美學傾向，同一套穿搭亦可能同時呈現多種風格特徵[2]。因此，本文不將風格視為單一服飾類別或固定標籤，而是將其視為描述整體穿搭氛圍、審美方向與使用者造型偏好的語意條件。此一設定可補足天氣與場合無法表達的視覺偏好，使推薦模型不僅考量穿搭是否符合當下情境，也能回應使用者對整體造型印象與風格語氣的需求。

情境感知穿搭推薦並非僅僅將天氣資料加入推薦流程，而是將天氣、場合與風格三類因素轉換為可供模型學習的文字條件。三者在功能上各有差異：天氣提供穿著舒適度限制，場合提供活動與社會情境限制，風格則提供視覺語意與美學方向。由於使用者在實際搜尋穿搭時，通常會以自然語言同時表達溫度感受、使用情境與風格需求，例如「涼爽天氣的通勤休閒穿搭」或「夏日約會的優雅造型」，因此本文後續方法並未將三類因素拆為彼此獨立的固定標籤，而是整合為單一條件化穿搭描述。在參考論文中也指出，相較於提供圖片或使用數量有限的風格類別，自然語言描述能讓使用者以更方便且直覺的方式表達穿搭條件，並可適用於更多情境。此觀點支持本研究採用文字化情境描述，而非僅以固定風格類別建立推薦條件[43]。

綜合前述文獻與上述概念界定可知，雖然服裝推薦系統已在視覺理解、搭配相容性、多模態語意建模與生成式推薦方面取得進展，但若以日常穿搭決策為目標，現有方法仍有若干不足，主要可歸納為以下三點。

首先，既有服裝推薦研究多以視覺相容性、風格一致性與使用者偏好為主要核心，對於穿搭結果是否符合具體使用情境仍缺乏充分處理。雖然此類方法能有效提升推薦結果在外觀搭配與風格協調上的表現，但日常穿搭決策同時受到環境條件、場合屬性、活動強度與舒適度需求等因素制約。若模型僅依據視覺或語意層面的相容性進行推薦，而未能納入上述情境限制，則推薦結果可能在形式上具備搭配合理性，卻難以充分滿足實際穿著需求，進而形成推薦結果與真實使用需求之間的落差。

其次，現有研究尚缺乏將自然語言情境需求轉換為可計算推薦條件的系統化流程。在實際應用中，使用者對穿搭的需求往往以自然語言表達，例如天氣感受、活動安排、場合限制與風格偏好等條件常同時出現，且具有模糊性與隱含性。若缺乏一致且可檢核的條件轉換機制，模型容易只根據文字表層語意進行判斷，導致不同描述方式下的推薦依據不穩定，或使部分情境限制在推薦過程中被弱化。

第三，現有文字條件式與生成式穿搭推薦較少引入具物理意義的舒適度尺度。雖然近年研究能透過文字描述、影像特徵或風格標籤控制推薦結果，但多數方法仍以語意或視覺特徵作為主要依據，較少使用可比較、可解釋且具物理基礎的中介指標描述穿著舒適性。對日常穿搭而言，保暖程度、活動強度與環境溫度並非單純的風格問題，而會直接影響推薦結果是否實用。若缺乏此類約束，推薦結果即使具有視覺相容性，也可能忽略實際穿著需求，降低系統在真實情境中的可用性與可信度。

基於上述缺口，本文聚焦於日常穿搭情境下推薦條件的建構、控制與驗證。具體而言，本文以 CLO、MET 與熱舒適條件作為中介尺度，將天氣、活動與場合等情境需求轉換為具物理意義、可計算且可控制的文字條件，進而支援後續穿搭推薦任務。在方法定位上，本文結合大型語言模型進行情境化描述生成與品質檢核，並透過結構化條件與檢核規則降低生成內容不穩定所造成的影響。在概念層次上將天氣、場合與風格視為影響日常穿搭決策的三類情境感知因素；而後續消融實驗中對天氣、場合與風格的拆分，則屬於實驗操作定義，目的在於分析不同語意因子對推薦效能的相對貢獻。其後，本文將所建構的條件化描述應用於下游穿搭推薦任務，檢驗該流程是否能提升推薦結果對天氣、場合與風格需求的回應能力。相較於既有研究多著重於相容性建模、風格生成或推薦結果本身，本研究更強調推薦條件形成過程的可解釋性、可比較性與可檢核性，期望提升服裝推薦系統在日常穿搭決策中的實用性與可信度。

第三章、研究方法

承接前一章對服裝推薦技術演進、情境感知需求缺口與本文研究定位的整理，本章進一步說明本研究如何將天氣、場合與風格等日常穿搭情境需求，轉換為可計算、可控制且可驗證的推薦條件。具體而言，本文聚焦於情境感知語意的建構流程，透過 CLO 與 MET 作為中介尺度，結合熱舒適條件推估、條件化描述改寫與 LLM-as-a-Judge 生成品質評估流程，將抽象情境需求轉換為具物理意義與語意可用性的文字條件，作為後續穿搭推薦任務的基礎。透過此一流程，本文期望縮減自然語言情境描述與模型可計算條件之間的落差，並建立可重現的系統設計流程。基於上述架構，本章將依序說明研究問題與系統目標、整體研究流程、資料工程與條件建構方式、推薦模型設計，以及後續實驗評估任務的規劃，作為第四章實證結果分析的基礎。

3.1 研究問題定義與系統目標

多數現有服裝推薦系統以電商應用為主要研究領域，其設計核心著重於推薦視覺相似或高互動率商品，以提升平台轉換率與銷售效益，較少針對使用者日常生活中的實際穿搭決策情境進行處理與整合。相較於在商品集合中挑選單一最相似或最熱門項目，日常穿搭更接近一種受限制的整體組合決策：使用者需要在既定行程與天氣條件下，維持整體風格一致，並兼顧場合適切性與穿著舒適度。當描述包含氣溫變化、降雨可能性、以及上課、開會、聚餐等多場合切換時，條件通常以語意形式呈現且隱含推理與取捨，例如保暖層次、材質與防護性、攜帶便利性、正式度可切換性等。若缺乏一致且可檢核的條件轉換流程，系統將難以在不同表述方式下維持穩定推薦依據，常出現視覺協調但情境限制不足的結果，導致使用者需反覆試錯調整，降低系統的實用性與信任度。

因此，本研究聚焦於情境感知穿搭的文字條件建模與套裝推薦，核心研究問題定義為：在天氣與行程等情境感知資訊已知的前提下，如何將使用者的語意需求轉換為一致且可控制的文字條件表示，並檢驗該條件表示是否能在不顯著犧牲搭配協調性的前提下，提高套裝推薦對情境感知條件與舒適度需求的符合程度。此問題的關鍵在於條件符合度與搭配協調性之間的權衡：若模型過度依賴既有搭配分布或視覺相容性，容易產生外觀合理但不完全符合天氣、場合與舒適度限制的結果；反之，若條件過於硬性，可能降低整體協調性與可穿性。為使推薦結果能落地於日常穿搭決策，本研究同時要求推薦條件具備可追溯性與可解釋性，以支援使用者回饋與調整。基於上述觀察，本研究提出情境感知驅動的智慧穿搭推薦系統架構，並設定以下系統目標：以可重現的流程整合天氣與行程，產生可供模型使用的文字條件；同時引入具物理意義的舒適度指標作為一致的約束來源；並透過生成品質評估與後續推薦任務驗證，區分條件反映程度與模型推薦表現，使推薦結果的分析具備可解釋性與可追溯性，進而支援使用者互動調整並提升日常可用性。

3.2 研究流程

由於現有穿搭資料通常已包含套裝影像、單品組合與風格描述，但較少呈現天氣、場合及活動需求等情境感知語意，若完全依賴人工逐筆標註，不僅成本較高，也不易維持不同樣本之間的標註一致性。因此，本研究建立一套由物理指標推導至自然語言條件的資料建構流程，將衣物保暖程度、活動強度及主觀舒適溫度參考值轉換為可供文字條件式穿搭推薦模型學習的情境感知描述。

如圖 3-1 所示，本研究以原始穿搭資料集為基礎，依序進行知識基準整理、物理反向推導、溫度區間轉換、大型語言模型條件化改寫與生成資料品質評估，並依評估結果決定是否調整生成設定與重新批次生成。各步驟說明如下：

步驟 1. 知識基準整理

本研究首先蒐集並整理 CLO、MET 及熱舒適度相關標準、文獻與公開資料，建立 CLO 數值對照表格、活動類型與 MET 對應表格及主觀舒適溫度計算方式等知識基準。此知識基準並非由原始穿搭資料直接取得，而是作為後續推導與生成階段的外部依據，用以限制大型語言模型的推估範圍，避免相同或相近的穿搭組合因生成表達差異而得到差異過大的 CLO、MET 或溫度結果，並提升資料建構流程的一致性與可檢核性。

步驟 2. 套裝層級的 CLO 與 MET 反向推導

以原始資料集中的套裝影像、單品組合及原始套裝描述為輸入，依據前一步建立的知識基準，反向推估每套穿搭所對應的套裝層級 CLO 值與可能活動類型，再將活動類型映射至相應的 MET 值。其中，CLO 用以表示整套穿搭的保暖程度，MET 則反映活動強度所造成的代謝產熱。由於原始穿搭資料並未直接提供 CLO、活動及 MET 標註，本研究將此一由穿搭內容推估物理相關代理值的過程概括為物理反向推導。完成推估後，另依據預先設定的數值範圍與對應規則進行異常值檢查及修正，降低不合理代理值對後續溫度計算的影響。

步驟 3. 熱舒適度推估

將前一步取得的 CLO 與 MET 代入基於 Fanger 熱平衡概念的 McIntyre 主觀舒適溫度簡化模型[32]，計算各套穿搭所對應的主觀舒適溫度，並依據計算結果轉換為相應的冷暖程度與天氣條件。此處所得溫度並非實際氣象觀測值，也非個別使用者真實的熱舒適感受，而是在一致環境假設下，由 CLO 與 MET 推導出的比較性參考值。其主要用途是將不同套裝的保暖程度與活動強度對應至共同的溫度尺度，使後續大型語言模型能依據相對一致的冷暖條件生成天氣語意，避免僅憑套裝外觀任意判斷適穿溫度。

步驟 4. 套裝描述條件化改寫

以原始套裝影像與原始套裝描述為主要內容來源，並將前述步驟取得的CLO、MET 及主觀舒適溫度參考值共同作為條件輸入，交由多模態大型語言模型進行套裝描述改寫。改寫後的文字須同時反映三類情境感知語意，包括天氣感受（Weather, W）、活動或場合語意（Occasion, O）及穿搭風格（Style, S）。其中，天氣語意主要依據主觀舒適溫度參考值建構；活動與場合語意參考 MET 及原始套裝內容；風格語意則依據套裝影像與原始描述中的造型線索生成。透過此步驟，原始資料中偏向商品或外觀介紹的文字描述，將被改寫為較接近日常使用者查詢形式的情境感知文字條件，使推薦模型能進一步學習天氣、場合與風格需求和穿搭組合之間的關係。

步驟 5. 生成資料品質評估與整體可用性確認

針對條件化改寫後的套裝描述，本研究依循 PREF 的三階段架構[13]，並結合 Check-Eval 的清單式檢核機制[35]，從圖文一致性、情境條件反映程度、圖像依據及推薦任務適用性等面向進行品質評估。評估結果用於確認正式批次生成資料的整體品質與後續實驗可用性，但不作為依單筆分數刪除、篩選或替換描述的依據。僅當評估結果顯示存在系統性或大範圍問題時，才調整生成設定並重新批次生成；少數個別錯誤則保留，並納入後續低分樣本與失敗案例分析。

綜觀上述流程，各步驟之間具有明確的資料依賴關係：步驟一建立的知識基準用以約束步驟二的 CLO 與 MET 推導範圍；步驟二所得的 CLO 與 MET 作為步驟三計算主觀舒適溫度參考值的輸入；步驟三形成的溫度結果提供步驟四進行情境感知描述改寫；步驟五則評估生成資料的整體品質與後續實驗可用性。完成資料建構後，本研究將改寫後的情境感知文字條件投入推薦模型進行訓練與驗證，並透過穿搭相容性預測與套裝推薦兩項任務，比較不同文字條件設定下的模型表現，以評估所建構情境感知資料對不同推薦任務的適用性及其效益。此流程使各階段均具有明確的輸入、處理方式與輸出結果，並提升整體實驗流程的可追溯性與結果可信度。

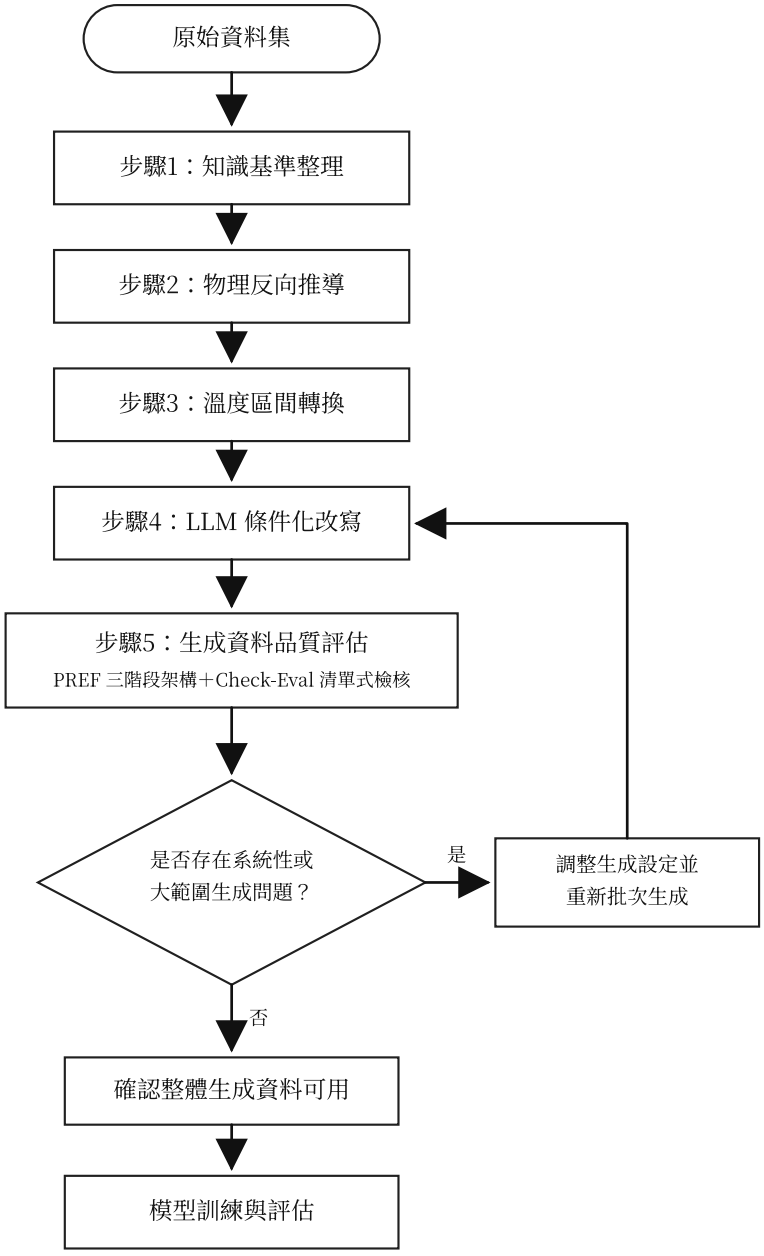


圖 3 - 1、研究流程圖

3.3 資料工程

前述研究架構提及本研究需同時處理兩類資訊來源：一為使用者以自然語言描述的穿搭需求與情境限制，二為模型訓練與推論所需的可計算條件。由於現有穿搭資料多僅包含單品組合與風格描述，缺乏環境與舒適度的量化資訊，若直接以原始資料進行條件式學習，難以確保訓練階段與應用階段條件的一致性。因此，本研究於資料工程中引入「反向推導」與參數標準化，以既有套裝資料為基礎，推估其保暖需求與活動強度，轉換為可比較且可檢查的數值指標。透過此方式，可補齊原始資料中缺乏的環境與舒適度資訊，並建立訓練與應用階段共用的條件表示。

在本研究中，穿著舒適度相關條件主要以 CLO 與 MET 作為量化基礎。CLO 與 MET 為描述人體熱交換狀態的實用單位，此概念最早由 Gagge、Burton 與 Bazett（1941） 於二戰初期提出[14]，旨在建立一套能跨越工程、生理與醫學領域的共同描述系統。現今為熱舒適度評估中常用的個人因素指標，已被 ASHRAE 與 ISO 的熱環境評估流程採用，用於描述衣著保暖程度與活動強度對熱平衡的影響。相關指標常應用於室內熱舒適評估與建築環境設計，並可搭配 PMV（Predicted Mean Vote）等方法進行舒適度推估。將上述指標引入資料工程流程，為套裝資料建立一致的量化參考，使後續條件生成與評估有可依循的共同基準。

近年熱舒適與電腦視覺估計研究顯示，CLO 與 MET 並非僅是傳統標準中的靜態查表參數，而是持續作為個人熱狀態評估與動態估計的重要變數。Sun 等人指出，PMV 模型除環境參數外，仍需納入衣著保暖程度與活動代謝率兩項個人參數；然而，這兩項參數在實際情境中較難直接取得，因此近年研究開始透過影像、影片與深度學習模型進行動態估計。該研究建立基於電腦視覺的 CLO 與 MET 偵測模型，並顯示在其實驗條件下，使用實測 CLO 與 MET 計算 PMV，較使用 ASHRAE Standard 55 標準值更接近實際熱感受[39]。另一方面， Aparicio-Ruiz 等人亦指出，衣著保暖程度同時存在於靜態熱舒適與適應性熱舒適方法中，並可應用於使用者輔助系統與服裝組合建議，以改善熱舒適與能源效率[3]。

基於上述脈絡，本文並非直接進行即時影像式 CLO 與 MET 偵測，而是延續近年熱舒適與電腦視覺估計研究中對個人熱舒適參數的重視，將 CLO 與 MET 作為穿搭資料工程中的中介尺度。透過此一設計，本文得以將天氣、活動與舒適度等抽象情境需求，轉換為具物理意義、可比較且可檢查的文字條件，進而使原本偏向風格與搭配語意的穿搭資料，能進一步連結至實際穿著情境。

3.3.1 衣物保暖指數 (Clothing Insulation, CLO)

CLO 為量化衣著隔熱性能的標準化單位，用以描述衣物對人體熱流所提供的熱阻。一般而言，1 clo 代表一名靜止成人在約 21 °C、微風（<0.1 m/s）且低濕度環境下，為維持熱平衡所需的衣物隔熱量。本文採用國際通用的 CLO 單位換算關係式，如式 3 - 1。 CLO 值亦為熱舒適度模型的重要輸入參數， Fanger 於 1970 年代提出的 PMV 模型將服裝隔熱量（Icl，單位為 clo）納入計算，用以量化服裝對熱舒適的影響[12]，許多冷暖空調（heating, ventilation and air conditioning, HVAC）設計指南與人體熱平衡模型亦多依賴 CLO 數值，以評估室內環境對人體的影響。因此，本研究將 CLO 作為服裝隔熱能力的可比較尺度，作為後續資料合成與條件約束的依據。

$$1\ \text{clo} = 0.155\ \text{m}^2\cdot\text{K/W} = 0.88\ ^{\circ\text{F}}\cdot\text{ft}^2\cdot\text{hr/Btu} \qquad \text{式 3 - 1}$$

本研究的 CLO 資料同時涵蓋單品與套裝兩種層級。由於單一資料庫在實務上常出現覆蓋不完整或尺度不一致的情形，例如單品具備隔熱數值但套裝資料不足，或套裝資料難以回推至單品層級。此外，部分資料建立年代較早，可能與現代服裝版型、材質與穿著情境存在差異。基於覆蓋率與可追溯性的需求，本文整合三

類 CLO 來源：其一為 2021 年 **ASHRAE 測試報告**，來自 ASHRAE RP-1760 專案，包含 69 套西方常見服裝套裝的熱阻實測值[37]。該研究指出，既有資料庫多建立於 1970–1980 年代，且對動作與風速影響的交代不足，因此採用多實驗室、多區域熱人偶量測以更新資料庫，並提供總隔熱、固有隔熱與修正因子等資訊。其二為**單品與套裝實測論文**（Zhao 等人, 2025），利用熱人偶量測 34 件單品衣物（20 件上身、14 件下身）及其組合成的 16 套代表性服裝的隔熱量[50] ，並比較「標準估值」與「實測值」的差異，指出以標準值代表現代服裝可能產生系統性偏差。其三為 **ASHRAE 2010 版衣物隔熱資料表**，即 ASHRAE 標準 55 附錄所列的傳統服裝隔熱估值，用於補充現代實測未涵蓋的服裝類型[4]。考量套裝隔熱量可能受疊穿造成的空氣層壓縮與有效受熱面積變化影響，總隔熱值未必可由單品 CLO 直接加總推得，並可能產生非線性偏差[26]。此外，單品隔熱值亦會隨材質、厚度與款式（如是否連帽、長短羽絨版型）而異。基於上述考量，本文不以單品加總方式推導套裝 CLO ，而是直接採用文獻與標準表所提供的數值，並彙整為兩份結構化對照資料，分別為單品衣物的 CLO 對照表（附錄 A），以及套裝的 CLO 對照表（附錄 B）。

接著，將附錄 A 與附錄 B 的 CLO 值對照資料納入模型輸入，作為模型推論參考依據。本文採用固定模板提示詞以限制輸出格式，要求模型回傳單一套裝的總 CLO，並以 JSON 形式輸出，以利後續批次彙整與資料串接。模型輸出後，本文將結果逐筆寫入紀錄檔案，作為後續條件生成與資料分析的隔熱條件標籤。提示詞以模板化方式整理，如圖 3 - 2 所示： System 區塊固定任務定義與輸出限制，User 區塊輸入穿搭資訊與圖片，以及 CLO 對照資料的欄位內容。為確保標註品質，本文加入兩階段後處理。第一階段為合理範圍檢核，以排除非數值結果與明顯不合理的總 CLO。第二階段為異常值修正：先以已完成的有效標註計算四分位距 (Interquartile Range, IQR)，並以 1.5 倍 IQR 建立上下界，將超出範圍的樣本視為異常值。針對異常值樣本，本文回溯其原始穿搭內容並重新執行推論；若新結果通過合理性檢核，則以新值覆寫原標註。

SYSTEM
You are a clothing thermal comfort expert. Your task is to estimate the total CLO insulation value of an outfit.

Return exactly two blocks:
[REASONING]
- <=4 bullets, <=280 chars, no tables, no lists from data.
- Briefly note included layers and ignored accessories.

<json>{"total_clo": number}</json>
Only one JSON object. Do not echo inputs.

USER
Outfit description: {outfit_desc}
Items:{items_block}

Reference CLO knowledge:
Ensemble CLO values:{ensemble_clo_text}
Single item CLO values:{single_items_clo_text}

Now, estimate the total CLO value of this outfit.Return two blocks exactly:
[REASONING] <=4 bullets, <=280 chars.
<json>{"total_clo": number}</json>

圖 3 - 2、提示詞模板

3.3.2 活動代謝率 (Metabolic Equivalent of Task, MET)

MET 用於量化人體在不同活動強度下的代謝產熱，並作為熱平衡與熱舒適度推估中的個人因素之一。Gagge et al. (1941) [14] 將 1 met 定義為單位體表面積每小時約 50 calories 的代謝率，並指出此值約對應於人體在熱舒適條件下坐姿休息時的代謝水準。其中，原文的 calories 採當時常見的大卡用法，依現代單位記法相

當於 50 kcal。為避免與小卡（cal）混淆，本文統一將其表示為 50 kcal·h^{-1}·m^{-2}，並以式 3 - 2 作為 MET 的基準換算。該研究亦指出，若要在假設的最佳皮膚溫度下維持熱平衡，且不需額外的生理調節，須同時考量人體產熱、衣著隔熱與環境溫度三項因素。其中，人體產熱主要受到肌肉活動程度影響，因此 MET 可用於描述活動所造成的代謝產熱負荷，並與 CLO 共同作為後續情境條件建構與熱舒適度推估的量化基準。

$$1\ \text{met} = 50\ \text{kcal} \cdot \text{h}^{-1} \cdot \text{m}^{-2} \qquad \text{式 3 - 2}$$

為將行程或活動描述轉換為一致的 MET 數值，本研究採用 **2024 Adult Compendium of Physical Activities** [21] 作為日常活動的 MET 對照依據。該對照表以文字描述對應 MET 值，涵蓋步行、通勤與日常工作等多類活動，可作為將情境描述轉換為代謝強度的標準參考。然而，原始對照表共包含 **1,114** 筆活動類型，如表 3 - 1 所示，若直接將完整表格納入大型語言模型提示詞，容易因輸入長度限制而影響參考的一致性與穩定性。因此，本研究對資料進行預處理：先依 MET 值由小至大排序，並在 MET 值相同的情況下，以活動主類別 (Major Heading) 為單位進行去重，僅保留具代表性的活動描述。經整理後，對照清單縮減為 457 筆，作為後續生成任務的標準參考集，表 3 - 2 為整理後前五筆範例。

表 3 - 1、2024 Adult Compendium of Physical Activities 主類別分布情況

活動大類 （Major Heading）	**活動代碼範圍**	**筆數**	**處理後**
Bicycling （自行車）	01003 - 01262	42	25
Conditioning Exercise （體能訓練）	02000 - 02344	89	38
Dancing （舞蹈）	03005 - 03093	35	18
Fishing & Hunting （釣魚與狩獵）	04001 - 04168	38	18
Home Activities （居家活動）	05010 - 05300	71	21
Home Repair （房屋修繕）	06010 - 06240	37	10
Inactivity （靜態活動）	07009 - 07075	14	4
Lawn & Garden （草坪與園藝）	08009 - 08262	53	24
Miscellaneous （其他/雜項）	09000 - 10135	41	9
Music Playing （樂器演奏）	10010 - 10135	27	10
Occupation （職業勞動）	11000 - 11892	143	34
Running （跑步）	12010 - 12620	82	41
Self Care （自我照護）	13000 - 13050	11	6
Sexual Activity （性行為）	14010 - 14030	3	3
Sports （運動項目）	15000 - 15734	157	44
Transportation （交通運輸）	16002 - 16060	14	10
Walking （步行）	17010 - 17492	77	34
Water Activities （水上活動）	18010 - 18440	102	41
Winter Activities （冬季運動）	19005 -19405	78	34
Religious Activities （宗教活動）	20000 - 20100	20	12
Volunteer Activities （志願服務）	21000 - 21070	22	13
Video Games （電子遊戲）	22040 - 22360	8	8

表 3 - 2、前五筆排序後 MET 值與活動對照表

MajorHeading	ActivityCode	METValue	ActivityDescription
Fishing & Hunting	04160	1.0	Sitting in boat, passenger
Inactivity	07009	1.0	Lying quietly and watching television
Miscellaneous	09025	1.0	Laughter, sitting
Religious Activities	20000	1.0	Sitting in church, in service, attending a ceremony, sitting quietly
Conditioning Exercise	02135	1.3	Whirlpool, sitting

在 MET 標註流程中，本研究以穿搭的套裝描述與單品組合作為判斷依據，並參照前述活動候選清單，選取最符合該穿搭所隱含的行動型態與場合需求的活動類型，提示詞指令如下圖 3 - 3。為避免活動描述被任意改寫而影響數值對應，本研究限制活動標註僅能從候選清單中擇一既有活動名稱，確保後續 MET 查表具有一致且可回溯的對應關係。完成活動選取後，研究流程即依該活動於對照表中所列的 MET 值進行指派，作為該樣本的活動代謝率。為確保標註結果的有效性，本研究僅接受能成功對應至候選清單的活動標註；若初次判定未能產生合法對應，則重新執行活動選取流程，直至取得可對應的結果為止。最終，每筆樣本均同時保留其活動類型與對應的 MET 數值，作為後續熱舒適度推估與條件化資料建構的輸入。

SYSTEM
You are a fashion-domain outfit and activity matching expert.

Think like a person planning their day: infer mobility, environment, and occasion from what's worn, then pick exactly one activity from the provided list.

Core reasoning (no examples):
- Mobility intuition: Use footwear properties (sole/heel/stability/coverage/traction/contact area) to estimate safe movement and standing duration.
- Environment fit: From fabric weight/breqthability, exposure, layering/protection, and dirt/wet tolerance, infer suitability for indoor climate control, urban paved surfaces, natural terrain, or near-water settings.
- Occasion parity: The activity's social formality must match the outfit's level.
- Load & free-hands: Align with carry system and hand freedom.
- Strongest signal rule: When signals conflict, satisfy occasion parity first; then let the single strongest physical signal decide movement intensity and setting. Do not average toward the middle.

Decision steps:
1) Occasion Parity Gate
2) Mobility Gate
3) Environment Gate
4) Selection rule: From "Available Activities", choose a single option that passes all three gates, is the most specific valid description, and appears verbatim in the list (exact string match).

Verification (no examples):
- Confirm occasion parity, environment compatibility, and movement intensity alignment.
- If any check fails, switch to the next most specific valid listed option that passes all checks. Prefer specificity over umbrella terms.

Strict output:
- PART A: 3–5 bullet points covering movement intensity, stability/ground, occasion parity, environment fit, and—if relevant—load/free-hands.
- PART B: {"activity": "<MUST COPY EXACTLY from Available Activities above, no paraphrasing>"}.

USER
Outfit description: {outfit_desc}
Items: {items_block}

Available Activities (choose exactly one; exact string match required): {activities_text}

Instructions:
- Apply the SYSTEM_PROMPT reasoning and decision steps without restating them.
- Produce the strict output format:
- PART A: 3–5 bullets (movement intensity; stability/ground; occasion parity; environment fit; load/free-hands if relevant).
- PART B: {{"activity": "<MUST COPY EXACTLY from Available Activities above, no paraphrasing>"}}
- Do not invent or paraphrase activity names. No examples in the explanation.

If Failed
IMPORTANT (Hard Constraint):
- The previous answer "{failed_activity}" is INVALID.
- Do NOT output "{failed_activity}" again.
- If you think "{failed_activity}" is conceptually right, COPY the closest exact phrase from the list that mentions the same concept verbatim.

圖 3 - 3、活動生成模板

3.3.3 熱舒適度推估：基於 McIntyre 主觀舒適溫度的簡化模型

取得每筆套裝對應的衣物保暖指數與活動代謝率後，本研究需進一步將兩者轉換為可對應環境條件的熱舒適度參考，作為後續環境條件生成與合理性檢核依據。為此，本研究採用以 Fanger 熱舒適理論為基礎的簡化推估方法，建立 CLO 與 MET 與主觀舒適溫度的對應關係。Fanger 於 1970 年代提出的預測平均評價模型（Predicted Mean Vote, PMV）係以人體熱平衡為核心[12]，綜合考量代謝率、衣著隔熱、空氣溫度、平均輻射溫度、風速與濕度等因素，用以預測群體對熱環境的主觀感受。該模型已被納入 ASHRAE 與 ISO 熱舒適相關標準，並廣泛應用於建築與室內環境設計。然而，完整 PMV 計算需同時處理多項環境變數，且假設條件較為嚴謹，不適合直接用於大規模資料工程與條件生成流程。

基於上述考量，本研究參考 McIntyre（1978）所提出的實務化熱舒適推估觀點[32]，將熱舒適視為衣著隔熱與活動強度在特定環境假設下的函數關係，如式 3 - 3。McIntyre 指出，在假設室內風速、濕度與輻射條件處於一般可接受範圍時，影響主觀熱感的主要因素可簡化為「人體產熱」與「衣著隔熱」兩項，並可據此推估一組對應的舒適溫度範圍。此類簡化方法已被實務研究與設計指引廣泛採用，用以快速估計不同活動與穿著組合下的熱需求。

$$T_{\text{sub}} = 33.5 - 3I_{\text{clo}} - (0.08 + 0.05I_{\text{clo}})M \qquad \text{式 3 - 3}$$

在本研究中，簡化熱舒適推估流程以 CLO 與 MET 為輸入，於假設一般室內環境條件（中等濕度、低風速、無顯著輻射不對稱）下，推估該套裝於特定活動強度下所對應的目標主觀舒適溫度 (T_{sub})。此推估結果不作為精確的生理預測，而是用於建立穿搭、活動及環境之間的一致性關係，使每筆資料樣本皆具備一組可比較的熱舒適參考值。實作上，活動強度以 MET 作為輸入指標，並依文獻的標準定義轉換為方程式所需的代謝率形式後進行計算。本研究依據既有文獻與標準表所整理的 CLO、MET 與溫度對應關係，將每筆樣本的 CLO 與 MET 映射至一個主觀舒適溫度，並將該結果作為後續條件化文字生成與品質評估的依據。透過此方式，系統得以檢核生成的情境描述在熱舒適層面是否具備基本合理性，例如避免在高活動強度且隔熱較低的條件下生成不合理的低溫需求，或在高隔熱套裝下對應過高的環境溫度。此推估流程的目的在於提供一個具物理意義且可追溯的中介表示，而非試圖重現完整的人體熱平衡機制，使語意化的穿搭需求得以對齊至一致的熱舒適條件尺度，從而支援後續條件生成、模型訓練與結果解釋。

3.3.4 套裝描述改寫：將客觀量化條件注入原始語意情境

在完成套裝的 CLO 估計、MET 標記，以及依基於 Fanger 熱平衡概念的 McIntyre 簡化模型推估主觀舒適溫度後，本研究進一步進行套裝描述的語意改寫，將客觀的熱舒適條件轉換為自然語言情境線索。本研究於資料工程階段的條件生成與描述改寫任務，皆採用 Google Gemma 3（gemma-3-4b-it）[1]多模態語言模型進行描述生成，其模型規模較小、推論成本較低，適合作為資料工程階段的條件生成模型。

[1] https://huggingface.co/google/gemma-3-4b-it

圖 3-4 套裝描述改寫流程整合三類資訊來源。首先，參考資料層提供衣物保暖指數與活動代謝率的對照表；接著，條件推導層透過模型分析套裝圖像與單品組合，推估對應的 CLO 與 MET，並進一步經由 McIntyre 主觀舒適溫度簡化模型計算主觀舒適溫度；最後，模型依據上述條件生成結合環境感受、活動情境與穿搭風格的自然語言描述。在描述生成階段，提示詞如附錄 C 所示，模型接收套裝拼貼圖像、原始描述、推導的 CLO 值與計算所得溫度作為輸入。以原始描述為“fairy purplish wedding” 的紫色系禮服套裝為例，模型依單品組合推導其 CLO 與 MET，並經 McIntyre 主觀舒適溫度簡化模型計算後得到主觀舒適溫度為 23.6°C，最終生成描述 “23.6°C, dreamy purple wedding vibes for a warm, romantic evening”。該描述將客觀溫度條件、婚禮行程與紫色系視覺風格自然融合，相較原始描述提供更具情境感知意涵的語意線索。

本研究在描述生成階段並未要求模型分別輸出天氣、場合與風格三個欄位，而是將三類因素整合為一段自然語言查詢式標題。此設計主要基於兩點考量。第一，文字條件式穿搭推薦模型的輸入形式為套裝描述，而非結構化標籤；若將條件拆為獨立欄位，可能降低其與實際使用者查詢語氣之間的相似度。第二，天氣、場合與風格在自然語言中常會彼此交織，例如 “cool office casual look” 同時包含冷暖感受、職場情境與休閒風格，因此本研究保留其整體語意脈絡，使模型能學習較完整的情境化穿搭描述。換言之，描述生成階段強調的是情境感知語意的自然整合，而非將天氣、場合與風格拆解為彼此獨立的標籤欄位。為確保輸出一致性，系統於後處理階段進行格式正規化，統一溫度符號表示並檢核是否符合標準格式；若模型輸出不符預期，則保留其情境語意並以正確溫度值重新組合。原始套裝資料中僅具簡要標題的描述，得以轉換為同時涵蓋環境條件、熱舒適邏輯與穿搭情境的語意表示，確保訓練與應用階段使用一致的條件特徵表示，並為後續條件式生成與評估提供穩定且可追溯的語意基準。

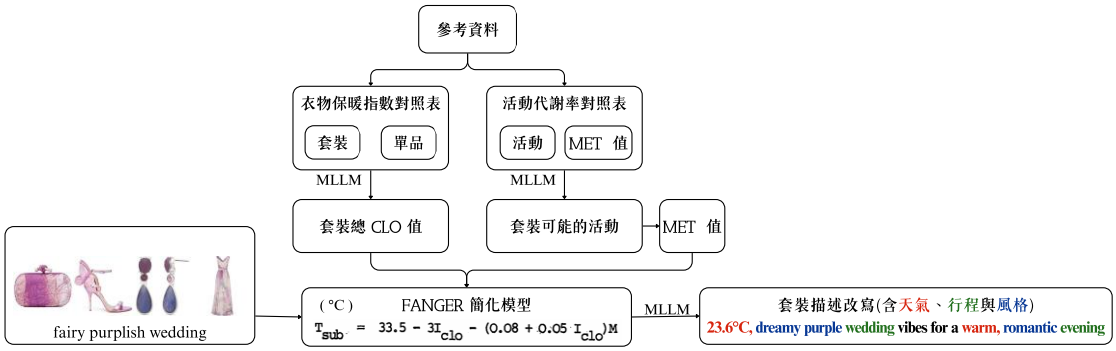


圖 3-4、完整資料工程示意圖

3.4 資料建構控管與可重現性

為確保情境感知語意資料建構過程具備一致性、可追溯性與可重複執行性，本研究於資料工程階段建立資料建構控管機制。涵蓋 CLO 推導、活動與 MET 對應、熱舒適度推估，以及套裝描述改寫流程。各階段透過固定輸入資料、明確界定

任務內容、限制輸出格式、檢查資料合法性、處理異常結果，以及保存正式輸出與必要的錯誤資訊，降低大型語言模型輸出不穩定對後續資料建構造成的影響。

本節著重說明資料如何依固定規則產生、檢查與保存，以及各階段產生的資料如何相互對應。文字長度可能造成的影響、生成描述是否包含目標單品線索，以及生成內容的圖文一致性與情境合理性，將於第 3.5 節進一步說明；推薦模型與評估任務則於第 3.6 節介紹。

3.4.1 資料建構流程與分工

情境感知語意資料的建構流程包含 CLO 推導、活動與 MET 對應、熱舒適度推估，以及套裝描述改寫四個主要階段。各階段處理不同性質的資料，並以前一階段產生的結果作為後續處理依據。

首先，CLO 推導階段依據套裝影像與服飾內容，估計整套穿搭的衣物保暖程度，產生套裝層級的 CLO 值。其次，活動推定階段根據套裝影像、原始描述及 CLO 資訊，判斷該套穿搭可能對應的活動情境，再將活動名稱對應至預先整理的活動清單，以取得相應的 MET 值。接著，依據 CLO 與 MET，使用 McIntyre 基於 Fanger 熱舒適模型[32]所提出的簡化公式進行熱舒適度推估，並取得後續情境語意建構所需的主觀舒適溫度參考值，使服裝保暖程度、活動強度與冷暖條件之間建立可追溯的對應關係。最後，套裝描述改寫階段整合原始套裝文字、穿搭影像、CLO、活動、MET 與主觀舒適溫度參考值，生成同時反映天氣、場合與風格的情境感知描述。

各階段的技術依據與處理方式已於第 3.3 節說明，其中第 3.3.1 節介紹 CLO 的推導方式，第 3.3.2 節說明活動與 MET 的對應流程，第 3.3.3 節說明熱舒適度推估方法，第 3.3.4 節則介紹套裝描述改寫流程。本節從整體資料建構角度，說明各階段如何使用一致的輸入、輸出及處理規則，使最終情境感知描述能回溯至其原始套裝資料與代理變數來源。

3.4.2 生成條件與輸出限制

為降低大型語言模型自由生成所造成的格式差異與內容偏移，本研究於各項生成任務中明確規定輸入資料、任務目標與輸出格式，並將模型回應轉換為可供程式處理的資料欄位。不同階段雖採用不同的提示詞與輸出內容，但皆遵循固定輸入範圍、限制輸出內容與檢查輸出格式等原則。

在 CLO 推導階段，模型輸入包含套裝影像、單品資訊及 CLO 參考資料，任務目標限定為估計套裝層級的總 CLO 值。模型輸出以可解析的數值為主，避免將 CLO 判斷混雜於無固定格式的長篇文字中，使其能直接作為後續活動推定與熱舒適度推估的輸入。CLO 推導所使用的參考資料、提示詞調整歷程與異常處理方式整理於附錄 D。在活動與 MET 對應階段，本研究不直接要求模型自由產生 MET 數值，而是要求模型根據套裝影像、原始描述及 CLO 資訊，判斷較符合穿搭情境

的活動。模型所選擇的活動須對應至預先整理的候選活動清單，再由程式依據活動對照資料取得固定的 MET 值。此一設計可避免模型任意產生缺乏依據的活動強度，並使每一筆 MET 值皆能回溯至具體活動項目及其參考來源。活動推定提示詞、候選活動清單與 MET 對應規則整理於附錄 E 。

熱舒適度推估是根據 CLO 與 MET，依第 3.3.3 節所述之簡化公式計算主觀舒適溫度參考值，並非由大型語言模型生成。此作法能使相同的 CLO 與 MET 組合皆能透過一致的方法完成推估，避免大型語言模型因文字表達差異而產生不同的冷暖條件。主觀舒適溫度參考值主要用於後續天氣與冷暖語意的建構，並非實際氣象觀測結果，亦不等同於個別使用者實際感受到的熱舒適狀態。完成上述推估後，資料進入套裝描述改寫階段，模型輸入包含套裝影像、原始套裝文字、CLO、活動與 MET，以及熱舒適度推估所得的主觀舒適溫度參考值，模型須依據上述條件生成同時反映天氣、場合與風格的情境感知描述，並進行文字格式整理，包括移除多餘符號、統一溫度表示方式，以及確認輸出內容是否符合預定格式。若模型回應的格式不符預期，但仍能辨識其中的情境語意，則依既定規則進行整理，使批次輸出維持一致且可解析的資料形式。套裝描述改寫所使用的主要提示詞模板與調整歷程分別整理於附錄 C 與附錄 F 。

3.4.3 代理變數檢查與錯誤處理

為避免資料格式錯誤、代理變數異常或活動對應失敗持續影響後續流程，本研究分別針對 CLO、活動與 MET，以及熱舒適度推估結果進行資料檢查與錯誤處理。相關處理方式依各階段的資料性質而有所不同，主要用於確認模型輸出是否可正確解析、代理變數是否具有明確來源，以及不同階段的資料能否依套裝樣本正確對應。

在 CLO 推導階段，若模型輸出無法解析為合法數值，或數值不符合合理範圍，該筆樣本會被標記為異常或失敗。完成 CLO 推論後，再以四分位距法標記資料分布中的異常樣本，其界線分別為第一四分位數減去 1.5 倍四分位距，以及第三四分位數加上 1.5 倍四分位距。被標記的樣本不會直接刪除，而是回溯其原始套裝影像與資料，再次執行 CLO 推論。重新推論所得的 CLO 值若落於 0 至 3 clo，則以新結果更新原紀錄；若重新推論失敗、輸出無法解析，或新結果仍未符合設定條件，則保留原始結果及相關異常資訊。此處的 0 至 3 clo 僅作為異常樣本重新推論後的檢查範圍，並非正式資料中所有 CLO 值的固定上限，也不表示超出該範圍的樣本均應排除。附錄 D 所述之失敗紀錄與續跑機制，主要用於處理無效輸出與執行中斷，並非完整保存每一筆樣本的所有模型回應、失敗嘗試與重新推論歷史紀錄。

在活動與 MET 對應階段，檢查重點為模型輸出的活動名稱能否對應至預先整理的活動清單。若活動名稱不完整、超出候選範圍，或無法與活動對照資料中的項目正確匹配，則視為無效活動結果，並重新執行活動推定。部分無效結果會保留必要資訊，以支援後續錯誤重試，並避免模型重複產生相同的無效活動答案。由於 MET 值是由對照表中的活動項目對應取得，因此此階段的重點是檢查其是否能正

確對應到活動清單。活動對應、字串比對、相似度輔助修正及錯誤重試方式詳見附錄 E。

熱舒適度推估以完成前述處理的 CLO 與 MET 作為輸入。計算前會確認必要欄位是否完整、資料型態是否正確，以及 CLO、MET 與原始套裝資料是否能正確對應。若必要欄位缺漏或無法解析，則須先完成資料修正後，再進入主觀舒適溫度參考值計算與套裝描述改寫流程。推估所得的主觀舒適溫度參考值屬於資料建構中的代理變數，而非人體實驗量測結果、真實氣象資料或個人化熱舒適度標籤。因此，本研究不使用特定溫度區間排除樣本，而是在完成資料建構後，分析其整體分布、主要範圍及極端值情形，以呈現簡化熱舒適度推估可能產生的邊界案例。

在套裝描述改寫階段，錯誤處理重點在於輸出格式的一致性與可解析性。生成結果會進行文字格式整理，包括移除多餘符號、統一溫度表示方式，以及確認輸出內容是否符合預定格式。若模型回應的格式不符預期，但仍能辨識其情境語意，則依既定規則整理為標準格式，以維持批次資料的一致性。處理完成後，正式資料保留套裝識別資訊、原始套裝文字、CLO、活動、MET、主觀舒適溫度參考值及情境感知描述等後續實驗所需欄位。

本研究所保存的內容主要包括各階段的正式輸出資料，以及支援錯誤處理、重新推論與接續執行所需的部分資訊，並未完整保存方法開發期間每一次模型呼叫、所有中間回應與全部失敗嘗試。因此，本文不另行回推各階段的完整失敗率、重試次數或淘汰率。上述處理主要用於降低資料格式錯誤、活動對應失敗及單次推論異常對後續描述生成造成的影響。最終資料中 CLO、MET 與主觀舒適溫度參考值的實際分布、主要範圍與極端值情形，將於 4.2.1 節呈現；各階段較完整的處理規則則整理於附錄 D、附錄 E 與附錄 F。

3.4.4 提示詞調整與正式資料設定

本研究於方法開發期間，曾針對 CLO 推導、活動推定與套裝描述改寫進行多次提示詞調整。調整內容主要包括限制輸出格式、改善數值解析方式、縮小活動選擇範圍，以及加強生成描述對天氣、場合與風格條件的反映。透過問題樣本檢視與錯誤類型整理，資料建構流程逐步由較開放的模型回應，調整為具有固定輸入條件、明確任務要求、可解析輸出格式及異常處理方式的流程。在 CLO 推導方面，提示詞由早期較自由的數值判斷，逐步調整為較明確的套裝層級 CLO 推估任務，並搭配格式解析與異常值重新推論。活動推定方面，則由一般性的活動猜測，調整為以穿搭情境為基礎，並受到候選活動清單限制的活動配對任務。套裝描述改寫方面，則逐步加入 CLO、MET、主觀舒適溫度參考值及影像語意條件，使生成描述能同時反映冷暖需求、場合脈絡與整體風格。

提示詞的調整屬於方法開發過程，主要用於修正輸出格式、活動對應與情境條件表達等問題，並逐步形成正式採用的資料建構流程。由於早期版本未使用一致的樣本範圍與評估方式進行比較，因此不將不同提示詞版本列為正式實驗條件，亦不據此判定各版本的效能差異。各階段的主要調整內容、常見問題與最終提示詞設

定，分別整理於附錄 D、附錄 E 與附錄 F。正式資料建構階段固定使用最終採用的大型語言模型、提示詞、輸入欄位、活動候選清單、CLO 與 MET 參考資料、熱舒適度推估公式、輸出格式及異常處理規則。完成資料解析、格式檢查與情境感知描述建構後，共取得 35,140 筆可用樣本，作為後續主要推薦實驗、情境因素消融實驗與個案分析的共同資料基礎。本研究的可重現性主要建立於上述資料來源、模型與提示詞設定、代理變數建構依據、處理規則及正式實驗資料的明確保存與說明。

完成正式資料建構後，下一節將進一步說明生成資料品質評估與補充分析方法，包括文字長度影響、目標單品線索檢查與生成描述品質評估。上述分析用於檢查正式資料中可能影響後續推薦結果解讀的因素，但 LLM-as-a-Judge 的分數、回饋與建議改寫不作為正式資料的刪除、篩選或描述替換依據。

3.5 生成資料有效性評估設計

情境感知描述相較於原始套裝文字，進一步納入天氣、場合與風格等語意資訊。然而，資料建構結果仍可能受到代理變數極端值、文字長度差異、目標單品線索，以及生成內容與套裝影像或情境條件不一致等因素影響。若未針對上述情形進行檢視，後續推薦效能的差異可能同時反映情境語意補強與其他資料特性，進而影響實驗結果的解讀。為檢視所建構資料的有效性，本研究分別從代理變數合理性、文字長度影響、目標單品線索與生成描述品質四個面向進行評估。其中，代理變數的檢查與異常處理方式已於第 3.4.3 節說明，其實際分布與合理性分析則於第 4.2.1 節呈現。本節主要說明其餘三項評估方法。

首先，文字長度影響分析用以檢視原始套裝文字與情境感知描述之間的長度差異，並分析文字長度變化與檢索表現變化之間的關係，以確認推薦效能提升是否可能受到描述長度增加所影響。其次，目標單品線索檢查用以確認生成描述是否直接出現目標單品的類別名稱或相關品項詞彙，藉此評估文字條件中是否存在可能降低檢索難度的答案線索。最後，生成描述品質評估透過 LLM-as-a-Judge，檢查生成內容的圖文一致性、情境條件反映程度與文字表達品質，並進一步進行雙評分模型比較、提示詞穩健性檢查及人工稽核。

文字長度影響分析與目標單品線索檢查主要用於辨識可能影響推薦結果解讀的替代因素；生成描述品質評估則用於掌握正式資料的整體品質，並作為判斷是否需進一步篩選或處理生成資料的依據。評分模型所產生的問題回饋與建議改寫僅供品質分析與案例說明使用，不直接取代正式生成描述。各項評估結果及後續資料處理於下一章節呈現。

3.5.1 文字長度影響分析

原始套裝文字多由簡短的商品頁面名稱、套裝標題或風格詞彙組成，情境感知描述則進一步納入天氣、場合與風格資訊，因此兩種文字條件在長度上可能存在明顯差異。若情境感知描述的檢索表現較佳，其改善可能部分來自文字資訊量增加，而不完全來自所加入的情境語意。為檢查此一可能性，本研究針對條件式單品檢索任務所使用的查詢資料進行文字長度影響分析。

文字長度依正式分析程式所採用的詞彙計算方式取得。對第 i 筆查詢而言，令 L_i^O 表示原始套裝文字的詞彙數，L_i^C 表示情境感知描述的詞元數，兩種文字條件的長度差定義如式 3 - 4。當 ΔL_i 為正值時，表示情境感知描述較原始套裝文字長；數值越大，代表兩種文字條件的長度差異越明顯。

$$\Delta L_i = L_i^C - L_i^O \qquad \text{式 3 - 4}$$

為檢視文字長度差異是否與檢索表現變化相關，本研究分別分析文字長度差與 Hit@10 變化，以及文字長度差與目標單品排名變化之間的關係。令 H_i^O 與 H_i^C 分別表示第 i 筆目標單品在原始套裝文字與情境感知描述條件下是否進入前 10 名，進入前 10 名時記為 1，否則記為 0，則 Hit@10 的變化定義如式 3 - 5。當 $\Delta H_i = 1$ 時，表示目標單品僅在情境感知描述條件下進入前 10 名；當 $\Delta H_i = -1$ 時，表示目標單品僅在原始套裝文字條件下進入前 10 名；當 $\Delta H_i = 0$ 時，則表示兩種文字條件的命中情形相同。

$$\Delta H_i = H_i^C - H_i^O \qquad \text{式 3 - 5}$$

另令 R_i^O 與 R_i^C 分別表示目標單品在兩種文字條件下的檢索排名，排名改善量定義如式 3 - 6。由於排名數值越小代表排序越前，當 ΔR_i 為正值時，表示使用情境感知描述後，目標單品的推薦排名有所提升；當其為負值時，則表示排名下降。

$$\Delta R_i = R_i^O - R_i^C \qquad \text{式 3 - 6}$$

除相關分析外，本研究分別檢視詞彙數差異與前 10 名命中變化，以及詞彙數差異與排名改善量之間的相關程度，以判斷描述長度增加是否伴隨較明顯的推薦表現改善。若兩者僅呈現有限相關，則表示套裝推薦效能的提升不太可能完全由文字變長所造成。為進一步降低兩種文字條件長度差異所造成的影響，本研究建立相近長度子集，分別納入兩種文字條件詞彙數完全相同，以及詞彙數差異不超過 1、2、3 與 5 個詞彙的樣本，其篩選條件如式 3 - 7。在各相近長度子集中，分別比較原始套裝文字與情境感知描述的前 10 名命中率，以觀察當兩者詞彙數相同或接近時，情境感知描述是否仍能維持相同的推薦表現變化方向。

$$| \Delta L_i | \leq k, k \in \{0,1,2,3,5\} \qquad \text{式 3 - 7}$$

上述相關分析、長度分組分析與相近長度子集分析，主要用於檢查文字長度是否足以構成推薦效能改善的替代解釋，而非證明文字長度與推薦效能之間的因果關係。若各項分析皆未顯示推薦表現主要隨文字長度增加而提升，則可支持效能改善並非僅由情境感知描述較長所造成。

3.5.2 目標單品線索檢查

條件式單品檢索的目的，是根據文字條件與部分穿搭內容，從候選單品中找出適合完成套裝的目標單品。若情境感知描述直接包含目標單品的類別名稱、品項名稱或具高度辨識性的詞彙，模型可能依賴文字中的答案線索完成檢索，而不需充分理解天氣、場合與風格等情境語意。因此，本研究針對條件式單品檢索任務所使用的文字條件與目標單品進行線索檢查。進行比對前，原始套裝文字、情境感知描述、目標單品名稱與類別欄位皆採用相同的文字整理方式，包括統一英文字母大小寫、移除或轉換標點符號，以及依相同規則進行詞彙切分。完成文字整理後，分別從類別線索與品項詞彙線索兩個層次進行檢查。

類別線索檢查首先確認文字條件中是否直接出現目標單品的細分類別名稱，例如踝靴、手提包或西裝外套等；其次，進一步確認文字中是否出現目標單品所屬的大分類名稱，例如鞋類、包袋、上身服飾或外套等。若生成描述包含目標單品的細分類別或大分類詞彙，則記錄為存在相應的類別線索。品項詞彙線索檢查則比較文字條件與目標單品名稱之間的詞彙重疊情形。首先，檢查兩者是否至少包含一個相同且具辨識性的詞彙；其次，進一步檢查是否出現相同的連續雙詞組合。相較於單一詞彙重疊，連續雙詞重疊可較嚴格地反映生成描述是否包含與目標單品名稱相近的片語。

為判斷線索出現是否主要來自情境感知描述的生成過程，本研究亦對原始套裝文字進行相同的類別與詞彙重疊檢查，並比較原始套裝文字與情境感知描述中的線索出現比例。若兩種文字條件皆具有相近的線索比例，則相關詞彙可能原本即存在於 Polyvore 套裝文字中；若情境感知描述的出現比例明顯較高，則需進一步檢視生成過程是否加入過多與目標單品直接相關的資訊。服裝類別詞本身亦可能是合理的穿搭查詢內容，例如「適合通勤的外套」或「夏季約會洋裝」，因此出現類別詞彙不必然等同於答案洩漏。本項分析主要用於檢查生成描述是否相較於原始套裝文字，更頻繁或更明確地揭露目標單品資訊，並評估此現象是否可能影響後續檢索結果的解讀。

3.5.3 生成描述品質評估

由於套裝描述改寫屬於開放式生成任務，缺乏唯一正確答案，且品質不僅涉及語言流暢度，更關係到描述是否如實反映穿搭組合，以及是否回應情境條件與控制需求，因此需要進行系統性的品質評估，過去相關研究主要採用兩類評估方式[27]：自動化數值指標（如語意相似度或困惑度）與人工標註評分。前者具備低成本與可重現性，但較難涵蓋多重條件控制、創意表達與複雜語意結構；後者可提供較細緻

判斷，卻在大規模資料情境下成本高昂，且一致性難以長期維持。隨著大型語言模型能力提升，近年開始採用 LLM-as-a-Judge 作為替代方案，透過模型模擬人工評審進行整體品質判斷。然而，多數做法仍偏向以單一分數或通用品質準則衡量，對任務偏好、條件控制與多面向權衡的可追溯性支持相對有限，尤其缺乏人工黃金標準時，易使評估準則不夠具體而難以診斷問題。

基於上述限制，本研究結合兩種互補框架進行生成資料品質評估。首先，採用 PREF [13] 所提出的三階段評估邏輯作為整體骨架，將生成品質區分為通用品質涵蓋與任務條件對齊兩個層次，前者用於檢查生成描述是否具備基本品質，例如內容忠實性（faithfulness）與圖文一致性，後者則用於衡量生成結果是否正確反映本研究所控制的天氣、場合與風格等因素，例如可控性與條件反映程度。然而，PREF 的優勢在於能將一般品質與條件對齊分開評估，但其原始設計主要以個人化文字生成為對象，且偏向整體評分，較難直接指出生成描述在哪一項條件上出現不足。為此，本研究進一步引入 Check-Eval [35] 的清單式評估機制，將品質要求轉換為可逐項檢查的條件項目，並以 YES／NO 方式檢視生成內容是否滿足各項要求，能提升評估結果的可解釋性，使錯誤來源更容易被追蹤；但其原始設計主要針對文字品質評估，若單獨使用，仍不足以反映本研究中不同條件的重要性差異。完整評分程序如演算法 1 所示。

演算法 1

Require:
Image collage set $I = \{i_n\}_{n=1}^{N}$
Description set $D = \{d_n\}_{n=1}^{N}$
Paired dataset $\mathcal{X} = \{\mathcal{X}_n\}_{n=1}^{N}$ with $\mathcal{X}_n = (i_n,\ d_n)$
Coverage LLM M_{cov}
Preference LLM M_{pref}
Scoring LLM M_{score}

Ensure:
Scores $S = \{s_{\text{n}}\}_{n=1}^{N}$
Feedback $F = \{f_n\}_{n=1}^{N}$
Suggested Revision $R = \{r_n\}_{n=1}^{N}$

Phase 1: Generate General Guidelines

$$C \leftarrow \text{GENERATEGUIDELINE}(M_{\text{cov}}, \mathcal{X})$$

$C = \{\boldsymbol{c}_1, \ldots, \boldsymbol{c}_{\text{m}}\}$, a universal checklist of yes/no items (criterion-guided, reference-free).

Phase 2: Personalize Guidelines

$$C* \leftarrow \text{PERSONALIZE}(M_{\text{pref}}, \mathcal{X}, C)$$

$C*$ re-ranks and may augment C according to global task conditions; denote $C^* = \{c_1^*, \ldots, c_{m*}^*\}$ (m^* may differ from m). All inputs thereafter are evaluated against the same C^*.

Phase 3: Score Descriptions

for each $\mathcal{X}_n = (i_n,\ d_n)$ in $\mathcal{X}$ **do**

$$(s_n, f_n, r_n) \leftarrow \text{SCORE}(M_{\text{score}}, \mathcal{X}_n, C*)$$

end for

return **S**, **F**, **R**

為降低評估結果過度依賴單一評分模型，本研究選用參數規模相近、公開可取得且具多模態輸入能力的 Qwen3-VL-32B-Instruct[2] 與 Gemma-3-27B-it[3] 作為雙評分模型。Qwen3-VL [46] 以 Apache 2.0 授權公開發布，Gemma 3 [15] 則為 Google 發布的公開權重模型，兩者皆支援圖文輸入，而官方技術文件亦指出，Qwen3-VL 在可比較的計算資源與推論延遲條件下，相較同時期同尺寸其他模型具有較佳表現，Gemma 3 則在同尺寸級距中表現突出。後續研究將 Qwen3-VL-32B-Instruct 記為評分者 A（Judge A），Gemma-3-27B-it 記為評分者 B（Judge B）。

評分者 A 與評分者 B 皆依循 PREF 的分層架構與 Check-Eval 的清單式檢核方式，分別建立各自的一般檢核清單 C_A 與 C_B，再依情境感知穿搭推薦任務的重要性，調整為加權檢核清單 C_A^* 與 C_B^*。兩評分模型的檢核項目、項目數量與權重配置並不完全相同，但皆涵蓋內容與情境、視覺屬性、天氣條件、場合語意、風格表達及語句品質等面向。清單示意圖如圖 3 - 5 所示，左圖為一般檢核清單；右圖為加權後的檢核清單，依任務重要性將圖文一致性、天氣條件、場合語意、風格一致性與語句流暢度等項目配置不同權重，使圖文一致性與情境條件反映程度等關鍵項目在整體分數中具有較高影響。兩評分模型檢核清單建立方式、評分提示詞調整歷程、相關控管規則與完整清單紀錄於附錄 G。

ID	Assessment Criteria	Check
Dimension 1: Content & Context		
c1	Does the description include weather/temperature context?	☐
c2	Does it mention the overall style (e.g., evening glamour)?	☐
	.....	
Dimension 2: Visual Attributes		
c6	Does it accurately reflect the color palette?	☐
c7	Does it mention key design features (e.g., lace)?	☐
	.....	
Dimension 3: Quality Control		
c8	No Hallucinations (avoids non-existent elements)?	☐
c10	Is the text grammatically correct and fluent?	☐

ID	Wgt.	Assessment Criteria	Check
Tier 1: High Priority (Safety & Grounding)			
c8	4	No hallucinations (avoids non-existent elements)	☐
Tier 2: Content & Context			
c1	3	Includes temperature/weather context	☐
c4	3	Conveys intended occasion or context	☐
		.....	
Tier 3: Visual & Text Quality			
c6	2	Reflects accurate color palette	☐
c10	1	Grammatically correct and fluent	☐
		.....	

圖 3 - 5、清單示意圖

正式評分時，評分者 A 與評分者 B 分別固定使用各自建立的加權檢核清單、權重設定與評分提示詞，並針對相同的套裝影像與生成描述進行獨立評分。令 r 表示評分模型，其中 $r \in \{A, B\}$；m_r 表示評分者 r 的檢核項目總數；$y_{ij}^{(r)}$ 表示評分者 r 對第 i 筆生成描述之第 j 項檢核結果，符合要求時記為 1，不符合時記為 0；$w_j^{(r)}$ 則表示評分者 r 之第 j 項檢核權重。第 i 筆生成描述由評分者 r 所給予的加權品質分數定義如式 3 - 8：

[2] https://huggingface.co/Qwen/Qwen3-VL-32B-Instruct
[3] https://huggingface.co/google/gemma-3-27b-it

$$S_i^{(r)} = \frac{\sum_{j=1}^{m_r} w_j^{(r)} y_{ij}^{(r)}}{\sum_{j=1}^{m_r} w_j^{(r)}}, r \in \{A, B\} \qquad \text{式 3 - 8}$$

其中，$S_i^{(r)}$ 的數值介於 0 與 1 之間；分數越高，表示該描述通過較多或權重較高的檢核項目。此計算方式允許兩位評分者使用不同數量的檢核項目與權重配置，並將分數正規化至相同範圍。每筆評分結果皆包含逐項 YES／NO 判斷、加權品質分數、問題回饋與建議改寫；其中，問題回饋與建議改寫僅用於低分樣本與失敗案例分析，不直接取代正式生成描述。

由於 LLM-as-a-Judge 的評估結果可能受到評分模型、評分尺度與提示詞設定影響，相關研究指出，LLM-as-a-Judge 的應用需進一步考量不同評分模型的判斷差異、模型偏誤與提示詞變化所造成的影響，以提升評估結果的可靠性[18, 27]。因此，本研究除正式品質分數外，進一步透過雙評分者比較、提示詞穩健性檢查與人工稽核，檢視評估結果的穩定程度。

在雙評分者比較方面，本研究首先統計評分者 A 與評分者 B 的平均品質分數、標準差與分數分布，並以語意嵌入比較兩組加權檢核清單的概念涵蓋程度，以確認兩者是否針對相近的品質面向進行評估。考量兩位評分者使用不同的檢核清單與權重配置，其絕對分數尺度未必一致，因此另以各自評分結果中的相對排序定義低分樣本，分別取最低 5%、10% 與 20% 建立低分集合，並計算實際交集、隨機期望交集、Lift、Jaccard 係數與 F1。此分析並非假設兩位評分者應產生完全相同的分數，而是檢查兩者是否能共同辨識較可能存在品質問題的樣本。採用三種低分比例亦可觀察重疊結果是否過度依賴單一門檻。

為進一步檢查評分結果對提示詞設定的敏感程度，本研究從正式評分結果的高分與低分區段各抽取 75 筆樣本，共 150 筆進行提示詞穩健性檢查。正式評分提示詞記為 P0，P0-R2 為相同設定下的重複執行版本，用以檢查重現性。P1 調整檢核項目的排列順序，P2 則加入證據不足或不確定時判定為不符合的保守規則。各版本皆使用相同樣本與輸出格式，比較其評分差異與樣本品質排序的變化。

除自動化評估外，本研究另從生成資料中選取 30 筆進行人工稽核。為涵蓋不同品質表現與評分分歧情形，先依評分者 A 與評分者 B 的正式品質分數建立百分位排名，並計算兩者平均百分位排名、百分位排名差與原始品質分數差。低分候選樣本定義為平均百分位排名不高於 0.25，且百分位排名差不高於 0.35；高分候選樣本定義為平均百分位排名不低於 0.75，且百分位排名差不高於 0.35；評分衝突候選樣本則定義為百分位排名差不低於 0.50，或兩位評分者的原始品質分數差不低於 0.25。三類各選取 10 筆，並固定隨機種子為 42。選樣時同時考量溫度、活動量、場合與風格，使人工稽核案例具有基本情境多樣性。溫度依主觀舒適溫度參考值區分為低於 12°C、12°C 至低於 18°C、18°C 至低於 24°C 與 24°C 以上，活動量則依 MET 區分為低於 1.3、1.3 至低於 1.6 與 1.6 以上。上述區間僅用於檢查樣本覆蓋情形，而非氣象、熱舒適度或活動強度的通用分類標準。

人工稽核沿用評分者 A 與評分者 B 的加權檢核清單 C*，由研究者根據相同的套裝影像與生成描述逐項進行 YES／NO 判斷。評分者 A 的清單包含 10 個題項，30 筆樣本共形成 300 項人工判斷；評分者 B 的清單包含 15 個題項，共形成 450 項人工判斷，合計為 750 項。完成逐項判斷後，再依式 3-8 相同的權重計算方式，分別取得每筆樣本對應兩組清單的人工加權分數，並與相對應的模型品質分數比較。比較指標包含偏差、平均絕對誤差、均方根誤差、Pearson 相關係數與 Spearman 等級相關係數，另比較人工與模型在各檢核題項上的加權分歧程度。人工稽核主要用於進一步檢視模型評分與人工判斷之間的差異，並協助辨識較容易產生分歧的檢核項目。由於本研究僅針對 30 筆樣本進行人工稽核，其目的在於補充驗證 LLM-as-a-Judge 的評估結果，而非建立大規模人工標註資料，上述評估結果於第 4.2.4 節呈現。

3.6 推薦模型與實驗評估設計

為全面評估本研究方法在穿搭理解與推薦情境中的表現，本研究從基礎搭配判斷與實際推薦能力兩個層面進行分析。首先，以 CP 任務檢驗模型是否具備辨識整體搭配合理性的能力；其次，以 OR 任務評估模型在候選單品集合中完成補全與排序的能力。為檢驗條件化描述改寫是否能提升推薦任務表現，本研究於相同推薦模型架構與資料切分設定下，比較兩種文字條件輸入：（1）Polyvore 原始描述；（2）本研究生成的情境感知改寫描述。透過固定模型架構並僅替換文字條件來源，可觀察情境感知語意注入對推薦結果的影響。

為降低單次模型訓練所產生的隨機差異，各任務皆以五組固定隨機種子重複執行，並回報各項評估指標之平均值、標準差與 95% 信賴區間。由於原始描述與情境感知改寫描述皆於相同隨機種子及實驗設定下進行比較，兩組結果屬於成對資料，因此採用成對樣本 t 檢定檢驗各項指標的平均差異。差值統一定義為「情境感知改寫描述－原始描述」；當差值為正時，表示情境感知改寫描述帶來效能提升。除回報 p-value 外，本研究亦計算成對樣本效果量 Cohen's d_z(式 3 - 9)，用以衡量兩種文字條件之標準化平均差異。其中，$\bar{D}$ 為五次重複實驗中「情境感知改寫描述－原始描述」配對差值的平均數，s_D 為該配對差值的標準差。

$$d_z = \frac{\bar{D}}{s_D} \qquad \text{式 3 - 9}$$

各任務之平均值、標準差、信賴區間、統計顯著性與效果量結果，將於第四章節呈現。由於本研究同時檢定多項主要推薦指標，若分別依未校正的 p值判定顯著性，可能增加多重比較下的偽發現風險。因此，本研究採用 Benjamini–Hochberg 方法進行多重比較校正，以控制偽發現率（False Discovery Rate, FDR），並依校正後的 p 值判定統計顯著性。各指標另回報配對差異的 95% 信賴區間，用以呈現平均差異的估計範圍、方向與不確定性。

3.6.1 文字條件式穿搭推薦模型

在本研究中，文字條件式穿搭推薦模型作為固定的下游推薦骨幹，用於比較不同文字條件來源對穿搭相容性與套裝推薦表現的影響。採用 Wang 與 Zhong 所提出之文字條件式穿搭推薦模型 *Text-Conditioned Outfit Recommendation with Hybrid Attention Layer* [43] 。該模型結合套裝層級文字條件與單品多模態特徵，並透過混合注意力層 (Hybrid Attention Layer) 建模文字條件、單品特徵及套裝內部單品關係，可支援穿搭相容性預測與套裝補全推薦任務。該模型為公開且完整實作的文字條件式穿搭推薦方法[4]，在相關任務上具備穩定且具代表性的效能表現。

選擇該模型主要基於以下考量，首先，該方法以 Polyvore 資料集[19]作為訓練與評估基礎，而 Polyvore 同時包含套裝結構、單品圖像與文字描述，與本研究採用的資料來源及任務設定一致。其次，該模型可將自然語言描述作為套裝推薦條件，並同時考量文字需求與單品之間的搭配關係，符合本研究檢驗情境感知文字條件是否能改善穿搭相容性與套裝推薦表現的目的。最後，該方法屬於在既有候選單品空間中進行相容性判斷與排序的推薦架構，而非直接生成新服裝影像或單品，因此能透過固定候選集合與評估指標進行一致且可比較的實驗分析。基於上述特性，本研究將其作為固定推薦模型，並將比較重點集中於文字條件來源的差異，而非推薦模型架構本身。

模型透過多模態特徵表示與注意力機制，整合套裝層級文字條件及單品資訊。如圖 3-6 所示（依據原混合注意力架構改繪而成），模型以 Polyvore 套裝資料為輸入，分別對文字描述、單品名稱與單品圖像進行特徵編碼。套裝層級文字描述經由文字編碼器轉換為文字條件嵌入，用以表示使用者對穿搭情境與整體造型的語意需求；單品名稱與單品圖像則透過 FashionCLIP 抽取文字與視覺特徵，形成單品的多模態嵌入表示。在此基礎上，混合注意力層同時建模文字條件與各單品之間的關聯，以及套裝內不同單品之間的搭配關係，並依注意力權重整合為套裝情境表示。模型再根據該表示進行相容性判斷與候選單品排序：在穿搭相容性預測任務中，用以區分原始套裝與替換單品後形成的負樣本；在套裝推薦任務中，則用以計算候選單品與部分套裝及文字條件之間的相符分數，並產生推薦排序。

為使固定推薦模型與前述資料工程結果銜接，本研究維持 Polyvore 原始套裝結構、單品圖像、單品名稱、特徵抽取方式、推薦模型架構及資料切分不變，僅替換套裝層級的文字條件來源。第一種文字條件為 Polyvore 原始描述，由 url_name 與 title 組成；第二種則為 3.3.4 產生的套裝改寫描述視為文字查詢來源之一，使文字條件不再僅停留於簡短標題，提供更貼近日常穿搭情境的描述線索。換言之，圖 3-6 中的「文字描述」可分別替換為原始描述或情境感知改寫描述，其餘模型輸入與處理流程均維持一致，藉此檢驗情境感知語意補強是否能改善穿搭相容性判斷與套裝推薦排序。

[4] https://github.com/WangXin93/text-conditioned-outfit-recommendation

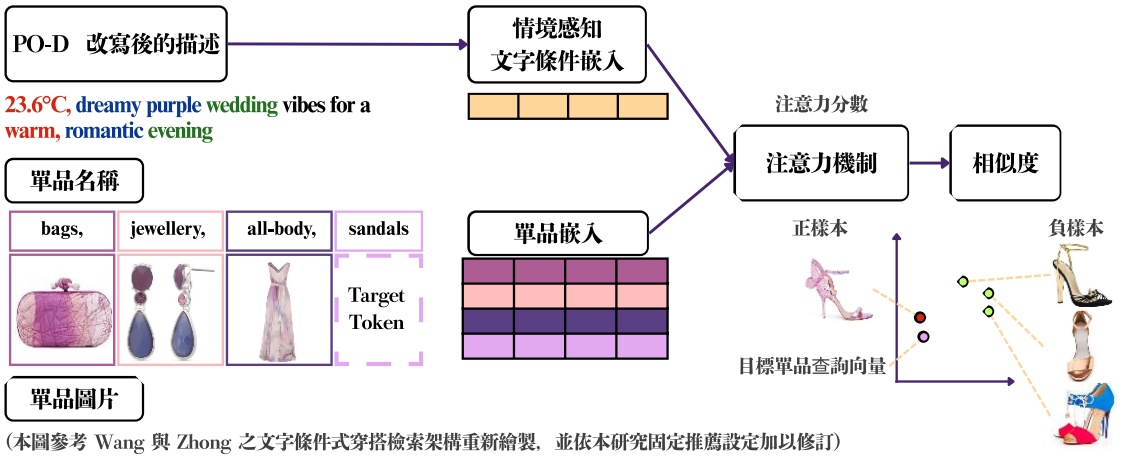


圖 3 - 6、推薦流程

3.6.2 任務一：穿搭相容性預測 (Compatibility Prediction, CP)

CP 任務旨在判斷一組服裝單品是否能在整體風格、視覺協調性與穿搭邏輯上形成合理的套裝配置。此任務主要用於評估模型能否掌握套裝層級的單品關係，而非僅根據個別單品特徵進行判斷。由於本研究的核心目標之一，是檢驗情境感知文字條件能否在維持套裝內部相容性的同時提升推薦表現，因此先透過 CP 任務評估模型對整體搭配關係的建模能力，作為後續套裝推薦任務的重要基礎。

資料與任務設定依循 Polyvore Outfits Disjoint 的套裝相容性評估方式，將資料集中原有的套裝組合作為正樣本，並透過替換原套裝中的單品建立負樣本，使其形成與原套裝結構不相容的組合。令一套穿搭表示 $O = \{o_1, o_2, \ldots, o_n\}$，模型輸入包括套裝中各單品的圖像特徵矩陣 $\mathbf{I}$、單品文字特徵矩陣 $\mathbf{T}$、套裝遮罩 $\mathbf{M}$，以及套裝層級文字條件嵌入 $\mathbf{d}$，並輸出介於 0 與 1 之間的相容性分數 s，如式 3 - 10 所示。其中 f_θ 表示參數為 θ 的文字條件式穿搭推薦模型，σ 表示 Sigmoid 函數。

$$s = \sigma\left(f_\theta\left(\mathbf{I}, \mathbf{T}, \mathbf{M}, \mathbf{d}\right)\right) \qquad \text{式 3 - 10}$$

模型訓練採用二元交叉熵損失，使正樣本獲得較高的相容性分數，負樣本則獲得較低的相容性分數。負樣本訓練採漸進式策略，初期使用隨機替換所形成的負樣本，後期再加入較難區分的硬負樣本，以提升模型辨識細微搭配差異的能力。相較於僅在單品層級進行排序，CP 任務可直接反映模型是否能捕捉套裝內部的結構性搭配關係，並作為後續套裝推薦模型訓練與效能比較的基礎。

評估指標方面，本研究以接收者操作特徵曲線下面積（Area Under the Receiver Operating Characteristic Curve, AUC）作為相容性預測的主要指標，用以衡量模型區分相容套裝與不相容套裝的排序能力。AUC 可解釋為模型對任一正樣本 x^+ 所給予的相容性分數，高於任一負樣本 x^- 的機率，如式 3 - 11 所示。由於 AUC 不依賴特定的分類閾值，因此適合比較不同文字條件下模型的整體相容性判斷能力。

$$\mathrm{AUC} = \Pr\big(s(x^+) > s(x^-)\big) \qquad \text{式 3 - 11}$$

除整體相容性預測外，本研究另採用填空式搭配（Fill-in-the-Blank, FITB）作為輔助評估，以檢驗模型能否根據部分已知套裝與文字條件，從候選單品中選出正確的缺漏單品。對第 i 題 FITB 問題，令已知的部分套裝為 $\mathcal{O}_i^{\text{partial}}$，候選單品集合為：$\mathcal{C}_i = \left\{c_i^{(1)}, c_i^{(2)}, \ldots, c_i^{(K)}\right\}$，將第 k 個候選單品加入部分套裝後，可形成候選補全套裝：$\mathcal{O}_i^{(k)} = \mathcal{O}_i^{\text{partial}} \cup \left\{c_i^{(k)}\right\}$ 模型分別計算各候選補全套裝在文字條件 $\mathbf{d}_i$ 下的相容性分數，並選擇分數最高者作為預測結果，如式 3 - 12 所示。

$$\hat{k}_i = \arg\max_{k \in \{1,\ldots,K\}} s\left(\mathcal{O}_i^{(k)}, \mathbf{d}_i\right) \qquad \text{式 3 - 12}$$

令 k_i^* 表示第 i 題的正確候選索引，填空搭配正確率定義如式 3 - 13 所示。

$$\mathrm{Acc}_{\mathrm{FITB}} = \frac{1}{N}\sum_{i=1}^{N} \mathbb{I}\left[\hat{k_i} = k_i^*\right] \qquad \text{式 3 - 13}$$

其中，N 為 FITB 測試題目總數，$\mathbb{I}[\cdot]$ 為指示函數；當模型預測的候選索引與正確答案相同時取值為 1，否則為 0。

本研究之 CP 評估共包含 30,290 筆正負套裝測試配對；FITB 評估則以 15,145 筆測試套裝建立填空式搭配問題。兩種文字條件皆使用相同的正負樣本、候選集合與測試題目，以確保原始描述與情境感知改寫描述之間的比較不受評估樣本差異影響。透過 AUC 與 FITB Accuracy，本研究可分別從「整體套裝相容性排序」與「局部缺漏單品選擇」兩個角度，評估模型對穿搭結構與文字條件的理解程度，並作為後續套裝推薦任務與兩種文字條件比較的依據。

3.6.3 任務二：套裝推薦 (Outfit Recommendation, OR)

OR 旨在根據部分套裝、套裝層級文字條件與待補全單品類別，從候選單品集合中找出最適合補全套裝的目標單品。相較於 CP 任務著重判斷完整套裝的相容性，OR 任務進一步對候選單品進行評分與排序，以檢驗模型能否將搭配關係轉化為單品推薦能力。訓練時，模型先完成 CP 任務，再以其權重作為初始化進行 OR 微調，使模型在保留套裝相容性判斷能力的基礎上，進一步學習部分套裝、文字條件與目標單品之間的對應關係。

對第 q 筆推薦查詢，令已知的部分套裝為 $\mathcal{O}_q^{\text{partial}}$，套裝層級文字條件為 $\mathbf{d}_q$，待補全單品之目標類別為 g_q。候選單品集合記為：$\mathcal{C}_q = \left\{c_q^{(1)}, c_q^{(2)}, \ldots, c_q^{(N_q)}\right\}$，其中，$\mathcal{C}_q$ 由符合目標類別 g_q 與任務篩選條件的單品所構成，N_q 為第 q 筆查詢的候選單品數量。候選池中包含該查詢的正確目標單品，模型的目標是在所有候選單品中，將正確單品排序至推薦列表前段。此設定不同於 FITB 任務中的固定少量候選選擇，而是著重於較大候選集合中的單品檢索與排序能力。

模型首先整合部分套裝的單品特徵與文字條件，產生該查詢的套裝情境表示 $\mathbf{h}_q^{\text{context}}$。接著，分別計算套裝情境表示與各候選單品嵌入 $\mathbf{e}_{c_q^{(j)}}$ 之間的餘弦相似度，可參見式 3 - 14。其中，候選單品嵌入由單品圖像與文字特徵共同構成；相似度分數越高，表示該候選單品與部分套裝及文字條件越相符。

$$s\left(c_q^{(j)} \mid \mathcal{O}_q^{\text{partial}}, \mathbf{d}_q\right) = \frac{\left(\mathbf{h}_q^{\text{context}}\right)^{\top} \mathbf{e}_{c_q^{(j)}}}{\| \mathbf{h}_q^{\text{context}} \|_2 \| \mathbf{e}_{c_q^{(j)}} \|_2} \qquad \text{式 3 - 14}$$

模型依各候選單品的相似度分數由高至低進行排序，形成第 q筆查詢的推薦列表。令：$\pi_q = \underset{c \in \mathcal{C}_q}{\text{argsort}^{\downarrow}} s\left(c \mid \mathcal{O}_q^{\text{partial}}, \mathbf{d}_q\right)$ ，其中，π_q 表示依相似度分數遞減排列後的候選單品序列。

評估指標方面，本研究採用資訊檢索與推薦排序中常見的 Recall@K，衡量正確目標單品是否出現在推薦列表前 K 名。令 $\mathcal{Q}$ 為符合 OR 評估條件的查詢集合，c_q^* 為第 q 筆查詢的正確目標單品，$\text{TopK}(\pi_q)$ 為推薦列表中的前 K 個候選單品，則 Recall@K 定義如式 3 - 15。

$$\text{Recall@K} = \frac{1}{|\mathcal{Q}|} \sum_{q \in \mathcal{Q}} \mathbb{I}\left[c_q^* \in \text{TopK}(\pi_q)\right] \qquad \text{式 3 - 15}$$

其中，$\mathbb{I}[\cdot]$ 為指示函數；當正確目標單品位於推薦列表前 K名時取值為 1，否則為 0。本研究分別回報 Recall@1、Recall@3、Recall@5、Recall@10、Recall@30 與 Recall@50，以觀察模型在不同推薦列表深度下的排序表現。

在 15,145 筆測試套裝中，共有 9,311 筆查詢－目標單品配對符合 OR 候選池建立與評估條件，作為 Recall@K 的正式評估資料；其餘 5,834 筆因未符合任務特定的候選池條件，不納入 Recall@K 計算。兩種文字條件使用相同的部分套裝、目標類別、候選單品集合與正確目標單品，以確保 Polyvore 原始描述與情境感知改寫描述之間的表現差異不受評估樣本或候選池不同所影響。

3.6.4 消融實驗：條件因子貢獻度分析

為分析天氣、場合與風格三類情境感知語意對模型表現的相對影響，本研究設計因子消融實驗。描述生成階段，天氣 (Weather, W)、場合 (Occasion, O) 與風格 (Style, S) 三項因素整合為單一自然語言查詢式描述，以保留使用者實際搜尋穿搭時常見的完整語意脈絡。消融實驗則以完整情境感知描述 (Context-aware) 為基礎，分別建立移除天氣 (No-W)、移除場合 (No-O) 與移除風格 (No-S) 的文字條件版本，並比較完整情境感知描述與各因子移除版本的模型表現，以分析移除單一因子後對穿搭相容性與套裝推薦效能的影響。三種因子依據表 3 - 3 操作型定義移除後的句子示意如圖 3 - 7 所示。

表 3 - 3、各因子的操作型定義

因子	操作型定義
天氣 (W)	描述外在氣候、溫度、季節或體感冷暖的文字片段。判定依據分為硬指標與軟指標：硬指標包含溫度數值、天氣現象及季節詞；軟指標則包含 *warm*、*cool*、*chilly* 等明確指向天氣或冷暖條件的詞彙。
場合 (O)	描述能獨立表達活動、場域或使用情境的文字片段，例如 *work*、*date*、*travel*、*party*、*walk*、*day out* 等。本研究僅保留具明確情境語意的核心片段，並移除前導介係詞；若描述僅呈現與特定情境相符的風格傾向，而未出現可獨立辨識的場合語句，則不視為 O。
風格 (S)	描述服裝風格、美學傾向、服飾單品、材質或圖樣的文字片段，例如 *casual*、*formal*、*streetwear*、*coat*、*heels* 與 *floral prints* 等風格、單品、材質或圖樣詞彙。

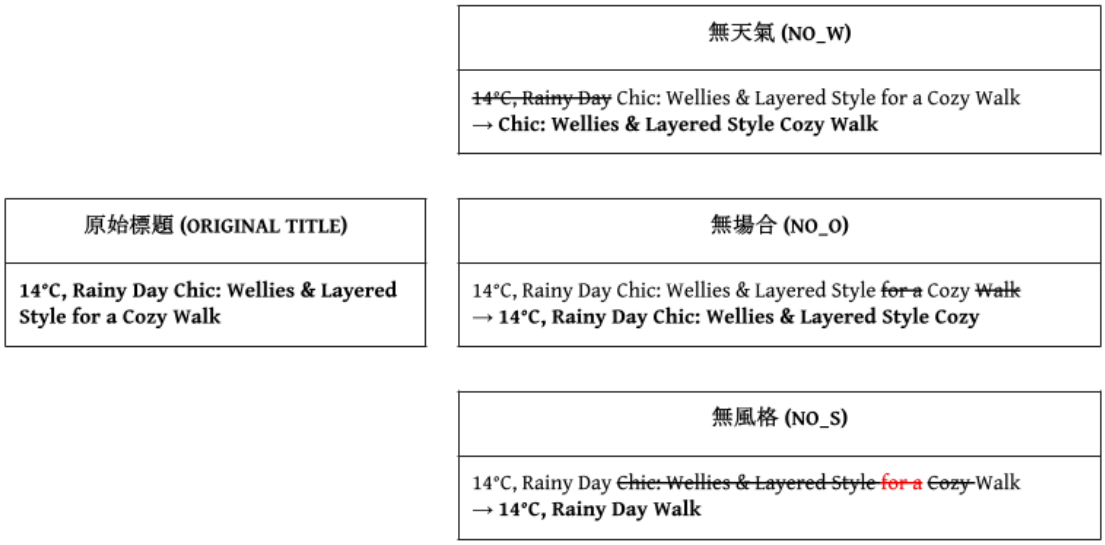


圖 3 - 7、天氣、場合與風格因子移除示意圖

本研究對三個因子建立操作型定義，如上表 3 - 3 所示，檢驗各因子的影響，設改寫後的服裝描述為 x，其中包含天氣 (W)、場合 (O)與風格 (S)三類條件訊息。令完整情境感知描述為 x，且其中可能包含天氣、場合與風格三類語意片段。移除單一因子後所形成的消融描述定義如式 3 - 16：

$$x^{-W} = \text{Clean}\,(x \setminus W), x^{-O} = \text{Clean}\,(x \setminus O), x^{-S} = \text{Clean}\,(x \setminus S) \qquad \text{式 3 - 16}$$

其中，$x \setminus W$、$x \setminus O$、$x \setminus S$ 分別表示自原始描述中移除天氣、場合與風格片段；$Clean(\cdot)$表示文字後處理程序，用以清除片段移除後殘留的多餘空白、標點符號、連接詞與介系詞。各消融版本僅移除對應因子的文字片段，並保留其餘內容，以降低重新生成文字所引入的額外語句與文字品質差異。

由於場合與風格在自然語言中可能具有較高的語意鄰接性，部分描述雖呈現適合特定活動的造型傾向，卻未包含可獨立辨識的場合片段。因此，場合因子採取較保守的辨識原則，僅在活動、場域或使用情境能夠單獨成立時，才將該片段標記為 O，以降低場合與風格語意重疊所造成的誤判。

為避免樣本原先即缺少特定因子，使消融操作未能實際改變文字輸入，本研究僅保留同時具備天氣、場合與風格三項語意的樣本。此外，若不同消融條件使用不同的樣本集合，模型表現差異可能同時受到資料組成與因子移除效果影響，難以明確判讀。因此，本研究建立公平比較子集 D_{fair}，作為 Context-aware、No-W、No-O 與 No-S 的共同訓練及評估資料，其定義如式 3 - 17，其中，D 表示完整情境感知描述資料集合；W(x)、O(x) 與 S(x) 分別表示描述 x 中辨識出的天氣、場合與風格片段。僅當三類片段皆非空集合時，該樣本才納入 D_{fair}，以確保各消融版本皆對原始文字條件產生實際改變，且不同實驗條件建立於相同的資料基礎上。

$$D_{\text{fair}} = \{x \in D \mid W(x) \neq \emptyset, O(x) \neq \emptyset, S(x) \neq \emptyset\}. \qquad \text{式 3 - 17}$$

對任一評估指標 m 與情境因子 f，本研究以因子移除版本相對於完整情境感知版本的效能差異，衡量移除該因子後的模型表現變化，如式 3 - 18，其中，$P_m(\cdot)$ 表示特定文字條件版本於指標 m 上的模型表現。當 $\Delta_{m,f} < 0$ 時，表示移除因子 f 後模型表現下降，且其絕對值愈大，代表效能下降幅度愈明顯；當 $\Delta_{m,f} > 0$ 時，則表示移除該因子後模型表現反而提升。

$$\Delta_{m,f} = P_m(\text{No-}f) - P_m(\text{Context-aware}) \qquad \text{式 3 - 18}$$

消融實驗的核心比較包含 Context-aware、No-W、No-O 與 No-S 四種文字條件版本，另以 Polyvore 原始描述作為外部參照。所有版本皆使用相同的公平比較子集、資料切分、推薦模型架構、特徵表示、訓練設定與隨機種子，以降低非文字條件因素對實驗結果的影響。需要說明的是，此處的效能差異代表單一語意因子移除後的相對變化，三項因子的影響不宜直接相加，亦不作為各因素因果效果的估計。

第四章、研究成果

本章首先說明資料集來源、實驗環境與模型訓練設定，作為後續結果分析的基礎；其次，評估情境感知改寫描述的品質，以確認其作為文字條件輸入的可用性；接著，比較 Polyvore 原始描述與情境感知改寫描述於穿搭相容性預測及套裝推薦任務中的表現差異；最後，透過消融實驗與個案分析，探討天氣、場合與風格等情境語意因子對模型表現的相對影響，並說明本研究方法的效益與限制。

4.1 實驗設置

以下將說明實驗所使用的資料集、正式樣本範圍、軟硬體環境與模型訓練設定。為公平比較 Polyvore 原始描述與情境感知改寫描述，兩組實驗皆使用相同的資料切分、單品特徵、模型架構、訓練流程與隨機種子，僅替換套裝層級文字條件。各項實驗設定均依第三章所述方法固定執行，後續依序呈現生成資料有效性、推薦任務與情境語意因子消融結果。

4.1.1 資料集與實驗樣本

在 Polyvore 資料集中，包含 Polyvore Non-Disjoint (PO) 與 Polyvore Disjoint (PO-D) 兩個版本，本研究採用 PO-D 作為主要實驗資料集。相較於允許相同單品出現在不同資料切分中的 Non-Disjoint 版本，PO-D 確保訓練集、驗證集與測試集之間不共享單品，可降低單品層級的資訊洩漏，並提供較嚴格的泛化能力評估。

完成 CLO 與 MET 推導、熱舒適度推估、情境感知描述改寫及格式檢查後，共取得 35,140 筆可用套裝樣本。其中，訓練集、驗證集與測試集分別包含 16,995、3,000 與 15,145 筆套裝，並沿用 PO-D 原始資料切分。Polyvore 原始描述與情境感知改寫描述皆與上述套裝一一對應，兩種文字條件使用相同的資料切分進行模型訓練與評估。

在下游任務中，CP 評估共使用 30,290 筆相容與不相容套裝測試樣本，FITB 評估則包含 15,145 題測試問題。OR 任務因需依待補全單品類別建立符合條件的候選池，最終共有 9,311 筆查詢－目標單品配對納入 Recall@K 計算，其餘未符合 OR 候選池建立條件，故不納入該任務評估。消融實驗則使用同時具備天氣、場合與風格語意的公平比較子集，共計 21,903 筆樣本。此外，本研究沿用原始推薦模型的類別篩選設定，僅將資料量超過 3,000 筆的單品類別納入模型訓練與後續評估，以避免樣本數過少的類別造成訓練與排序結果不穩定。

4.1.2 實驗環境設置

本研究的實驗流程分為前期與後期兩個階段。前期於 Google Colab 雲端環境使用 NVIDIA A100 GPU 進行資料前處理、情境感知描述流程建構；後期則於本

地端環境進行生成描述品質評估及下游推薦模型訓練，使用 NVIDIA RTX PRO 6000 Blackwell Workstation Edition GPU，搭載 96 GB 顯示記憶體。實驗環境與主要軟硬體配置整理如表 4 - 1 所示。

表 4 - 1、實驗環境與主要軟硬體配置

項目	前期	後期
平台	Google Colab（雲端）	實驗室本地端
GPU	NVIDIA A100	NVIDIA RTX PRO 6000 Blackwell Workstation Edition
VRAM	依 Colab 實際配置	96GB
主要用途	資料前處理、流程開發	LLM 驗證與模型訓練

4.1.3 模型訓練超參數與資料切分

本研究評估 CP 與 OR 兩項下游任務，兩者皆沿用 Polyvore Outfits Disjoint 的訓練、驗證與測試切分，以降低資料洩漏風險並提升評估結果的可信度。CP 任務用於學習相容套裝與不相容套裝之間的差異，其主要訓練設定如表 4-2 所示。OR 任務則以 CP 任務訓練完成後的模型權重作為初始化，進一步針對候選單品排序進行微調。原始描述與情境感知改寫描述皆採用相同的資料切分、模型架構與訓練設定，僅替換套裝層級的文字條件來源，以確保比較基礎一致。

表 4 - 2、CP 任務的訓練設定

項目	設定
任務	穿搭相容性預測 (CP)
目標	判斷一組套裝是否相容
架構	Hybrid Attention + FashionCLIP
Epoch	100
Batch size	50
Learning rate	5×10^{-5}
負樣本策略	第 40 個 epoch 後啟用硬負樣本採樣

4.2 生成資料有效性檢查

在進行下游推薦任務比較前，本節先檢視情境感知改寫描述及其代理變數是否具備支撐後續實驗的基本可用性。分析依序包含 CLO、MET 與主觀舒適溫度參考值的分布合理性、文字長度對推薦表現的可能影響、目標單品線索，以及生成描述品質。上述檢查主要用於辨識可能影響推薦結果解讀的替代因素，並非作為穿搭相容性預測或套裝推薦任務的替代評估指標。

4.2.1 代理變數合理性檢查

為確認情境感知描述建構所使用的中介尺度是否具備基本可解析性與可解釋範圍，本節分析 CLO、MET 及主觀舒適溫度參考值的資料分布，如表 4-3 所示。此項分析並非驗證是否符合使用者實際的熱舒適感受，而是檢視代理變數是否能作為後續天氣語意建構、描述改寫與結果分析的參考依據。

表 4-3、CLO、MET 與主觀舒適溫度參考值之分布

代理變數	中位數	四分位範圍	第 5 至第 95 百分位	集中或極端情形
CLO	0.93	0.63–1.21	0.25–2.07	最大值為 5.20；共 20 筆樣本 CLO 大於 4
MET	1.00	1.00–1.30	1.00–1.50	MET 等於 1.0 者共 25,786 筆，占 73.4%；MET 大於 10 者共 8 筆
T_{sub}	22.9°C	19.9–24.5°C	13.5–27.1°C	低於 0°C 者共 257 筆，占 0.73%；低於 −20°C 者共 51 筆，占 0.15%

CLO 的中位數為 0.93，四分位範圍介於 0.63 至 1.21，且 90% 的樣本分布於 0.25 至 2.07 之間，顯示多數套裝的保暖程度集中於可解釋範圍。資料中仍包含少量較高保暖值，其中 CLO 大於 4 的樣本共 20 筆，最大值為 5.20。由於 CLO 是依套裝單品組合推估所得，而非實際衣物熱阻量測結果，因此這些高值主要作為資料分布與邊界案例保留，未另行進行硬性裁切。

MET 的中位數為 1.00，四分位範圍介於 1.00 至 1.30，其中 MET 等於 1.0 的樣本共 25,78 筆，占全部資料的 73.4%，此結果反映模型依據穿搭影像與文字線索所選取的活動，多屬於日常穿著可能對應的低活動強度情境。由於 MET 是由活動候選清單映射取得，並非使用者實際活動量測結果，因此其用途主要在於約束活動語意與後續熱舒適度推估。

主觀舒適溫度參考值的中位數為 22.9°C，四分位範圍介於 19.9°C 至 24.5°C，且 90% 的樣本分布於 13.5°C 至 27.1°C 之間，顯示多數樣本集中於可供冷暖語意建構使用的範圍。然而，仍有 257 筆樣本低於 0°C，其中 51 筆低於 −20°C。依據簡化熱舒適公式（式 3-3），CLO、MET 與主觀舒適溫度參考值之間具有熱補償關係。在相同主觀冷暖感受下，活動強度較高時，人體代謝產熱較多，因此所需的衣物保暖程度應相對較低；反之，低活動強度情境則需要較高的衣物保暖程度或較溫暖的環境條件。對應至公式映射，提高 CLO 或 MET 均會使溫度參考值下降，符合以衣著保暖性與活動強度共同約束冷暖語意的設計邏輯。由於本研究的 MET 多集中於低強度日常活動，樣本間的活動強度差異較小，因此溫度參考值的分布主要反映 CLO 的差異；少數較高 MET 樣本則會進一步降低推估結果。

因此，上述極端低值可視為較高 CLO、較高 MET 或兩者共同作用下的公式邊界結果，而非實際環境溫度、真實舒適溫度或氣象標籤。本文保留相關紀錄作為診斷結果揭露。整體而言，三項代理變數的主要分布具有可用性，但不代表精確的人體生理量測結果，後續實驗將這些欄位視為情境語意建構的中介尺度。

4.2.2 文字長度影響分析

情境感知改寫描述相較於 Polyvore 原始文字條件包含較完整的天氣、場合與風格語意，因此文字長度亦有所增加。為檢查下游推薦表現的提升是否僅源自文字變長，本研究進一步分析文字長度與模型表現之間的關係，並比較不同長度差距及相近長度子集中的推薦結果。

首先，依第三章所定義的文字長度差 ΔL_i、前 10 名命中變化 ΔH_i 與排名改善量 ΔR_i，針對套裝推薦任務中的 9,311 組查詢－目標單品配對進行相關分析，結果如表 4 - 4 所示。

表 4 - 4、文字長度差與檢索表現變化之相關分析

自變數	檢索表現變數	樣本數	Pearson r	p 值
文字長度差 (ΔL_i)	Hit@10 命中變化 (ΔH_i)	9,311	0.0276	0.0076
	排名改善量 (ΔR_i)		0.0434	< 0.001

從上方實驗結果可觀察到，文字長度差與 Hit@10 命中變化之間的 Pearson 相關係數約為 0.0276，與排名改善量之間的相關係數約為 0.0434。兩項相關雖達統計顯著，但相關程度皆屬可忽略範圍，表示情境感知描述增加的詞彙數與檢索表現改善幅度之間僅有極弱關聯。換言之，描述增加的詞彙越多，並不代表目標單品更容易進入前 10 名，或其檢索排名會獲得更明顯的提升。

為進一步降低兩種文字條件長度差異的影響，本研究依式 3 - 7 建立相近長度子集，分別納入詞彙數完全相同，以及詞彙數差異不超過 1、2、3 與 5 個詞彙的樣本，並比較原始文字條件與情境感知改寫描述的 Hit@10 及平均排名改善量，結果如表 4 - 5 所示。

表 4 - 5、相近文字長度子集之 Hit@10 與排名改善結果

詞彙數絕對差	查詢－目標單品配對數	原始文字條件 Hit@10	情境感知改寫描述 Hit@10	差異	平均排名改善量
0（相同）	63	0.0698	0.0762	+0.0063	22.62
≤ 1	223	0.0646	0.0753	+0.0108	10.00
≤ 2	573	0.0667	0.0729	+0.0063	12.84
≤ 3	1,158	0.0772	0.0879	+0.0107	11.21
≤ 5	3,014	0.0790	0.0896	+0.0106	21.47

當兩種文字條件的詞彙數完全相同時，情境感知改寫描述的 Hit@10 由 0.0698 提升至 0.0762，差異為 0.0063，平均排名改善量為 22.62。當詞彙數差異放寬至不超過 1、2、3 與 5 個詞彙時，Hit@10 分別提升 0.0108、0.0063、0.0107 與 0.0106，平均排名改善量亦皆為正值。結果顯示，即使兩種文字條件的詞彙數相同或接近，情境感知改寫描述仍能維持較高的前 10 名命中率，並使目標單品的平均檢索排名向前提升。

上述相近長度子集係隨允許的詞彙數差異逐步放寬所形成的累積子集，並非彼此獨立的樣本群組。綜合相關分析與相近長度子集結果，文字長度差與檢索表現

改善之間僅呈現可忽略的相關性，且在控制詞彙數差異後，情境感知改寫描述仍一致優於原始文字條件。因此，結果不支持推薦表現提升僅由描述文字變長所造成，文字長度不足以作為本研究效能改善的主要替代解釋。

4.2.3 目標單品線索洩漏檢查

情境感知改寫描述是根據完整套裝影像與原始文字條件建構，若改寫描述中直接出現待補全目標單品的類別名稱或具高度辨識性的商品詞彙，可能使模型較容易辨識目標單品，進而高估套裝推薦 (OR) 任務的表現。為檢查此一可能性，本研究進行目標單品線索詞彙檢查。

此項檢查使用 Polyvore Outfits 資料集提供的商品類別字典，將每項商品對應至一個主類別與一個子類別，共包含 11 種主類別，如 tops、shoes 與 bags，以及 141 種有效子類別，如 sweater、heels 與 clutch，不包含未定義類別。針對每一筆 OR 任務查詢，本研究先取得目標單品的主類別、子類別與商品文字，再檢查改寫描述是否直接包含目標單品的類別詞彙，以及目標單品文字是否與改寫描述或原始文字條件產生詞彙或連續雙詞組重疊。檢查結果如表 4 - 6 所示。

表 4 - 6、生成描述與原始文字條件之目標單品線索洩漏檢查結果

檢查項目	**筆數**	**比例**	**說明**
OR 任務查詢－目標單品配對	9,311	100.00%	正式 OR 任務評估樣本
改寫描述出現目標單品**子類別**詞彙	419	4.50%	直接提及目標單品的子類別
改寫描述出現目標單品**類別**詞彙	454	4.88%	提及目標單品的子類別或主類別
改寫描述與目標單品文字產生**詞彙**重疊	1,030	11.06%	較寬鬆的詞彙層級線索檢查
改寫描述與目標單品文字產生**連續雙詞**重疊	81	0.87%	較嚴格的片語層級線索檢查
原始文字條件與目標單品文字產生**詞彙**重疊	1,155	12.40%	原始文字條件亦可能包含目標單品相關詞彙

在 9,311 組 OR 任務查詢－目標單品配對中，情境感知改寫描述直接出現目標單品子類別詞彙的比例為 4.50%；若同時納入子類別與主類別詞彙，比例為 4.88%。此結果顯示，改寫描述直接提及目標單品類別名稱的情形相對有限。進一步以目標單品的商品文字進行檢查時，改寫描述與目標單品文字的詞彙重疊比例為 11.06%；採用較嚴格的連續雙詞重疊檢查後，比例則降至 0.87%。此結果表示，部分改寫描述雖可能與目標單品文字共享一般詞彙，但具有較高辨識性的連續片語線索並不常見。此外，原始文字條件與目標單品文字的詞彙重疊比例為 12.40%，高於本研究提出情境感知改寫描述的 11.06%。此結果顯示，與目標單品相關的詞彙並非情境感知改寫後才產生，原始文字條件 (url_name + title) 本身亦可能包含商品或類別線索。由於服飾類別名稱也可能自然出現在穿搭查詢中，因此，文字中出現類別詞彙並不必然等同於直接洩漏目標單品答案。

整體而言，情境感知改寫描述直接出現目標單品類別名稱及連續雙詞線索的比例皆偏低，且其詞彙重疊比例未高於原始文字條件，未顯示改寫描述系統性增加目標單品線索。因此，OR 任務的表現提升不太可能主要來自改寫描述直接暴露目標單品答案。本項分析定位為事後有效性檢查，用以辨識明顯的文字表面線索，不代表改寫描述完全不存在較隱含的語意提示。

4.2.4 生成描述品質評估

本節依據第 3.5.3 節所述之 LLM-as-a-Judge 評估流程，呈現 35,140 筆情境感知改寫描述的品質評估結果。由 Qwen3-VL-32B-Instruct 與 Gemma-3-27B-it 兩個多模態評分模型擔任評分者，分別依據各自固定的加權檢核清單 C_A^*與 C_B^*、權重設定及評分提示詞進行。為便於後續圖表呈現，以下分別記為評分者 A (Judge A) 與評分者 B (Judge B)。分析內容包括整體分數分布、檢核概念對應程度、低分樣本重疊情形、提示詞穩健性及人工稽核結果。

Judge A 與 Judge B 的平均品質分數與標準差分別為 0.828 ± 0.142 與 0.960 ± 0.089。由圖 4-1 可見，兩位評分者的評分結果皆偏向高分區間，其中評分者 B 的分數明顯集中於接近 1.0 的區段，評分者 A 的分布則相對分散。此結果表示，多數改寫描述能通過各評分者清單中的多數或較高權重檢核項目；然而，評分者 B 的結果亦呈現較明顯的天花板效應。若僅依平均分數判斷，雖可掌握整體品質趨勢，仍難以區分高分樣本之間的細部差異，因此後續進一步分析兩組檢核清單的概念對應程度及低分樣本辨識情形。

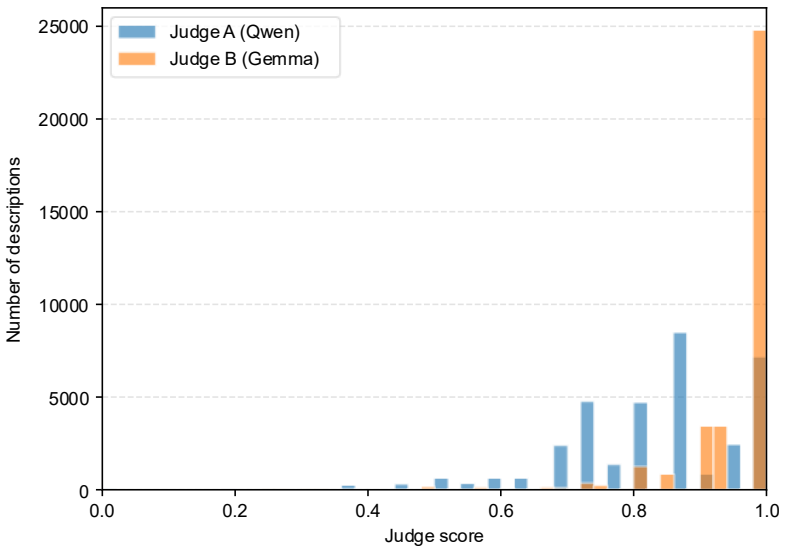


圖 4-1、兩位評分者的分數分布

本研究採用 Nomic Embed Text v2 [5]語意嵌入模型，將兩組評分標準轉換為向量表示，並計算檢核項目之間的語意相似度，透過多對多配對方式估計兩組評分標準彼此涵蓋的程度與加權 F1 分數。實驗結果如圖 4-2 所示，當 τ 不高於 0.80

[5] https://huggingface.co/nomic-ai/nomic-embed-text-v2-moe

時，Cov A→B、Cov B→A 與加權 F1 皆維持於高水準；當門檻進一步提高後，各項指標才逐步下降，顯示兩組清單在圖文一致性、天氣、場合、風格與文字品質等主要概念上具有高度重疊，但對部分細部檢核項目的表達方式與切分方法仍存在差異。此結果說明，兩位評分者雖採用不同數量的檢核項目與權重配置，其加權檢核清單仍涵蓋相近的核心品質概念。不過概念涵蓋程度較高不代表兩位評分者對每一筆樣本具有完全相同的判斷，因此仍須透過低分樣本集合分析，檢查兩者是否能共同辨識較可能存在問題的改寫描述。

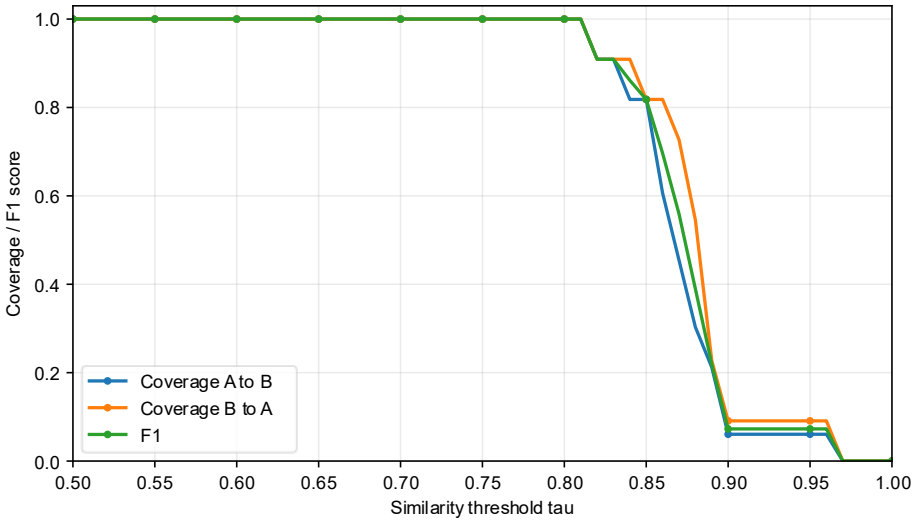


圖 4 - 2、不同相似度門檻下的評估標準一致性分析

在前述評估標準一致性分析基礎上，本文進一步透過表 4 - 7 與圖 4 - 3 檢視兩位評分者對低分樣本的辨識情形。本文以 bottom-p% 的方式，分別取兩位評分者分數最低的 5%、10% 與 20% 樣本作為低分樣本集合，並比較兩集合之交集樣本數、隨機期望交集、Lift、Jaccard 與 F1。

由表 4 - 7 可知，當在 p = 0.05 時，兩位評分者共同標記之低分樣本為 668 筆，高於隨機期望交集 87.9 筆，Lift 為 7.604，表示兩位評分者共同標記之低分樣本數約為隨機情況下預期重疊數的 7.6 倍。當 p 擴大至 0.10 與 0.20 時，交集樣本數分別增加至 1323 筆與 2833 筆，Lift 仍分別為 3.765 與 2.016，皆高於隨機水準。此結果顯示，兩位評分者對低品質描述的辨識並非隨機重合，而具有一定程度的共同判斷基礎；同時，隨著低分集合範圍擴大，Lift 逐漸下降，亦反映低分邊界在較寬鬆設定下較容易受到評分尺度差異影響。進一步觀察集合重疊指標，Jaccard 值介於 0.2319 至 0.2524，F1 值介於 0.3765 至 0.4031，顯示兩位評分者雖能共同辨識部分低品質樣本，但低分集合尚未達高度一致。

由圖 4 - 3 可觀察到，在 p 約介於 5% 至 20% 的範圍內，Jaccard 與 F1 曲線趨勢相對平穩，且 95% bootstrap band 變化幅度有限，表示低分樣本辨識結果在不同 p 值設定下具有一定穩定性。雖然兩位評分者在絕對分數尺度與低分邊界判定上仍存在差異，但其低分樣本重疊程度明顯高於隨機水準，顯示 LLM-as-a-Judge 對於生成描述中較可能存在問題的樣本具有一定辨識能力。因此，本文將 LLM-as-a-Judge 評估結果作為生成描述品質分析與案例檢視之輔助依據，用以檢視改寫描

述是否存在語意偏移、條件不一致或圖文不符等情形。整體而言，評估結果顯示完成改寫後的情境感知描述具備基本語意合理性，故後續 CP 與 OR 任務使用完成改寫後的描述作為文字條件輸入。

表 4 - 7、兩位評分者低分樣本集合重疊分析

低分比例 p	交集樣本數	隨機期望交集	Lift	Jaccard	F1
0.05	668	87.9	7.604	0.2347	0.3802
0.10	1323	351.4	3.765	0.2319	0.3765
0.20	2833	1405.6	2.016	0.2524	0.4031

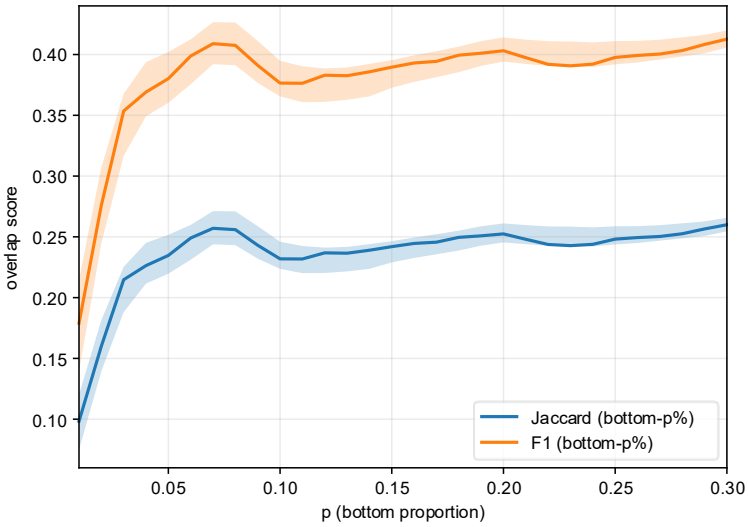


圖 4 - 3、低分樣本敏感度分析

為進一步檢查評分結果是否受到提示詞表述與重複執行影響，本研究另以 **150 筆樣本**進行提示詞穩健性檢查，由表 4 - 8 可知，在 P0-R2 重複執行的條件下，評分者 A 與正式評分結果高度接近，平均絕對差異僅為 0.0048，且 97.3% 的樣本差異不超過 0.05。評分者 B 的平均絕對差異為 0.0461，雖呈現較明顯的個別樣本波動，仍有 89.3% 的樣本差異不超過 0.10，顯示兩位評分者在相同提示詞設定下皆具有一定程度的重現性。相較之下，P1 語序調整版在兩位評分者上皆造成較明顯差異，表示 LLM-as-a-Judge 對提示詞區塊順序仍具有一定敏感性；P2 保守判斷版則因加入「證據不足或不確定則判 NO」之規則，使部分樣本產生合理分數變動。整體而言，此結果說明正式評估流程需固定 prompt 版本、C* 檢核清單、權重計算方式與輸出格式。

表 4 - 8、兩位評分者之提示詞穩健性檢查結果

模型	比較版本	平均絕對差異	中位數絕對差異	最大差異	差異≤ 0.05	差異≤ 0.10
Judge A	P0-R2	0.0048	0.0000	0.2727	97.3%	98.7%
Judge B		0.0461	0.0000	0.3939	62.0%	89.3%
Judge A	P1	0.0709	0.0455	0.6818	64.0%	72.0%
Judge B		0.0713	0.0455	0.4242	50.0%	75.3%
Judge A	P2	0.0506	0.0455	0.4545	80.0%	85.3%
Judge B		0.0521	0.0000	0.6061	71.3%	84.0%

依據第 3.5.3 節所述之人工稽核方法，本研究最終選取高分、低分與評分衝突案例各 10 筆，共 30 筆生成描述進行人工稽核。實際情境覆蓋情形如表 4-9 所示，溫度與活動量各描述性區間皆有樣本涵蓋，場合與風格亦包含多種類型，此目的在於增加情境多樣性，而非建立各類型等比例樣本，因此樣本數不要求完全均衡。

表 4-9、30 筆人工稽核樣本之情境覆蓋情形

面向	區間／類型	樣本數
溫度	< 12°C	6
	12°C 至 < 18°C	5
	18°C 至 < 24°C	14
	≥ 24°C	5
活動量	< 1.3 MET	16
	1.3 至 < 1.6 MET	7
	≥ 1.6 MET	7
場合	休閒／日常	5
	晚間／活動	8
	正式／工作	3
	戶外／旅行	5
	其他／無法明確歸類	9
風格	波希米亞／海灘	4
	休閒／街頭	5
	暗黑／前衛	3
	優雅／浪漫	7
	極簡／經典	3
	運動／活動	3
	其他／無法明確歸類	5

依前一節所述之人工稽核與加權計分方式，進一步比較兩位評分模型與相對應的人工加權分數，結果如表 4-10 所示。

表 4-10、30 筆人工稽核之模型與人工分數比較結果

評分者	人工平均分數	模型平均分數	偏差	MAE	RMSE	Pearson r	Spearman ρ
Judge A	0.7242	0.6667	−0.0576	0.2273	0.3369	0.5988	0.6729
Judge B	0.6818	0.6566	−0.0253	0.2212	0.3085	0.5537	0.4909

由於偏差定義為模型分數減去人工分數，兩位評分者皆呈現負值。評分者 A 所對應的人工加權分數平均值為 0.7242，模型平均分數為 0.6667，兩者偏差為 −0.0576；評分者 B 所對應的人工加權分數平均值為 0.6818，模型平均分數為 0.6566，偏差為 −0.0253。由此可見，在本次 30 筆人工稽核樣本中，兩位評分模型的平均分數皆略低於相對應的人工加權分數，呈現較為保守的評分傾向。在模型分數與人工加權分數的關聯方面，評分者 A 的 Pearson r 與 Spearman ρ 分別為 0.5988 與 0.6729；評分者 B 則分別為 0.5537 與 0.4909，皆呈現正向關係。此結

果表示，在本次人工稽核樣本中，模型評分與人工評分在分數變化及樣本排序上具有一定程度的同向趨勢，但仍存在個別樣本的評分差異。結合 MAE 與 RMSE 結果可知，LLM-as-a-Judge 可作為大規模生成描述品質檢查的自動化輔助工具，但仍不足以完全取代人工稽核。

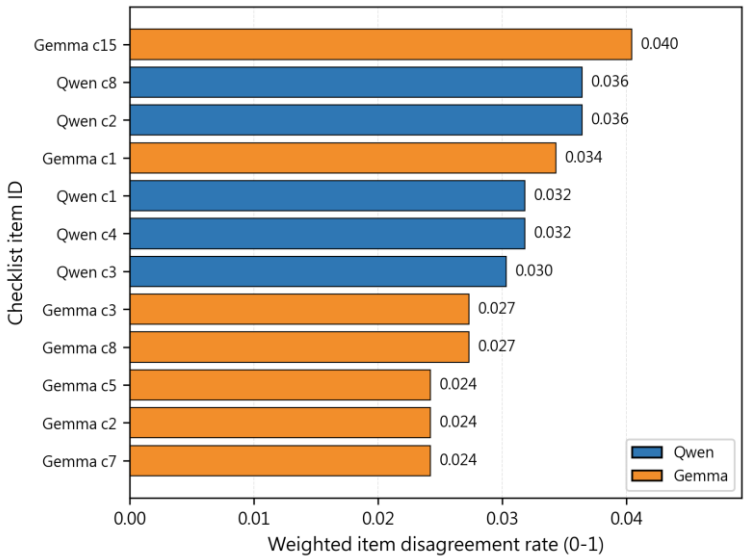


圖 4 - 4、人工判斷與 LLM-as-a-Judge 之加權題項分歧

各檢核題項的人工與模型加權分歧程度如圖 4 - 4 所示。圖中 Qwen c1–c10 與 Gemma c1–c15 分別對應評分者 A 與評分者 B 的加權檢核題項，其完整題目與權重設定可參見附錄表 G - 5 與表 G - 7。結果顯示 Gemma c15 的分歧程度最高，其次為 Qwen c8 與 Qwen c2，相關題項主要涉及套裝整體圖文一致性、圖片無法支持的細節，以及風格、場合與顏色等視覺與情境判讀。由此可見，涉及整體影像理解與情境推論的檢核項目，是本研究中人工與 LLM-as-a-Judge 較容易產生判斷差異的部分。

由於本次人工稽核的目的在於補充檢查不同品質與評分分歧案例，而非推估全部 35,140 筆資料的整體分布，因此不另以 30 筆樣本進行統計顯著性檢定。綜合完整資料的分數分布、雙評分者低分樣本重疊、提示詞穩健性與本次人工稽核結果，雖然部分視覺屬性與情境語意仍可能出現判斷差異，但未發現需要大規模重新生成或替換描述的系統性問題。因此，後續推薦實驗仍保留正式批次生成的 35,140 筆情境感知改寫描述作為文字條件輸入，不依品質分數額外篩除或替換樣本；評分者所產生的問題回饋與建議改寫，則僅用於低分樣本分析與失敗案例說明，不直接取代正式生成描述。

4.3 推薦任務實驗結果

本節依據第 3.6 節所述之推薦任務設定與統計比較方式，呈現原始描述與情境感知改寫描述於 CP 與 OR 任務中的實驗結果。各表中，Original 代表使用 Polyvore 原始文字條件的結果，Context-aware 代表使用情境感知改寫描述的結

果，兩欄均以五次重複實驗的平均值 ± 標準差呈現；Δ 定義為 Context-aware 減去 Original，方括號內則為平均配對差異的 95% 信賴區間。顯著性欄以星號呈現 8 項推薦指標共同經 Benjamini–Hochberg 方法校正後的 p 值，標記方式為：$*\ p < .05$、$**\ p < .01$、$***\ p < .001$。效果量以 Cohen's d_z 表示，用以衡量五次重複實驗中配對差異相對於其變異程度的大小。

4.3.1 任務一：CP 實驗結果

如表 4 - 11 顯示，採用情境感知改寫描述作為文字條件時，模型於 AUC 與 FITB Accuracy 兩項指標上皆優於原始文字條件。AUC 由 0.9292±0.0013 提升至 0.9454±0.0013，平均差異為 0.0162，95% 信賴區間為 [0.01569, 0.01672]；FITB Accuracy 則由 0.6374±0.0037 提升至 0.6478±0.0021，平均差異為 0.0103，95% 信賴區間為 [0.00536, 0.01532]。兩項指標的信賴區間皆未包含 0，經 Benjamini–Hochberg 校正後仍達統計顯著，而 Cohen's d_z 分別為 38.934 與 2.578，顯示兩項指標的配對差異在五次重複實驗中具有高度一致性。其中，AUC 的效果量特別大，主要是因為五組配對差異均穩定落在相近範圍，使配對差異的標準差極小。

圖 4 - 5 呈現兩種文字條件下 AUC 與 FITB Accuracy 的平均值與標準差。情境感知改寫描述於兩項指標上皆呈現正向提升，圖中百分比表示其相較於原始文字條件的相對提升幅度，分別約為 1.7% 與 1.6%。

表 4 - 11、CP 任務 - 成對 t 檢定

指標	Original	Context-aware	Δ（95% CI）	顯著性	Cohen's d_z
AUC	0.9292 ± 0.0013	**0.9454 ± 0.0013**	+0.0162 [+0.01569, +0.01672]	***	38.934
FITB ACC	0.6374 ± 0.0037	**0.6478 ± 0.0021**	+0.0103 [+0.00536, +0.01532]	**	2.578

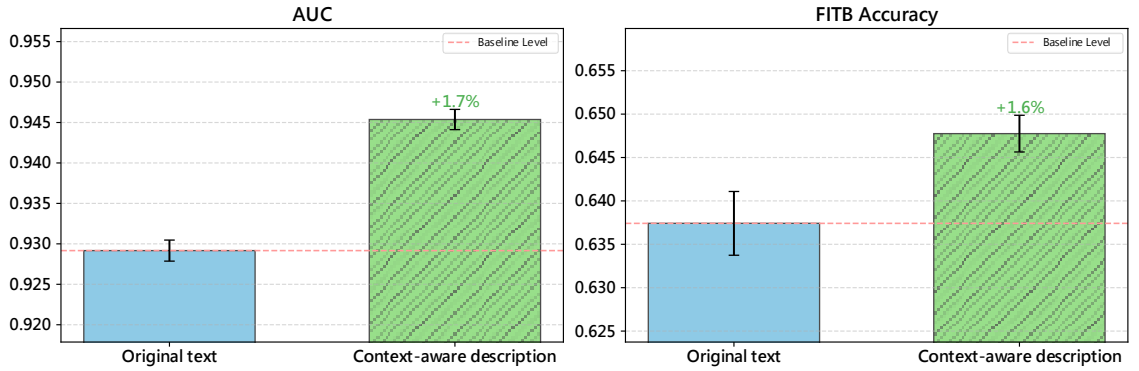


圖 4 - 5、CP 任務實驗結果比較

AUC 的提升表示模型更有效地區分相容與不相容套裝。FITB Accuracy 的提升則顯示，情境感知改寫描述亦有助於模型在部分套裝與候選單品之間辨識正確的補全項目。因此，改寫的描述能同時改善套裝相容性判斷與缺失單品選擇能力。

4.3.2 任務二：OR 實驗結果

如表 4 - 12 所示，採用情境感知改寫描述作為文字條件時，模型於各項 Recall@K 指標上皆優於原始文字條件。各項平均差異的 95% 信賴區間皆未包含 0，且經 Benjamini–Hochberg 校正後仍達統計顯著。其中，Recall@10 與 Recall@50 的顯著性層級由未校正時的 $p < .001$ 調整為 $p < .01$，但仍維持統計顯著。各指標的 Cohen's d_z介於 1.253 至 5.526，顯示五次重複實驗中的配對改善具有一致性；其中 Recall@1 與 Recall@3 的信賴區間下限較接近 0，表示提升幅度相對較小，而 Recall@10、Recall@30 與 Recall@50 的信賴區間距離 0 較遠，效果量亦較大，顯示較大推薦範圍下的改善結果較為穩定。

圖 4 - 6 呈現兩種文字條件下各項 Recall@K 的平均值與標準差。各指標上皆呈現一致提升，圖中百分比表示相較於原始文字條件的相對提升幅度，各 K值介於 8.6% 至 18.1% 之間，其中 Recall@5 與 Recall@10 的相對提升幅度最大。

表 4 - 12、OR 任務 - 成對 t 檢定

指標	Original	Context-aware	Δ（95% CI）	顯著性	Cohen's d_z
Recall@1	0.0139 ± 0.0004	**0.0151 ± 0.0011**	+0.0012 [+0.00005, +0.00236]	*	1.292
Recall@3	0.0333 ± 0.0010	**0.0369 ± 0.0020**	+0.0036 [+0.00003, +0.00714]	*	1.253
Recall@5	0.0476 ± 0.0010	**0.0557 ± 0.0023**	+0.0082 [+0.00443, +0.01189]	**	2.719
Recall@10	0.0780 ± 0.0010	**0.0921 ± 0.0035**	+0.0141 [+0.01006, +0.01816]	**	4.326
Recall@30	0.1677 ± 0.0045	**0.1874 ± 0.0038**	+0.0197 [+0.01527, +0.02412]	***	5.526
Recall@50	0.2303 ± 0.0035	**0.2518 ± 0.0038**	+0.0215 [+0.01606, +0.02686]	**	4.934

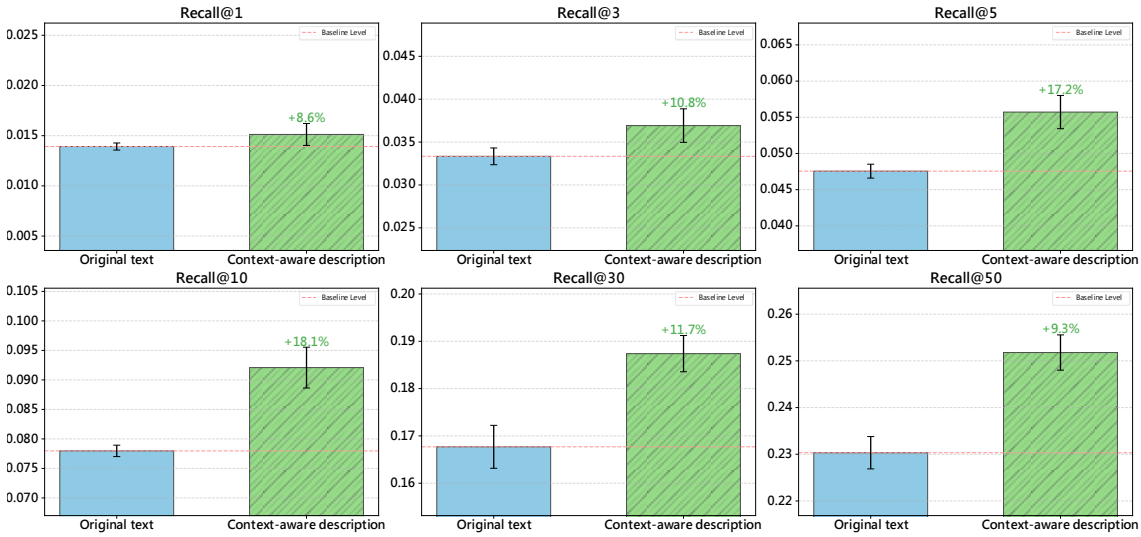


圖 4 - 6、OR 任務實驗結果比較

4.4 消融實驗：條件因子貢獻度分析

為進一步釐清效能提升的來源，本節透過消融實驗分析不同條件因子對模型表現的相對貢獻。具體而言，將完整改寫描述中的天氣（Weather）、場合（Occasion）與風格（Style）資訊分別移除，形成 No-W、No-O 與 No-S 三種條件設定，藉此觀察在缺少特定語意因子時，模型於 CP 與 OR 任務上的效能變化。

4.4.1 公平比較子集再驗證

為避免不同消融設定因樣本集合不一致，使模型表現同時受到資料組成與條件移除的影響，本研究依第 3.6.4 節定義之公平比較子集 D_{fair}，僅保留同時具備天氣（W）、場合（O）與風格（S）三項條件的樣本，作為消融分析的資料基礎。在 35,140 筆有效樣本中，天氣因子覆蓋率為 100.0%，風格因子為 99.87%，場合因子則為 62.45%。場合因子覆蓋率較低，可能與場合語意常透過整體氛圍或風格描述呈現有關，例如部分描述雖隱含約會、度假或聚會等情境，卻未包含可獨立辨識的場合語句。由於場合因子採較保守的抽取原則，僅在情境語意可單獨成立時納入，因此覆蓋率相對較低。最終保留同時具備 W、O、S 三項條件的樣本共 21,903 筆，占有效樣本的 62.33%，後續消融實驗皆以此共同樣本集合進行比較。

在公平比較子集上重新比較原始文字條件與情境感知改寫描述於 CP 與 OR 任務中的表現，結果分別如表 4 - 13 與表 4 - 14 所示。於 CP 任務中， AUC 由 0.9112 ± 0.0015 提升至 0.9265 ± 0.0015，平均差異為 0.0153，95% 信賴區間為 [0.01308, 0.01750]。FITB Accuracy 則由 0.6109 ± 0.0035 提升至 0.6228 ± 0.0034，平均差異為 0.0119，95% 信賴區間為 [0.00474, 0.01915]。兩項指標經 Benjamini–Hochberg 校正後仍達統計顯著，其 Cohen's d_z 分別為 8.601 與 2.059，顯示五次重複實驗中的配對改善具有一致性。

於 OR 任務中選取 Recall@10、Recall@30 與 Recall@50 作為代表性指標。三項指標的平均差異分別為 0.0096、0.0203 與 0.0241，95% 信賴區間均未包含 0，且經校正後仍達統計顯著。其中，Recall@50 的顯著性標記由校正前的 *** 調整為 **，但仍維持統計顯著。各指標的 Cohen's d_z 由 1.479 增加至 4.774；Recall@10 的信賴區間下限較接近 0，而 Recall@30 與 Recall@50 的信賴區間距離 0 較遠，顯示後兩項指標的配對改善較為一致。整體而言，情境感知改寫描述在一致的樣本集合下仍維持正向效益，支持後續以公平比較子集進行條件因子消融分析。

表 4 - 13、縮減子集 CP 任務 - 成對 t 檢定

指標	Original	Context-aware	Δ（95% CI）	顯著性	Cohen's d_z
AUC	0.9112 ± 0.0015	**0.9265 ± 0.0015**	+0.0153 [+0.01308, +0.01750]	***	8.601
FITB Acc	0.6109 ± 0.0035	**0.6228 ± 0.0034**	+0.0119 [+0.00474, +0.01915]	*	2.059

表 4 - 14、縮減子集 OR 任務 - 成對 t 檢定

指標	Original	Context-aware	Δ（95% CI）	顯著性	Cohen's d_z
Recall@10	0.0686 ± 0.0043	**0.0781 ± 0.0023**	+0.0096 [+0.00153, +0.01758]	*	1.479
Recall@30	0.1517 ± 0.0077	**0.1720 ± 0.0034**	+0.0203 [+0.01069, +0.02999]	**	2.617
Recall@50	0.2111 ± 0.0046	**0.2351 ± 0.0045**	+0.0241 [+0.01781, +0.03033]	**	4.774

4.4.2 各因子貢獻度

確認公平比較子集上的主實驗結果仍具一致優勢後，本研究進一步透過 No-W、No-O 與 No-S 三種設定，分析天氣、場合與風格三項條件因子對模型表現的相對影響，亦即分別自情境感知改寫描述中移除天氣、場合或風格資訊，並比較各設定相對於完整的 Context-aware 設定的效能差異。Context-aware、No-W、No-O 與 No-S 欄位以五次重複實驗的平均值 ± 標準差呈現；Δ_X = No-X − Context-aware，負值表示移除該因子後效能下降。

於 CP 任務中（表 4 - 15），風格因子對模型表現的影響最為明顯。以 AUC 為例，移除天氣資訊後下降 0.0023，移除場合資訊後下降 0.0029，而移除風格資訊後則下降 0.0154，下降幅度明顯高於其餘兩者。FITB Accuracy 亦呈現相同趨勢，No-W、No-O 與 No-S 分別下降 0.0037、0.0031 與 0.0164。此結果顯示，在本資料與模型設定下，風格資訊對穿搭相容性判斷的影響最大；天氣與場合資訊移除後亦造成效能下降，但幅度相對較小。

表 4 - 15、CP 任務 – 消融實驗

指標	Context-aware	No-W	Δ_W	No-O	Δ_O	No-S	Δ_S
AUC	**0.9265 ± 0.0015**	0.9241 ± 0.0034	-0.0023	0.9236 ± 0.0015	-0.0029	0.9110 ± 0.0041	**-0.0154**
FITB Acc	**0.6228 ± 0.0034**	0.6191 ± 0.0060	-0.0037	0.6197 ± 0.0024	-0.0031	0.6064 ± 0.0051	**-0.0164**

於 OR 任務中（表 4 - 16）各因子的影響程度同樣存在明顯差異，且仍以風格因子最高。於 Recall@10、Recall@30 與 Recall@50 三項指標中，移除風格資訊後分別下降 0.0110、0.0196 與 0.0241，皆明顯高於移除天氣或場合資訊所造成的下降幅度。移除天氣資訊後，各指標分別下降 0.0022、0.0030 與 0.0026；移除場合資訊後則分別下降 0.0008、0.0014 與 0.0004。隨著推薦範圍擴大，移除風格資訊所造成的下降幅度亦逐步增加，顯示風格語意在較大候選範圍中仍能協助模型維持目標單品的排序。整體而言，風格語意對候選單品排序的影響較大，而天氣與場合資訊則主要提供額外的情境限制。

表 4 - 16、OR 任務 – 消融實驗

指標	Context-aware	No-W	Δ_W	No-O	Δ_O	No-S	Δ_S
Recall@10	**0.0781 ± 0.0023**	0.0760 ± 0.0013	-0.0022	0.0774 ± 0.0009	-0.0008	0.0671 ± 0.0035	-0.0110
Recall@30	**0.1720 ± 0.0034**	0.1690 ± 0.0047	-0.0030	0.1706 ± 0.0030	-0.0014	0.1524 ± 0.0042	-0.0196
Recall@50	**0.2351 ± 0.0045**	0.2325 ± 0.0068	-0.0026	0.2347 ± 0.0014	-0.0004	0.2110 ± 0.0014	-0.0241

為使各因子的影響程度更易於比較，圖 4 - 7 將三項因子移除後的絕對效能下降量正規化為 100%，呈現各因子的相對效能下降占比。風格因子的占比介於 71% 至 89%，明顯高於天氣的 10% 至 16% 與場合的 1% 至 14%。其中，風格因子在 OR 任務中的占比隨 K 值增加而提高。此比例僅用於比較同一指標內各因子的相對影響，不代表三項因子具有可相加的獨立因果貢獻。

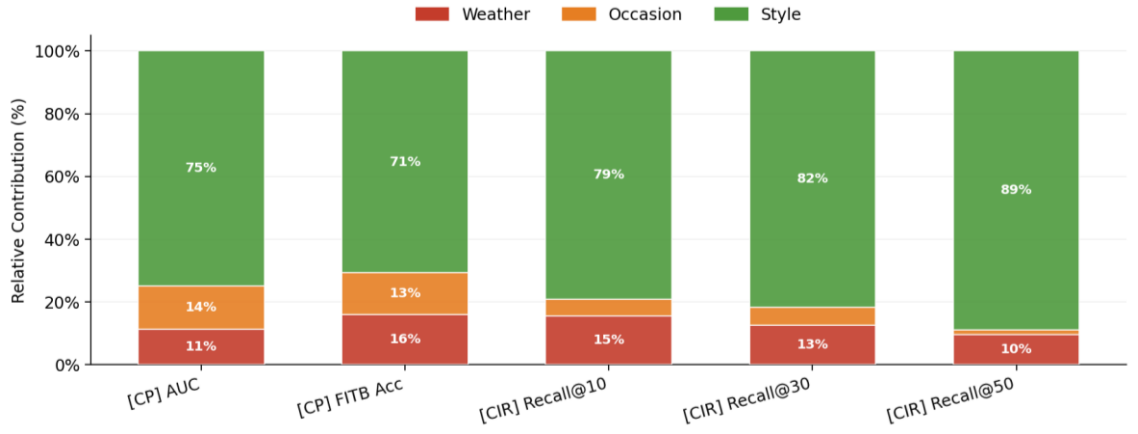


圖 4 - 7、各因子相對貢獻度

綜合消融實驗與第 4.2.2 節的文字長度分析，結果不支持效能提升僅來自描述變長，而較可能來自不同情境語意所提供的條件資訊。移除三項因子後效能皆下降，其中以風格資訊的影響最大，此結果可能與原始資料集的描述特性及條件建構方式有關。Polyvore 原始文字多著重整體造型與風格表達，使風格語意與推薦任務中的既有表徵較為一致；場合與風格在自然語言中亦常相互交疊，部分場合訊息可能已由風格語句間接承載。相較下，天氣資訊主要依 CLO、MET 與主觀舒適溫度補入，天氣狀態的描述可能較不完整，亦可能混入代理值誤差或生成雜訊。因此，在本資料與建構流程下，風格資訊主要提供搭配語意基礎，天氣與場合則主要補充外在情境限制。

4.5 單品類別與情境子集表現分析

除整體指標與消融結果外，本節進一步檢視情境感知改寫描述在不同目標單品類別與情境子集中的表現差異。分析以 PO-D 測試集為基礎，使用符合公平比較子集條件的 3,432 筆 OR 查詢－目標單品配對。由於各文字條件均使用 5 個固定隨機種子重複評估，因此共形成 17,160 筆種子層級觀測值 (seed-level

observation)。分析內容包括單品類別、情境子集，以及移除天氣、場合與風格資訊後的類別效能變化。

本研究使用第 4.2.3 節提到的原始 Polyvore 資料集之類別設定，圖中括號外為子類別，括號內為主類別，例如 dress（all-body）表示子類別為 dress，主類別為 all-body。圖 4-8 呈現各目標單品類別在 Hit@10 上的絕對變化，Hit@10 表示目標單品是否進入候選排序前 10 名，ΔHit@10 則表示 Context-aware 相較於 Original 的差異。提升幅度最高者為 dress （all-body），其 ΔHit@10 為 +0.023；其次為 purse （bags） 與 heels （shoes），兩者皆為 +0.013；pump （shoes） 亦有 +0.010 的改善。相較下，earrings （jewellery）、clutch （bags） 與 necklace （jewellery） 僅呈現小幅提升，而 sunglasses （accessories） 則下降 0.004。

此結果顯示，情境感知改寫描述對與整體造型、正式程度、場合或季節語意較相關的單品類別較具幫助。以 dress、heels 與 purse 為例，其選擇通常同時受到場合需求、風格方向與整體搭配的影響，因此補充更具體的情境語意後，模型較容易建立與目標單品相符的文字條件。相較之下，部分配件類別較依賴顏色、輪廓、材質或局部造型等視覺線索，情境語意所提供的限制較弱，因此改善幅度較小，部分類別甚至出現負向變化。

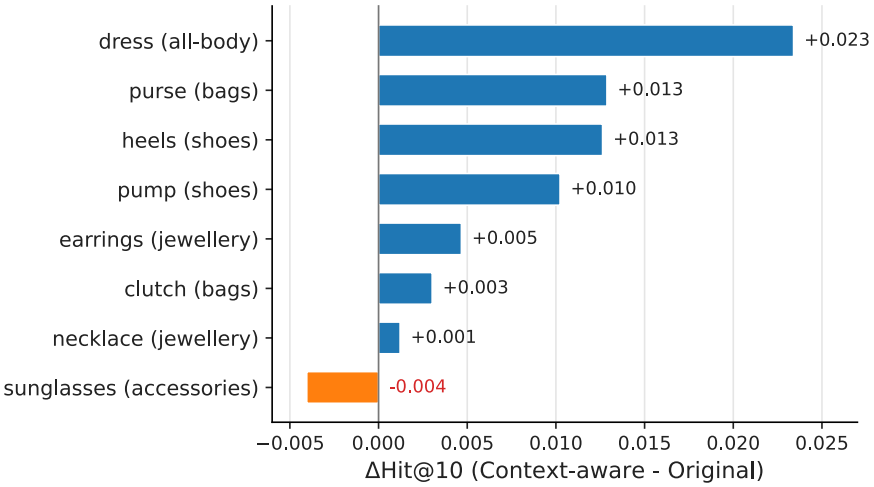


圖 4-8、不同目標單品類別於改寫描述下的 ΔHit@10

為進一步檢查本文方法是否僅對特定樣本或特定情境有效，本研究針對測試集進行情境子集穩定性分析。子集切分方式包含四個面向。第一，依主觀舒適溫度參考值，以測試集中位數 22.9°C 為分界，將樣本區分為寒冷 (Cold) 與溫暖 (Warm)。第二，依場合語意，將 office、interview、meeting、wedding 等詞彙者歸為正式 (Formal)，將 casual、weekend、travel 等詞彙者歸為休閒 (Casual)。第三，依風格片段（style fragment）數量區分風格描述密度，數量大於或等於 2 者歸為高風格密度 (High style)，小於或等於 1 者歸為低風格密度 (Low style)。第四，依主類別定義之單品類型區分衣物導向 (Clothing-led) 與配件導向 (Accessory-led)。

如圖 4-9 與圖 4-10 所示，Context-aware 在所有情境子集中的 Hit@10 皆高於 Original，且 Median Rank 改善量均為正值。Median Rank 改善量定義為

Original 的排名中位數減去 Context-aware 的排名中位數，正值表示改寫後目標單品的排序位置向前。綜合兩項結果，情境感知改寫描述不僅提高目標單品進入前 10 名的比例，也能改善其整體排序位置，且此效益在不同天氣、場合、風格密度與單品類型下皆維持一致方向。

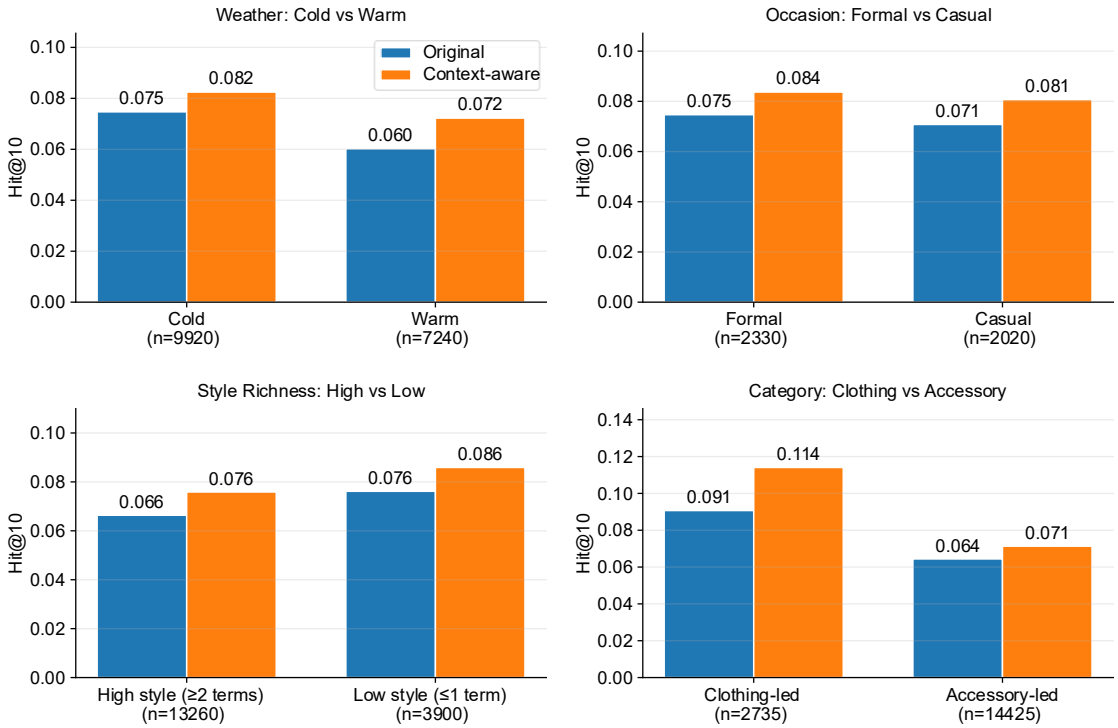


圖 4 - 9、不同情境子集下 Original 與 Context-aware 的 Hit@10 比較

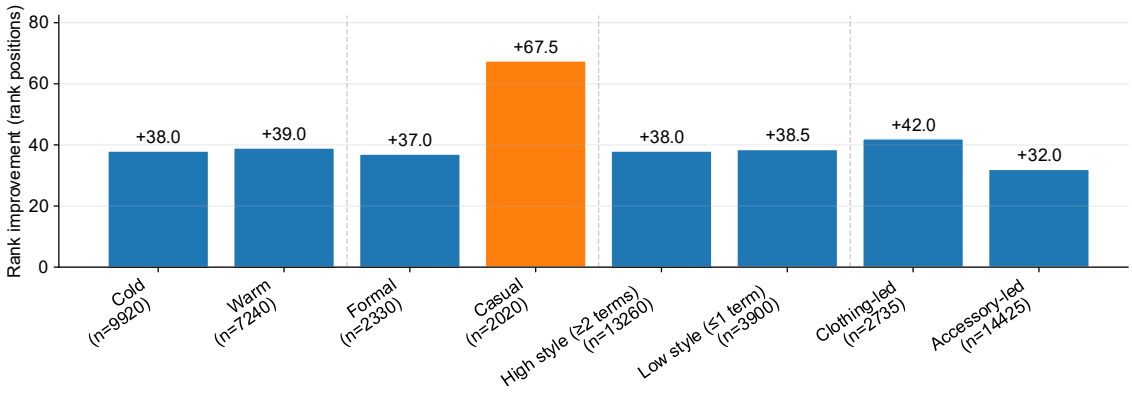


圖 4 - 10、不同情境子集下的 Median Rank 改善幅度

整體而言，情境感知改寫描述能補強套裝層級語意，使模型更容易辨識符合場合、風格與季節需求的單品，並同時改善前十名命中率與整體排序位置；但對較依賴局部視覺細節的配件類別，其效益相對有限。

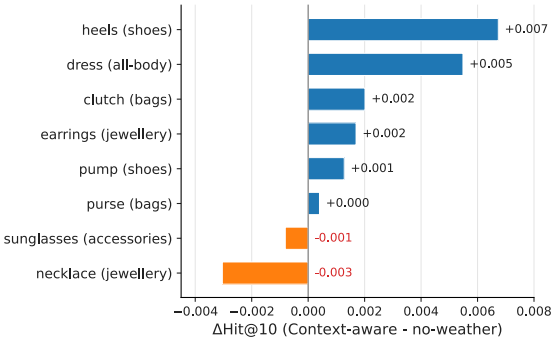
4.5.1 天氣因子對類別效能的影響

天氣因子對檢索表現的影響如圖 4 - 11 (a) 至圖 4 - 11 (c) 所示。其中，圖 4 - 11 (a) 呈現天氣資訊對不同服飾類別的 ΔHit@10 影響，圖 4 - 11 (b) 整理改寫為情境感知描述後提升幅度較高的天氣相關條件詞，圖 4 - 11 (c) 則比較保留與移除天氣資訊後的差異，以檢視各天氣詞彙對檢索表現的實際貢獻。

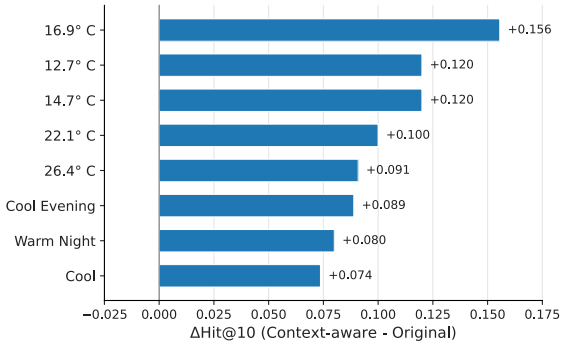
由圖 4 - 11 (a) 可見，heels 與 dress 等與穿著溫度、裸露程度及季節需求較相關的類別受益較明顯，而 sunglasses 與 necklace 等較依賴局部造型或裝飾細節的配件類別則改善有限，部分甚至出現小幅下降。圖 4 - 11 (b) 顯示，對推薦系統帶來較高提升幅度的天氣條件詞多集中於具體氣溫資訊，以及體感與時段相關語句，例如 16.9°C 與 Cool Evening，能較明確的補充原始描述所欠缺的外在環境脈絡。不過，具體氣溫原本即為改寫流程中的固定輸入，因此其結果亦可能受到出現頻率與樣本組成影響。圖 4 - 11 (c) 顯示，移除部分天氣相關詞後會造成較明顯的效能下降，表示相關語意能為檢索提供額外限制。例如 shimmering evening 所對應的樣本在移除天氣資訊後下降較多，但該詞亦包含時段與風格氛圍，因此較適合解讀為複合情境語意的效能差異。相較於圖 4 - 11 (b) 著重於改寫後帶來的提升，圖 4 - 11 (c) 更能反映天氣詞彙本身的實際貢獻。

整體而言，天氣資訊主要補充外在環境限制，其效益會隨單品類別、表達方式及語意重疊程度而異。

(a) 對天氣資訊較敏感的單品類別



(b) 改寫後提升較多的天氣條件詞



(c) 移除天氣資訊後的詞彙效能差異

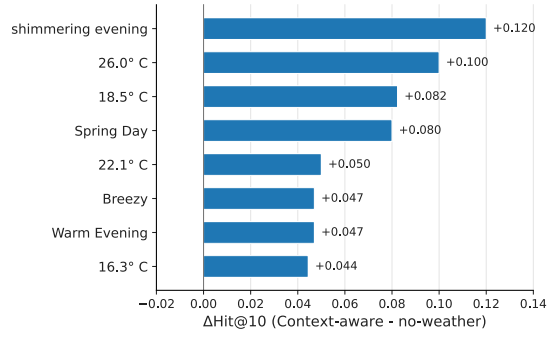


圖 4 - 11、天氣因子對不同類別與語意條件的影響

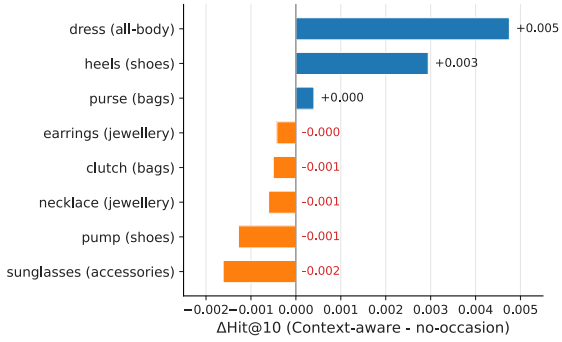
4.5.2 場合因子對類別效能的影響

場合因子對檢索表現的影響如圖 4 - 12 (a) 至圖 4 - 12 (c) 所示。其中，圖 4 - 12 (a) 呈現場合資訊對不同服飾類別的 ΔHit@10 影響，圖 4 - 12 (b) 整理改寫為情境感知描述後提升幅度較高的場合相關條件詞，圖 4 - 12 (c) 則比較保留與移除場合資訊後的差異，以檢視各場合詞彙對檢索表現的實際貢獻。

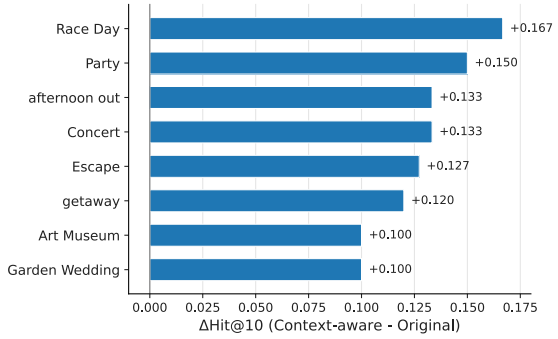
由圖 4 - 12 (a) 可見，dress 與 heels 等與穿著情境、正式程度及活動需求較相關的類別受益較明顯，而 clutch、necklace、pump 與 sunglasses 等較依賴局部造型或外觀細節的類別則改善有限，部分甚至出現小幅下降。圖 4 - 12 (b) 顯示，對推薦系統帶來較高提升幅度的場合條件詞，多集中於具明確活動或場域指向的語句，例如 Race Day、Party 與 Concert，明確地補充原始描述所欠缺的使用情境脈絡，不過，相關結果可能同時受到詞彙出現頻率、樣本組成及多種語意共現影響。圖 4 - 12 (c) 顯示，移除部分場合相關詞後會造成較明顯的效能下降，表示相關語意能為檢索提供額外限制。例如 evenings 與 Race Day 所對應的樣本在移除場合資訊後下降較多，但 evenings 同時帶有時段語意，因此較適合解讀為複合情境語意的效能差異。相較於圖 4 - 12 (b) 著重於改寫後帶來的提升，圖 4 - 12 (c) 更能反映場合詞彙本身的實際貢獻。

整體而言，場合資訊的效益在不同類別與詞彙形式之間存在差異，較明顯地反映於 dress 與 heels 等與穿著情境、正式程度及活動需求關聯較高的單品，場合因子雖非所有類別皆同樣敏感，但對與使用情境高度相關的單品，仍是影響檢索表現的重要條件來源。

(a) 對場合資訊較敏感的單品類別



(b) 改寫後提升較多的場合條件詞



(c) 移除場合資訊後的詞彙效能差異

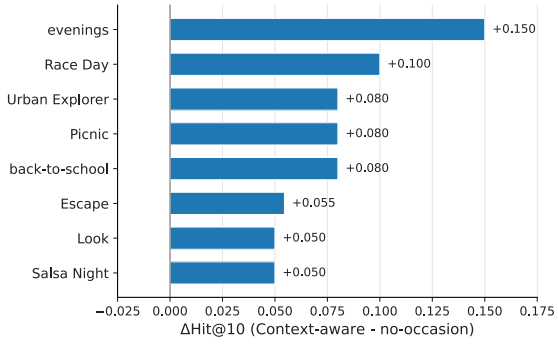


圖 4 - 12、場合因子對不同類別與語意條件的影響

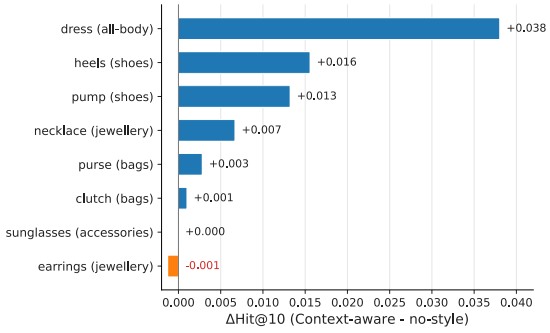
4.5.3 風格因子對類別效能的影響

風格因子對檢索表現的影響如圖 4 - 13 (a) 至圖 4 - 13 (c) 所示，其中圖 4 - 13 (a) 呈現風格資訊對不同服飾類別的 ΔHit@10 影響，圖 4 - 13 (b) 整理改寫為情境感知描述後提升幅度較高的風格相關條件詞，圖 4 - 13 (c) 則比較保留與移除風格資訊後的差異，以檢視各風格詞彙對檢索表現的實際貢獻。

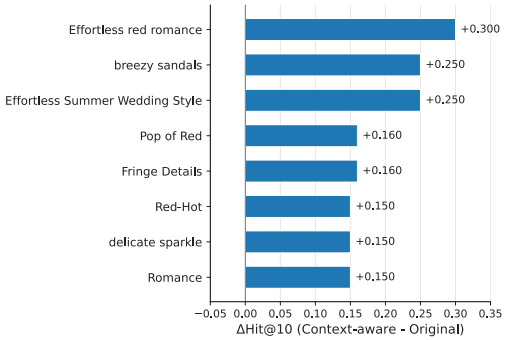
由圖 4 - 13 (a) 可見，風格資訊對 dress 的影響最為明顯，其次為 heels 與 pump，顯示完整造型與鞋款類別較能受益於風格語意。necklace 亦呈現正向改善，表示風格資訊的效益並不限於主要服裝，也能協助部分配件類別建立與整體造型相符的檢索條件；但 earrings 出現輕微下降，顯示不同配件對風格條件的敏感程度並不一致。圖 4 - 13 (b) 顯示，改寫後提升幅度較高的風格條件詞多涵蓋整體造型氛圍、顏色與單品形式，例如 Effortless red romance 與 breezy sandals，表示具體風格描述能補充原始文字條件中的造型語意。不過，相關結果可能同時受到詞彙出現頻率、樣本組成及多種語意共現影響。圖 4 - 13 (c) 則顯示，Effortless Summer Wedding Style、breezy sandals 與 Fringe Details 等代表性詞彙在移除風格資訊後出現較明顯的效能下降，整體造型、單品形式與裝飾細節等風格語意能提供有效的檢索條件。

整體而言，風格資訊除對主要服裝與鞋款有較明顯影響外，部分配件類別亦能受益。提升較多的詞彙通常同時包含搭配氛圍、顏色、單品形式或裝飾細節，顯示模型利用的是較完整的複合造型語意。此結果與前述消融實驗一致，說明風格資訊是目前資料與模型設定下影響檢索表現最明顯的條件因子。

(a) 對風格資訊較敏感的單品類別



(b) 改寫後提升較多的風格條件詞



(c) 移除風格資訊後的詞彙效能差異

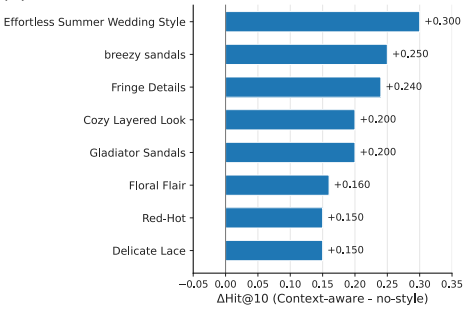


圖 4 - 13、風格因子對不同類別與語意條件的影響

4.6 個案分析

前述結果已從整體指標、消融設定、單品類別與情境子集等層面，說明情境感知改寫描述對推薦效能的影響。本節進一步透過具體檢索案例，觀察改寫描述如何改變目標單品的排序結果，並分析其對顏色偏移的改善情形及仍可能出現的失敗類型。案例分析分為描述改善與排序變化、顏色偏移改善，以及失敗案例三部分，以補充量化結果較難呈現的模型行為與方法邊界。

4.6.1 描述改善與排序變化案例

為更具體說明改寫描述如何影響檢索結果，以下選取兩個具代表性的成功案例進行分析，分別以 purse (bags) 與 dress (all-body) 類別的樣本為例，並同時比較原始描述、完整改寫描述，以及移除單一天氣、場合與風格因子後的結果，以觀察排序改善主要來自何種語意補充。需先說明的是，案例圖示所呈現的 seed rank，係自五個隨機種子實驗結果中，選取與 mean rank 最為接近者作為代表性範例，而非直接擇取最佳或最差的單次結果；至於 mean rank，則用以反映五次重複實驗下的整體排序表現。如此可避免個別種子的偶然波動影響案例判讀，並使圖示結果更接近整體實驗趨勢。

案例一的目標單品為 purse (bags)，實驗結果可參考附錄 H。原始描述僅為 “shein xv”，幾乎不包含可供模型判別的有效語意，因此在原始條件下，目標單品的 seed rank 與 mean rank 分別為 25 與 23.4，顯示模型難以憑藉此類過於簡略的文字條件有效聚焦於正確候選。完整改寫後，描述轉為 “19.2°C, breezy beach vibes in a dreamy blue swimsuit and linen dress”，其內容可概括為「19.2°C 的微風海灘氛圍，搭配夢幻藍色與亞麻質地的度假風格」。相較於原始描述，改寫後明確補入了天氣條件、海灘情境，以及藍色調與輕盈材質等風格線索，使查詢條件由原先幾乎無語意的字串，轉為具有環境與造型指向的完整描述。於此條件下，目標單品的 seed rank 前移至 2，mean rank 亦降至 1.8，顯示單次代表性結果與五次實驗的平均排序皆明顯改善。

表 4 - 17、案例一 - 各描述版本的檢索排名比較

描述版本	seed rank	mean rank
Original	25	23.4
No-Weather	2	2.8
No-Occasion	9	6.4
No-Style	9	4.4
Context-aware	**2**	**1.8**

由消融結果可知，此案例的改善主要來自**場合與風格資訊**。移除天氣資訊後，seed rank 仍維持為 2，mean rank 僅由 1.8 略退至 2.8，表示天氣因子在此案例中的額外貢獻相對有限。相較下，移除場合資訊與風格資訊後，排名皆明顯退步，顯示真正有效縮小候選範圍者，並非單純的氣溫資訊，而是「海灘氛圍」所提供的情境約束，以及「夢幻藍色、亞麻風格」所提供的造型線索。換言之，此案例的改善

並非僅來自描述變長，而是與改寫後補充了目標包款外觀及使用情境相關語意有關，使模型得以將檢索方向收斂至更貼近目標單品的候選集合。

案例二的目標單品為 dress (all-body)，實驗結果可參考附錄 I 。原始描述為 “salsa dance Salsa Lessons”，雖已包含部分活動線索，但整體仍偏簡略，僅能大致指出與舞蹈相關的場合，缺乏足以支撐檢索的外觀與風格資訊。因此，在原始條件下，目標單品的 seed rank 為 18，但 mean rank 高達 122.6，顯示代表性單次結果雖位於較前位置，五次實驗的平均排序表現仍不理想。完整改寫後，描述轉為 “23.6°C, Effortless Red Romance for Salsa Nights”，可理解為「23.6°C 下適合 Salsa 舞蹈夜晚的率性紅色浪漫風格」。相較於原始描述，改寫後除保留活動情境外，進一步補入了溫度條件、夜間使用情境與紅色浪漫風格，使查詢條件由單一活動名稱，轉為同時包含氣候、場合與造型方向的完整語意表述。改寫後，目標單品的 seed rank 前移至 5，mean rank 則大幅降至 3.0，顯示情境感知改寫描述能明顯改善五次實驗的平均排序表現。

表 4 - 18、案例二 - 各描述版本的檢索排名比較

描述版本	**seed rank**	**mean rank**
Original	18	122.6
No-Weather	3	6.4
No-Occasion	8	24.4
No-Style	68	60.2
Context-aware	**5**	**3.0**

此案例中，改善主要來自**風格資訊**，其次為**場合資訊**。移除風格資訊後，排名明顯惡化，顯示 Effortless Red Romance 所對應的風格語意，對目標洋裝的檢索方向具有關鍵作用。移除場合資訊後，mean rank 由 3.0 退至 24.4，表示 Salsa Nights 所提供的使用情境，對縮小候選範圍同樣具有重要影響至於移除天氣資訊後，seed rank 雖由 5 前移至 3，但 mean rank 由 3.0 退至 6.4，顯示單次代表性結果與五次實驗的平均結果並不完全一致；就平均排序而言，保留天氣資訊仍具有補充作用。這也說明，對 dress 類別而言，真正主導檢索方向者仍是風格與場合，而天氣資訊則較偏向補充性的情境修正。

綜合兩個案例，描述改寫的效益主要體現在將原始描述中不足或鬆散的文字線索，轉化為較具結構性的條件組合，使模型能同時掌握單品外觀方向與使用情境，進而改善檢索排序。結合個案觀察、類別分析與條件因子貢獻度結果可知，情境感知描述的價值不在於單一因子必然主導所有案例，而在於天氣、場合與風格共同提供較完整且貼近日常穿搭需求的文字條件。

4.6.2 顏色偏移改善案例

除目標單品排序改善外，實驗結果亦顯示，情境感知改寫描述有助於補強既有文字條件式穿搭推薦模型在屬性對齊上的限制。參考文獻指出[43]，當查詢條件包含特定顏色時，模型有時會優先推薦與套裝整體協調性較高的單品，而非符合指定顏色的候選，因而產生顏色偏移現象。

如圖 4 - 14 所示，原始文字條件為 “gray Gray Outfits”，情境感知改寫描述則為 “24.3°C, Effortless Gray Evening Look with a Classic Twist”，指定顏色為灰色。原始文字條件下，前五名候選皆為黑色單品，顯示模型未充分反映查詢中的灰色限制；使用情境感知改寫描述後，前段候選則轉為灰色單品，說明較完整的文字條件有助於改善檢索結果與指定顏色之間的對齊。不過，改寫後，案例中正確目標單品的排名由第 27 名退至第 36 名，顯示顏色對齊的改善未必會同步提升特定目標單品的排序。對於穿搭推薦而言，推薦結果是否符合使用者明確的情境與屬性需求具有重要意義，此案例中，情境感知改寫描述雖未改善目標單品排名，但能使前段推薦結果更符合灰色條件，呈現其在屬性對齊方面的補強效果。



圖 4 - 14、顏色偏移改善案例

為避免過度依賴單一案例，本研究進一步統計整體顏色偏移情形，結果如表 4 - 19 所示，分析僅保留 Original 與 Context-aware 皆具有相同單一顏色條件的資料，共取得 745 筆種子層級 (row-level) 觀測值，並以圖片主色判定顏色偏移。若前段候選中最常見的錯誤顏色比指定顏色至少多 2 筆，且目標單品符合指定顏色，即判定為顏色偏移。種子層級以單次隨機種子結果為單位，Original 共有 89 筆出現偏移，其中 39 筆於 Context-aware 下獲得改善，改善比例為 43.82%。個案層級 (case-level) 則合併相同套裝與目標單品的五次結果；若 Original 至少半數種子出現偏移，即列為問題個案，而 Context-aware 少於半數種子出現偏移則視為改善。結果共有 15 個問題個案，其中 5 個獲得改善，改善比例為 33.33%。

整體而言，情境感知改寫描述能改善部分顏色偏移，使前段候選更符合指定顏色，但個案層級的改善比例仍有限，且屬性對齊的提升未必會同步轉化為目標單品排名改善，顯示模型在顏色限制與精確單品檢索之間仍存在取捨。

表 4 - 19、顏色偏移改善分析結果

分析層級	問題數	改善數	改善比例
row-level	89	39	43.82%
case-level	15	5	33.33%

4.6.3 失敗案例與限制

為補充說明情境感知描述的適用限制，本研究另選取一組失敗案例進行分析，其各描述版本的檢索排名比較如表 4 - 20 所示，完整檢索結果則置於 0。由結果可見，在原始文字條件下，目標單品仍位於相對前段；使用情境感知改寫描述後，排名反而明顯後退，且移除天氣、場合或風格資訊後的各版本亦皆劣於 Original。此結果顯示，該案例的排序退化並非由單一因子造成，而可能源於改寫後的整體語意重心偏離目標單品的辨識關鍵。

表 4 - 20、失敗案例各描述版本的檢索排名比較

描述版本	seed rank	mean rank
Original	**28**	**22.4**
No-Weather	644	532.4
No-Occasion	333	505.2
No-Style	106	84.4
Context-aware	530	505.0

該案例的目標單品為 sunglasses。原始描述為 “burgundy babe Burgundy Clutches”，雖然文字本身仍不完整，且類別詞與目標單品並不完全一致，但其中至少保留了與目標單品較相關的色彩線索，即 burgundy。相較下，完整改寫描述 “27.2°C, Effortless Sunset Vibes with a Beachy Edge”，則將語意重心轉向氣溫、情境氛圍與整體風格，例如夕陽感、海灘感與率性風格等較抽象的條件。對於太陽眼鏡此類配件而言，模型更可能依賴鏡框輪廓、鏡片形狀、裝飾細節與色彩搭配等局部視覺特徵進行辨識，而非透過天氣、場合或整體造型氛圍進行檢索。因此，當描述中加入較多環境與風格語意後，模型反而可能被導向與情境相符、但與目標單品局部外觀差異較大的候選，進而造成排名後退。

此外，三種消融版本中，以 No-Style 的退化幅度相對較小，顯示 Beachy Edge 等風格語意雖會影響檢索方向，但主要原因可能不在單一風格詞，而在於整體描述將檢索焦點由單品細節轉向情境氛圍。此案例反映情境感知改寫描述的作用會受到單品類別特性限制。對 dress、heels 等與整體造型及穿著情境關聯較高的單品，情境資訊通常能提供有效限制；對 sunglasses 等較依賴局部外觀辨識的配件類別，過多情境語意則可能稀釋原有辨識線索。此結果與前述類別效能分析一致，說明情境感知改寫描述的適用性仍須配合單品類型與檢索目標加以判斷。

4.7 綜合討論

綜合各項實驗結果可知，在固定資料切分、模型架構、單品特徵、訓練流程與隨機種子的條件下，僅將原始文字替換為情境感知改寫描述，即能提升穿搭相容性預測、填空式搭配與套裝推薦表現，且在公平比較子集上仍維持相同趨勢。由於改寫描述的文字長度普遍高於原始文字，本研究進一步檢查效能提升是否僅來自描述變長。結果顯示，文字長度差與命中變化及排名改善之間僅呈現極弱相關，且在文字長度相同或接近的子集中，情境感知改寫描述仍具有較佳表現；目標單品線索

檢查亦未顯示改寫描述系統性增加答案相關詞彙。因此，推薦效能的改善較可能來自天氣、場合與風格語意所提供的情境感知條件資訊，而非單純增加文字數量或直接暴露目標單品線索。

為確認生成資料可用於後續推薦實驗，本研究亦檢查 CLO、MET 與主觀舒適溫度參考值的分布，以及情境感知改寫描述的圖文一致性與條件合理性。三項代理變數的主要分布均落於可解釋範圍，雖存在少數極端值，但其用途僅在於約束情境語意，並不等同於實際氣象或個人熱舒適感受。兩位多模態評分者的結果顯示，多數描述能通過主要品質檢核項目，且共同辨識的低分樣本明顯高於隨機期望；提示詞穩健性檢查與 30 筆人工稽核樣本中亦顯示，評分結果具有一定重現性，且與人工判斷呈現正向趨勢。雖然圖像對齊、風格與場合判讀，以及顏色或材質辨識等項目仍存在分歧，但未發現需要大規模重新生成或替換描述的系統性問題。因此，正式生成的 35,140 筆描述均保留作為下游模型輸入，品質分數僅用於診斷與案例分析，不作為資料篩選依據。

在確認效能提升與生成資料有效性後，本研究透過公平比較子集上的消融實驗，進一步分析天氣、場合與風格三項因子的相對作用。移除三項因子後，推薦效能皆出現不同程度的下降，其中風格資訊的影響最為明顯，天氣與場合則主要提供額外的外在環境與使用情境限制。此差異可能與 Polyvore 原始文字本身偏重整體造型與風格表達有關，使風格語意較容易與既有影像及文字表徵對應；場合語意亦常與風格、活動及時段交疊，而天氣語意則依代理變數建構，可能受到推估誤差與描述完整度影響。因此，此結果僅反映三項因子在目前資料與模型設定下的相對影響，不應該就此推論天氣與場合在實際穿搭決策中的重要性較低。

類別、情境子集與個案分析則進一步說明上述效益的適用範圍。情境感知改寫描述在不同冷暖、場合、風格密度與單品類型下皆維持一致的改善方向，但洋裝、鞋款與部分包款等與整體造型及使用情境關聯較高的類別，提升幅度較為明顯；太陽眼鏡與部分飾品等較依賴顏色、輪廓與局部裝飾細節的類別，改善則相對有限。成功案例顯示，改寫描述能補充原始文字欠缺的情境與造型線索，使目標單品排名明顯前移；顏色偏移案例亦顯示，改寫後的前段候選能更符合指定顏色，但屬性對齊改善未必同步提升唯一目標單品的排名。失敗案例則說明，當描述中的抽象情境氛圍取代原有的色彩或局部外觀線索時，可能使檢索方向偏離目標單品。這些案例與整體及類別分析的趨勢一致，顯示情境感知語意確實能補強原始文字條件，但其效益仍會受到單品類型與檢索目標特性的影響。

整體而言，本研究成果顯示，在維持推薦模型架構與表徵設定不變的條件下，透過資料端的情境語意建構，即能改善文字條件式穿搭推薦效能。所提出流程將天氣、場合與風格轉換為可檢核且可供模型學習的自然語言條件；然而，如何在保留整體情境語意的同時，避免稀釋顏色、輪廓與裝飾細節等局部辨識線索，仍有待未來研究進一步探討。

第五章、結論與未來研究

總結本研究的主要成果與貢獻，並說明研究限制及未來可延伸的研究方向。

5.1 研究結論

本研究探討如何將天氣、場合與風格等情境感知需求，轉換為可供模型學習的文字條件，以提高穿搭推薦對明確情境需求的回應能力。針對 Polyvore 原始文字較為簡略且缺乏生活情境資訊的問題，本研究導入 CLO、MET 與主觀舒適溫度參考值，建立具情境約束的文字建構流程，並生成同時反映天氣、場合與風格的情境感知改寫描述。推薦實驗維持模型架構、表徵設定、資料切分、訓練流程與隨機種子不變，僅比較原始文字與情境感知改寫描述的差異。

完成資料解析與格式檢查後，共取得 35,140 筆可用套裝樣本。代理變數分布、生成描述品質、文字長度與目標單品線索等檢查結果顯示，多數描述具備基本圖文一致性與情境合理性，且未發現需要大規模重新生成或替換描述的系統性問題，因此正式生成資料均保留作為推薦模型輸入。文字長度差與推薦改善僅呈現極弱相關，改寫描述亦未系統性增加目標單品線索，顯示效能提升較不可能僅由文字變長或答案線索造成。

推薦結果顯示，使用情境感知改寫描述後，穿搭相容性預測與套裝推薦表現皆顯著優於使用原始文字的設定。曲線下面積由 0.9292 提升至 0.9454，填空式搭配準確率由 0.6374 提升至 0.6478；Recall@10 由 0.0780 提升至 0.0921，Recall@50 則由 0.2303 提升至 0.2518，且於公平比較子集上仍維持相同改善方向。消融實驗進一步顯示，移除天氣、場合與風格資訊後，模型效能皆出現不同程度的下降，其中風格資訊的影響最為明顯，天氣與場合則主要補充外在環境與使用情境限制。

類別、情境子集與個案分析顯示，情境感知改寫描述在不同情境下具有一致的正向效益，但改善幅度會受到單品類別影響。洋裝、鞋款與部分包款等與整體造型及穿著情境關聯較高的單品受益較明顯；太陽眼鏡與部分飾品等較依賴局部視覺細節的類別，效益則相對有限。整體而言，本研究在不調整推薦模型架構的前提下，驗證資料端的情境語意建構能改善文字條件式穿搭推薦效能，並說明其效益來源與適用邊界。

5.2 研究限制

本研究雖已驗證情境感知條件化描述對穿搭推薦任務具有一定效益，但仍存在若干限制。首先，本研究以 Polyvore 穿搭資料集為主要實驗基礎，CLO、MET 與情境條件亦透過文獻資料、標準化指標與大型語言模型推估，並非直接來自真實使用者衣櫃、即時天氣、穿著回饋與主觀舒適度資料。因此，所建構之情境感知條

件仍可能受到原始資料分布、文獻參考值與推估誤差影響，且 Polyvore 資料與近年實際穿搭趨勢亦可能存在時間落差。此外，本研究沿用原始推薦模型之類別篩選規則，僅將資料量超過 3,000 筆的單品類別納入訓練。經確認，明確標記為男性類別的資料未達此門檻，因此未納入下游模型訓練與評估，中性或未標記性別的資料亦不視為男性資料，故目前結果尚不足以反映男性穿搭情境下的適用性。

其次，本研究以 CLO、MET 與熱舒適推估作為情境條件的中介尺度，但實際穿著舒適度仍會受到個人體質、年齡、濕度、風速、日照與室內外環境等因素影響，因此主觀舒適溫度參考值僅作為相對比較與語意建構依據，而非精確的個人生理熱舒適預測。另一方面，資料生成與品質評估皆採固定模型設定，尚未系統性比較不同模型規模與視覺理解能力，亦未結合大規模人工標註、使用者研究或真實穿著回饋。因此，本文結果主要反映既有資料集與固定實驗設定下的驗證，實務適用性仍需進一步確認。

5.3 未來研究方向

基於上述限制，後續研究可優先建立更貼近真實使用情境的穿搭資料，納入使用者衣櫃、即時天氣、行程情境、穿著回饋與主觀舒適度評分，並擴充不同性別、體型、年齡層、穿著風格與地區氣候的資料分布。性別資料方面，應明確區分男性、女性、中性與未標記資料，並補充目前不足的男性類別樣本，使其達到模型訓練門檻，再透過不同性別子集與跨資料集驗證，檢查情境感知文字條件在不同族群中的適用性。未來亦可結合使用者問卷、人工標註與實際穿著回饋，補足自動化評估較難反映的穿著舒適度、情境契合度與風格符合程度。

在實驗設計方面，後續可加入一般文字改寫控制組、單一條件版本或不同條件組合，以進一步拆解文字改寫與情境資訊的影響。同時，可強化配件類別與局部視覺細節的表徵，使模型在保留整體情境語意的同時，仍能掌握顏色、輪廓與裝飾等單品線索，改善精確單品檢索表現。

參考文獻

[1] Agarwal, P. et al. 2018. Personalizing Similar Product Recommendations in Fashion E-commerce. arXiv.

[2] An, H. et al. 2023. Conceptual framework of hybrid style in fashion image datasets for machine learning. *Fashion and Textiles*. 10, 1 (May 2023), 18. https://doi.org/10.1186/s40691-023-00338-8.

[3] Aparicio-Ruiz, P. et al. 2024. Predicting the clothing insulation through machine learning algorithms: A comparative analysis and a practical approach. *Building Simulation*. 17, 5 (May 2024), 839–855. https://doi.org/10.1007/s12273-024-1114-9.

[4] ASHRAE 2013. *ANSI/ASHRAE Addendum h to ANSI/ASHRAE Standard 55-2010: Thermal Environmental Conditions for Human Occupancy*. Technical Report #Addendum h to ANSI/ASHRAE Standard 55-2010. American Society of Heating, Refrigerating and Air-Conditioning Engineers.

[5] Chakraborty, S. et al. 2021. Fashion Recommendation Systems, Models and Methods: A Review. *Informatics*. 8, 3 (Sept. 2021), 49. https://doi.org/10.3390/informatics8030049.

[6] Chang, C.-L. et al. 2025. Using large multimodal models to predict outfit compatibility. *Decision Support Systems*. 194, (July 2025), 114457. https://doi.org/10.1016/j.dss.2025.114457.

[7] Chu, Y. et al. 2025. Beneath the colorness skies: Does weather influence consumer color preference? *Journal of Retailing and Consumer Services*. 82, (Jan. 2025), 104154. https://doi.org/10.1016/j.jretconser.2024.104154.

[8] Dai, X. et al. 2024. Appearance for Females, Functionality for Males? The False Lay Belief about Gender Difference in Product Preference. *Journal of Consumer Research*. 50, 6 (Apr. 2024), 1136–1156. https://doi.org/10.1093/jcr/ucad054.

[9] Deldjoo, Y. et al. 2024. A Review of Modern Fashion Recommender Systems. *ACM Computing Surveys*. 56, 4 (Apr. 2024), 1–37. https://doi.org/10.1145/3624733.

[10] Devlin, J. et al. 2019. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1* (Minneapolis, Minnesota, June 2019), 4171–4186.

[11] Ding, Y. et al. 2023. Personalized fashion outfit generation with user coordination preference learning. *Information Processing & Management*. 60, 5 (Sept. 2023), 103434. https://doi.org/10.1016/j.ipm.2023.103434.

[12] Fanger, P.O. 1972. *Thermal comfort : analysis and applications in environmental engineering*. McGraw-Hill.

[13] Fu, X. et al. 2025. PREF: Reference-Free Evaluation of Personalised Text Generation in LLMs. arXiv.

[14] Gagge, A.P. et al. 1941. A Practical System of Units for the Description of the Heat Exchange of Man with His Environment. *Science*. 94, 2445 (Nov. 1941), 428–430. https://doi.org/10.1126/science.94.2445.428.

[15] Gemma Team et al. 2025. Gemma 3 Technical Report. arXiv.

[16] Goldberg, D. et al. 1992. Using collaborative filtering to weave an information tapestry. *Communications of the ACM*. 35, 12 (Dec. 1992), 61–70. https://doi.org/10.1145/138859.138867.
[17] Gruber, R. et al. 2024. Dressing up social psychology: Empirically investigating the psychological functions of clothing using the example of symbolic protection. *British Journal of Social Psychology*. 63, 2 (2024), 1003–1035. https://doi.org/10.1111/bjso.12700.
[18] Gu, J. et al. 2026. A survey on LLM-as-a-judge. *The Innovation*. (Jan. 2026), 101253. https://doi.org/10.1016/j.xinn.2025.101253.
[19] Han, X. et al. 2017. Learning Fashion Compatibility with Bidirectional LSTMs. *Proceedings of the 25th ACM international conference on Multimedia* (Oct. 2017), 1078–1086.
[20] He, R. and McAuley, J. 2016. VBPR: Visual Bayesian Personalized Ranking from Implicit Feedback. *Proceedings of the AAAI Conference on Artificial Intelligence*. 30, 1 (Feb. 2016). https://doi.org/10.1609/aaai.v30i1.9973.
[21] Herrmann, S.D. et al. 2024. 2024 Adult Compendium of Physical Activities: A third update of the energy costs of human activities. *Journal of Sport and Health Science*. 13, 1 (Jan. 2024), 6–12. https://doi.org/10.1016/j.jshs.2023.10.010.
[22] Jagadeesh, V. et al. 2014. Large scale visual recommendations from street fashion images. *Proceedings of the 20th ACM SIGKDD international conference on Knowledge discovery and data mining* (New York, NY, USA, Aug. 2014), 1925–1934.
[23] Jing, W. et al. 2023. Outdoor clothing choice for different populations in cold regions: A clothing choice prediction model based on machine learning. *Energy and Buildings*. 289, (June 2023), 113069. https://doi.org/10.1016/j.enbuild.2023.113069.
[24] Koren, Y. et al. 2009. Matrix Factorization Techniques for Recommender Systems. *Computer*. 42, 8 (Aug. 2009), 30–37. https://doi.org/10.1109/MC.2009.263.
[25] Krizhevsky, A. et al. 2012. ImageNet Classification with Deep Convolutional Neural Networks. *Advances in Neural Information Processing Systems* (2012), 1097–1105.
[26] Kurazumi, Y. et al. 2021. Clothing Area Factor for Typical Seasonal Clothing of Infant. *Health (Irvine, Calif.)*. 13, 4 (2021), 378–392. https://doi.org/10.4236/health.2021.134031.
[27] Li, D. et al. 2025. From Generation to Judgment: Opportunities and Challenges of LLM-as-a-judge. *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing* (Suzhou, China, 2025), 2757–2791.
[28] Lin, J. et al. 2025. How Can Recommender Systems Benefit from Large Language Models: A Survey. *ACM Transactions on Information Systems*. 43, 2 (Mar. 2025), 1–47. https://doi.org/10.1145/3678004.
[29] Linden, G. et al. 2003. Amazon.com recommendations: item-to-item collaborative filtering. *IEEE Internet Computing*. 7, 1 (Jan. 2003), 76–80. https://doi.org/10.1109/MIC.2003.1167344.
[30] Liu, S. et al. 2012. Hi, magic closet, tell me what to wear! *Proceedings of the 20th ACM international conference on Multimedia* (Nara Japan, Oct. 2012), 619–628.
[31] Liu, Y. et al. 2017. Weather-to-garment: Weather-oriented clothing recommendation. *2017 IEEE International Conference on Multimedia and Expo (ICME)* (July 2017), 181–186.
[32] McIntyre, D.A. 1978. *Design Requirements for a Comfortable Environment*. Technical Report #ECRC/M1185. The Electricity Council Research Centre.

[33] O'Shea, K. and Nash, R. 2015. An Introduction to Convolutional Neural Networks. arXiv.
[34] Pang, K. et al. 2025. FashionM3: Multimodal, Multitask, and Multiround Fashion Assistant based on Unified Vision-Language Model. arXiv.
[35] Pereira, J. et al. 2024. Check-Eval: A Checklist-based Approach for Evaluating Text Quality. arXiv.
[36] Ricci, F. et al. eds. 2011. *Recommender Systems Handbook*. Springer US.
[37] Smallcombe, J. et al. 2021. Updated Database of Clothing Thermal Insulation and Vapor Permeability Values of Western Ensembles for Use in ASHRAE Standard 55, ISO 7730, and ISO 9920. *ASHRAE Transactions*. VC-21–011, (Jan. 2021), 773–799.
[38] Sohn, W. et al. 2026. Multi-modal deep learning-based fashion recommendation with styles. *Knowledge-Based Systems*. 340, (May 2026), 115701. https://doi.org/10.1016/j.knosys.2026.115701.
[39] Sun, Z. et al. 2025. Dynamic detection models for clothing insulation and metabolic rate based on computer vision. *Building and Environment*. 283, (Sept. 2025), 113372. https://doi.org/10.1016/j.buildenv.2025.113372.
[40] Vaswani, A. et al. 2017. Attention is All you Need. *Advances in Neural Information Processing Systems* (2017), 5998–6008.
[41] Vo, A.H. et al. 2023. An efficient framework for outfit compatibility prediction towards occasion. *Neural Computing & Applications*. 35, 19 (July 2023), 14213–14226. https://doi.org/10.1007/s00521-023-08431-1.
[42] Vogiatzis, D. et al. 2012. Expert and community based style advice. *Expert Systems with Applications*. 39, (Sept. 2012), 10647–10655. https://doi.org/10.1016/j.eswa.2012.02.178.
[43] Wang, X. and Zhong, Y. 2024. Text-Conditioned Outfit Recommendation With Hybrid Attention Layer. *IEEE Access*. 12, (2024), 281–293. https://doi.org/10.1109/ACCESS.2023.3346933.
[44] Wu, L. et al. 2024. A survey on large language models for recommendation. *World Wide Web*. 27, 5 (Sept. 2024), 60. https://doi.org/10.1007/s11280-024-01291-2.
[45] Xu, Y. et al. 2024. Diffusion Models for Generative Outfit Recommendation. *Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval* (July 2024), 1350–1359.
[46] Yang, A. et al. 2025. Qwen3 Technical Report. arXiv.
[47] Yang, L. et al. 2024. Diffusion Models: A Comprehensive Survey of Methods and Applications. *ACM Computing Surveys*. 56, 4 (Apr. 2024), 1–39. https://doi.org/10.1145/3626235.
[48] Yu, W. et al. 2018. Aesthetic-based Clothing Recommendation. *Proceedings of the 2018 World Wide Web Conference* (Republic and Canton of Geneva, CHE, Apr. 2018), 649–658.
[49] Zhang, X. et al. 2017. Trip Outfits Advisor: Location-Oriented Clothing Recommendation. *IEEE Transactions on Multimedia*. 19, 11 (Jan. 2017), 2533–2544. https://doi.org/10.1109/TMM.2017.2696825.
[50] Zhao, S. et al. 2025. Reliability of lookup table methods for estimating clothing insulation: Experimental verification using typical garments. *Energy and Buildings*. 348, (Dec. 2025), 116500. https://doi.org/10.1016/j.enbuild.2025.116500.

附錄 A

類別	name	Clo value
內搭	Bra	0.01
	Panties	0.03
	Men's briefs	0.04
	T-shirt	0.08
	Half-slip	0.14
	Long underwear bottoms	0.15
	Full slip	0.16
	Long underwear top	0.2
	Panty hose/stockings	0.02
上衣	Sleeveless/scoop-neck blouse	0.12
	Short-sleeve knit sport shirt	0.17
	Short-sleeve dress shirt	0.19
	Long-sleeve dress shirt	0.25
	Long-sleeve flannel shirt	0.34
	Long-sleeve sweatshirt	0.34
	Sleeveless vest （thin）	0.13
	Sleeveless vest （thick）	0.22
	Long-sleeve sweater （thin）	0.25
	Long-sleeve sweater （thick）	0.36
	Sleeveless vest （thin）	0.1
	Sleeveless vest （thick）	0.17
	Single-breasted jacket （thin）	0.36
	Single-breasted jacket （thick）	0.44
	Double-breasted jacket （thin）	0.42
	Double-breasted jacket （thick）	0.48
	T-shirt 1	0.11
	T-shirt 2	0.12
	Polo shirt	0.12
	Short-sleeved shirt	0.15
	Sports long sleeve 1	0.11
	Sports long sleeve 2	0.22
	Long-sleeved underwear	0.18
	Long-sleeved shirt 1	0.22
	Long-sleeved shirt 2	0.22
	Sweatshirt	0.26
	Hoodies	0.28
	Sports jacket	0.25
	Denim jacket	0.32
	Suit jacket 1	0.31
	Suit jacket 2	0.31
	Sweater	0.31
	Outdoor jacket	0.55
	Down jacket 1	0.54
	Down jacket 2	0.54
	Down jacket 3	0.64

類別	name	Clo value
	Sleeveless short gown （thin）	0.18
	Sleeveless long gown （thin）	0.2
	Short-sleeve hospital gown	0.31
	Short-sleeve short robe （thin）	0.34
	Short-sleeve pajamas （thin）	0.42
	Long-sleeve long gown （thick）	0.46
	Long-sleeve short wrap robe （thick）	0.48
	Long-sleeve pajamas （thick）	0.57
	Long-sleeve long wrap robe （thick）	0.69
下著	Short shorts	0.06
	Walking shorts	0.08
	Straight trousers （thin）	0.15
	Straight trousers （thick）	0.24
	Sweatpants	0.28
	Overalls	0.3
	Coveralls	0.49
	Skirt （thin）	0.14
	Skirt （thick）	0.23
	Sleeveless, scoop neck （thin）	0.23
	Sleeveless, scoop neck （thick）, i.e., jumper	0.27
	Short-sleeve shirtdress （thin）	0.29
	Long-sleeve shirtdress （thin）	0.33
	Long-sleeve shirtdress （thick）	0.47
	Shorts	0.06
	Light skirt	0.16
	Long legs underwear	0.16
	Sweatpants + shorts	0.19
	Sweatpants （thin）	0.19
	Sweatpants （middle）	0.24
	Sweatpants （thick）	0.27
	Coveralls	0.23
	Suit pants	0.2
	Jeans （thin）	0.2
	Jeans （thick）	0.27
	Casual pants （thin）	0.2
	Casual pants （middle）	0.19
	Casual pants （thick）	0.27
鞋子	Ankle-length athletic socks	0.02
	Sandals/thongs	0.02
	Shoes	0.02
	Slippers （quilted, pile lined）	0.03
	Calf-length socks	0.03
	Knee socks （thick）	0.06
	Boots	0.1

附錄 B

ID	description	Clo value
E001	T-shirt 1 + Shorts	0.35
E002	Walking shorts, short-sleeve shirt	0.36
E003	T-shirt 2 + Shorts	0.37
E004	Sports long sleeve 1 + Sweatpants （middle）	0.47
E005	Knee-length skirt, short-sleeve shirt （sandals）	0.54
E006	Polo shirt + Light skirt	0.54
E007	Short-sleeved shirt + Casual pants （thin）	0.56
E008	Trousers, short-sleeve shirt	0.57
E009	Trousers, long-sleeve shirt	0.61
E010	Long-sleeved shirt 1 + Casual pants （middle）	0.63
E011	Sports long sleeve 2 + Sweatpants （thick）	0.66
E012	Knee-length skirt, long-sleeve shirt, full slip	0.67
E013	Long-sleeve coveralls, T-shirt	0.72
E014	Sweat pants, long-sleeve sweatshirt	0.74
E015	Suit jacket 1 + Suit pants	0.82
E016	Bikini style briefs + Non-wired bra + Cap-sleeve top + Short mini skirt （thin） + Shoes	0.84
E017	Denim jacket + Jeans （thin）	0.84
E018	Outdoor jacket + Casual pants （middle）	0.84
E019	Hoodies + Sweatpants （thin）	0.85
E020	Bikini style briefs + Non-wired bra + Sleeveless print dress + Shoes	0.87
E021	Bikini style briefs + Non-wired bra + Short sleeve "fit and flare" dress + Sandals	0.87
E022	Overalls, long-sleeve shirt, T-shirt	0.89
E023	Bikini style briefs + Non-wired bra + Long-sleeve "fit and flare' print dress + Sandals	0.9
E024	Bikini style briefs + Non-wired bra + Short-sleeve jacquard dress + Shoes	0.91
E025	Suit jacket 2 + Coveralls	0.91
E026	Boxer shorts + Socks + Polo shirt + Chino shorts + Shoes	0.92
E027	Boxer shorts + Socks + T-shirt + Chino shorts + Shoes	0.93
E028	Bikini style briefs + Non-wired bra + Short-sleeve jacquard dress + Tights （10 denier） + Shoes	0.94
E029	Bikini style briefs + Non-wired bra + Long-sleeve blouse + Mini skirt （thick） + Shoes	0.95
E030	Bikini style briefs + Non-wired bra + Long-sleeve blouse + Denim Midi Skirt + Shoes	0.95
E031	Bikini style briefs + Non-wired bra + Long-sleeve tunic top + Leggings + Shoes	0.95
E032	Trousers, long-sleeve shirt plus suit jacket	0.96

ID	description	Clo value
E033	Long-sleeve pajama tops, long pajama trousers, short 3/4 length robe （slippers, no socks）	0.96
E034	Boxer shorts + Socks + Polo shirt + Jeans （skinny fit） + Shoes	0.97
E035	Bikini style briefs + Non-wired bra + Long-sleeve blouse + Mini skirt （thick） + Tights （10 denier） + Shoes	0.97
E036	Bikini style briefs + Non-wired bra + Sleeveless print dress + Cardigan + Shoes	0.98
E037	Bikini style briefs + Non-wired bra + Long-sleeve blouse + Jeans （skinny fit） + Shoes	0.98
E038	Bikini style briefs + Non-wired bra + Sleeveless blouse + Pencil skirt + Tights （10 denier） + Shoes	1.0
E039	Bikini style briefs + Non-wired bra + Long-sleeve blouse + Mini skirt （thick） + Tights （80 denier） + Shoes	1.0
E040	Trousers, long-sleeve shirt plus long-sleeve sweater, T-shirt	1.01
E041	Bikini style briefs + Non-wired bra + Long-sleeve blouse + Mini skirt （thick） + Tights （200 denier） + Shoes	1.01
E042	Bikini style briefs + Non-wired bra + Long-sleeve blouse + Ripped Jeans + Shoes	1.02
E043	Knee-length skirt, long-sleeve shirt, half slip, suit jacket	1.04
E044	Boxer shorts + Socks + Short-sleeve shirt + Chino pants + Shoes	1.04
E045	Boxer shorts + Socks + T-shirt + Chino pants + Trainers/sneakers	1.04
E046	Bikini style briefs + Non-wired bra + Long-sleeve blouse + Cardigan + Mini skirt （thick） + Tights （10 denier） + Shoes	1.04
E047	Bikini style briefs + Non-wired bra + Long-sleeve blouse + Mini skirt （thick） + Leggings + Shoes	1.04
E048	Bikini style briefs + Non-wired bra + Long-sleeve tunic top + Jeans （skinny fit） + Knee-high boots	1.04
E049	Boxer shorts + Socks + Polo shirt + Suit pants + Shoes	1.05
E050	Bikini style briefs + Non-wired bra + Lace-sleeve blouse + Suit pants （tapered fit） + Shoes	1.07
E051	Briefs + Socks + Polo shirt + Jeans （straight fit） + Shoes	1.08
E052	Bikini style briefs + Non-wired bra + Long-sleeve blouse + Jeans （skinny fit） + Knee-high boots	1.08
E053	Boxer shorts + Socks + Polo shirt + Jeans （straight fit） + Shoes	1.09
E054	Boxer shorts + Socks + T-shirt + Jeans （straight fit） + Shoes	1.09
E055	Long-sleeve blouse + Pencil skirt + Shoes （without bra）	1.09
E056	Bikini style briefs + Non-wired bra + Long-sleeve blouse + Capri pants （cropped） + Shoes	1.09
E057	Knee-length skirt, long-sleeve shirt, half slip, long-sleeve sweater	1.1
E058	Ankle-length skirt, long-sleeve shirt, suit jacket	1.1
E059	Sports jacket + Suit pants	1.1

ID	description	Clo value
E060	Bikini style briefs + Non-wired bra + Long-sleeve blouse + Pencil skirt + Shoes	1.11
E061	Bikini style briefs + Non-wired bra + Long-sleeve blouse + Mini skirt （thick） + Knee-high boots	1.11
E062	Bikini style briefs + Non-wired bra + Long-sleeve blouse + Suit pants （tapered） + Shoes	1.12
E063	Boxer shorts + Socks + Polo shirt + Jeans （loose fit） + Shoes	1.13
E064	Bikini style briefs + Non-wired bra + Long-sleeve blouse + Pencil skirt + Shoes	1.13
E065	Bikini style briefs + Non-wired bra + Long-sleeve blouse + Suit pants （bootcut fit） + Shoes	1.13
E066	Trousers, long-sleeve shirt plus suit jacket, vest, T-shirt	1.14
E067	Bikini style briefs + Non-wired bra + Strap vest top + Long-sleeve blouse + Pencil skirt + Shoes	1.14
E068	Boxer shorts + Socks + Office shirt + Chino pants + Shoes	1.16
E069	Boxer shorts + Socks + Office Shirt + Suit pants + Shoes	1.17
E070	Briefs + Socks + Office Shirt + Suit pants + Shoes	1.17
E071	Bikini style briefs + Non-wired bra + Sleeveless blouse + Cardigan + Pencil skirt + Shoes	1.17
E072	Bikini style briefs + Non-wired bra + Long-sleeve blouse + Suit pants （loose fit） + Shoes	1.17
E073	Boxer shorts + Socks + KSU shirt + KSU pants + Trainers/sneakers	1.2
E074	Bikini style briefs + Non-wired bra + Long-sleeve blouse + Pencil skirt + Cardigan + Shoes	1.21
E075	Bikini style briefs + Non-wired bra + Long-sleeve blouse + Pencil skirt + Cardigan + Tights （10 denier） + Shoes	1.21
E076	Boxer shorts + Socks + Office Shirt + Suit pants + Tweed blazer jacket + Tie + Shoes	1.22
E077	Bikini style briefs + Non-wired bra + Strap vest top + Long-sleeve blouse + Pencil skirt + Cardigan + Shoes	1.22
E078	Bikini style briefs + Non-wired bra + Strap vest top + Long-sleeve jumper + Capri pants （cropped） + Shoes	1.22
E079	Boxer shorts + Socks + T-shirt + Office shirt + Suit pants + Shoes	1.23
E080	Bikini style briefs + Non-wired bra + Strap vest top + Long-sleeve blouse + Pencil skirt + Cardigan + Shoes	1.23
E081	Boxer shorts + Socks + Office Shirt + Suit pants + V-neck sweater + Shoes	1.26
E082	Trousers, long-sleeve shirt plus long-sleeve sweater, T-shirt plus suit jacket, long underwear bottoms	1.3
E083	Bikini style briefs + Non-wired bra + Long-sleeve blouse + Long-sleeve jumper + Suit pants （tapered） + Shoes	1.3
E084	Boxer shorts + Socks + T-shirt + Check cotton shirt （thick） + Jeans （straight fit） + Shoes	1.31

ID	description	Clo value
E085	Bikini style briefs + Non-wired bra + Lace-sleeve blouse + Pencil skirt + Suit jacket + Tights （10 denier） + Shoes	1.31
E086	Down jacket 2 + Jeans （thick）	1.31
E087	Bikini style briefs + Non-wired bra + Lace-sleeve blouse + Suit pants （tapered） + Suit jacket + Shoes	1.33
E088	Down jacket 1 + Casual pants （thick）	1.33
E089	Boxer shorts + Socks + T-shirt + Check cotton shirt （thick） + Jeans （straight fit） + Shoes	1.34
E090	Bikini style briefs + Non-wired bra + Lace-sleeve blouse + Pencil skirt + Suit jacket + Shoes	1.34
E091	Boxer shorts + Socks + Office Shirt + Suit pants + Harrington Jacket + Tie + Shoes	1.35
E092	Boxer shorts + Socks + Office shirt + Suit pants + Suit Jacket + Tie + Shoes	1.36
E093	Insulated coveralls, long-sleeve thermal underwear tops and bottoms	1.37
E094	Boxer shorts + Socks + Office Shirt + Suit pants + Waistcoat + Suit Jacket + Tie + Shoes	1.37
E095	Briefs + Socks + Polo shirt + Jeans（straight fit）+ Tweed blazer jacket + Shoes	1.37
E096	Briefs + Socks + Office shirt + Suit pants + Suit Jacket + Tie + Shoes	1.37
E097	Boxer shorts + Socks + T-shirt + Jeans （straight fit） + Thin hooded jacket （"Hoodie"） + Shoes	1.38
E098	Boxer shorts + Socks （sport） + T-shirt + ASTM shirt + ASTM pants + Trainers/sneakers	1.39
E099	Boxer shorts + Socks + Office shirt + Suit pants + Tweed blazer jacket + Tie + Shoes	1.39
E100	Boxer shorts + Socks + T-shirt + Office Shirt + Suit pants + Suit Jacket + Tie + Shoes	1.4
E101	Boxer shorts + Socks + Polo shirt + Jeans（straight fit）+ Tweed blazer jacket + Shoes	1.41
E102	Boxer shorts + Socks + T-shirt + Check cotton shirt （thick） + Thin hooded jacket（"Hoodie"）+ Jeans（straight fit）+ Shoes	1.45
E103	Boxer shorts + Socks + T-shirt + Jeans （straight fit） + Thick hooded jacket （"Hoodie"） + Shoes	1.55
E104	Down jacket 3+ + Casual pants （thick）	1.72

附錄 C

USER
You are a fashion expert who writes creative, natural, and search-friendly outfit titles.

Analyze the provided outfit image and the following contextual data to generate a new title.
The title should sound like a phrase a user might type when searching for this kind of outfit online.

Outfit Data:
- **Recommended Temperature:** {temp:.1f}°C
- **Clothing Insulation:** {clo:.2f} CLO
- **Original Title:** {desc}

Guidelines:
1. Begin the title with the temperature, like "{int(round(temp, 0))}°C, ".
2. Combine weather feeling and the outfit's vibe or implied scene based on its visual cues (style, material, layering, color, accessories) into one concise, fluent sentence.
3. Reflect practical logic between temperature, CLO value, and the outfit — as if you understand why these clothes match the weather and activity.
4. The tone should be aspirational yet realistic, suitable for fashion recommendation platforms.
5. Avoid listing exact items (e.g., "shirt", "pants"); focus on the style or scene instead .
6. Output **only** the final title string, without any explanations or extra text.

Your Thought Process (implicit, do not include in output):
- Think about the thermal comfort logic: since the temperature is {temp:.1f}°C, imagine what it would actually feel like.
- Consider how the {clo:.2f} CLO value supports comfort in that condition.
- Infer a plausible scene primarily from visual cues in the outfit.
- Your goal is to make the title sound like something users would actually search for when dressing for similar weather and activities.

Output: A single English title that follows the above rules.

附錄 D

為提升本研究在 CLO 推導上的一致性、可解析性與批次執行穩定性，本研究於實作過程中歷經多次提示工程調整，逐步由初始的自由生成流程，修正為具固定輸出格式、容錯解析、合理範圍檢核與異常值處理機制的完整流程。本附錄旨在補充正文 3.4 節所述的資料建構控管與可重現性內容，說明 CLO 推導流程如何由原型階段發展為可持續執行的研究流程。

D.1 CLO 提示工程版本演進

表 D - 1 彙整本研究在 CLO 推導流程中的提示工程版本演進。本文推導的目標為套裝層級的**總 CLO 值**，亦即根據整體穿搭圖像、單品資訊與 CLO 參考資料，估計該套裝在穿著情境下所呈現的衣物保暖程度。此處採用總 CLO 值作為推導目標，主要是因為套裝保暖性會受到疊穿方式、衣物覆蓋面積、材質厚度與空氣層壓縮等因素影響，未必能由各單品 CLO 值直接加總取得。因此，本研究透過 LLM 輔助推估套裝整體保暖程度，並配合後處理規則進行合理性檢查與異常值修正。在提示工程演進上，初始版本主要仰賴模型自由生成推理與數值結果，容易造成說明文字與總 CLO 值混雜，導致後續批次解析困難。後續版本逐步加入固定輸出區塊、JSON 擷取、文字補抓、合理範圍檢核、失敗紀錄與續跑機制，使 CLO 推導流程由單次回應生成，逐步修正為可批次處理、可追溯且可重複執行的資料建構流程。

表 D - 1、CLO 提示工程版本演進

版本	版本資訊	PROMPT 改動	問題
v1	建立基本流程，輸入套裝描述、單品資訊、完整 CLO 知識與圖片，輸出 JSONL	System Prompt：You are a clothing thermal comfort expert... Please reason step by step, and at the end output the result in JSON format: {"total_clo": number}	初始輸出為自由生成文字，結果與推理混雜，總 CLO 值難以穩定擷取
v2	將輸出格式固定為 [REASONING] 與 <json>...</json> → 提升結果區塊辨識性，降低輸出結構混亂問題	System Prompt：Return exactly two blocks: [REASONING] ... <json>{"total_clo": number}</json> User Prompt：Return two blocks exactly: [REASONING] <=4 bullets, <=280 chars. <json>{"total_clo": number}</json>	僅依賴模型輸出合法 JSON，失敗率仍高
v3	新增 extract_json_block（）、fallback_total_from_text（）、_is_reasonable_total（），將流程改為「JSON 擷取 → 文字補抓 → 數值驗證」→ 顯著提升總 CLO 值擷取成功率，成為成功率提升的關鍵版本		單筆輸出可解析後，仍需支援長批次執行與結果管理

v4	整合完整 CLO 知識輸入、容錯解析、失敗紀錄、續跑機制與 Google Drive 輸出		完成可持續執行的最終批次流程

由表 D-1 可知，本研究的 CLO 推導是經由多次錯誤辨識與流程修正後逐步形成。前兩個版本主要處理輸出格式不穩定問題，版本 3 進一步處理 JSON 解析失敗與數值擷取困難，版本 4 則將單筆推論流程擴展為可批次執行的資料建構流程。此一演進過程顯示，CLO 推導結果並非完全依賴模型自由生成，而是透過輸出規格、容錯解析與後處理規則逐步提高資料建構的穩定性。

D.2 CLO 推導目的與合理範圍設定

本研究使用 CLO 值的目的，在於提供一個可比較、可解釋且具物理意義的條件尺度，作為後續熱舒適推估與條件化描述生成的中介基準，而非追求生理層級的精密熱舒適預測。因此，本文於 CLO 推導後進行有效樣本判定、分布檢查與異常值處理，並將 0–3 clo 作為離群樣本重新推論後的驗收範圍。相關控管規則整理如表 D-2 所示。

表 D-2、CLO 合理範圍與異常值處理規則

控管項目	設定內容	目的
有效樣本判定	總 CLO 值可轉換為數值，且 $CLO \geq 0$	排除無法解析的結果與不具物理意義的負值
重新推論驗收範圍	$0.0 \leq$ 新生成 CLO 值 ≤ 3.0	判斷離群樣本重新推論後是否可覆寫原值
分布檢查方式	計算有效樣本的 IQR	檢查批次輸出是否存在偏離整體分布的樣本
離群判定規則	低於 $Q1 - 1.5 \times IQR$ 或高於 $Q3 + 1.5 \times IQR$ 者標記為離群值；實際下界限制為不小於 0	標記可能受到單次生成不穩定影響的樣本
離群處理方式	回溯原始穿搭內容並重新執行推論	降低極端輸出對後續熱舒適推估與描述生成的影響
覆寫規則	新值通過重新推論驗收範圍則覆寫；否則保留原始紀錄並累計失敗紀錄	維持資料修正流程的可追溯性

由表 D-2 可知，本研究對 CLO 推導結果採取兩層次控管。第一層為有效樣本判定，系統先將總 CLO 值轉換為數值型態，並排除無法解析或小於 0 的結果，以確保後續分布統計建立於具有基本物理意義的數值資料。第二層為 IQR 分布檢查，用以標記相對於整體資料分布明顯偏離的樣本。考量 ASHRAE Standard 55 與 ISO 7730 所涵蓋的服裝保暖性分析範圍多約落於 0–1.5 clo 至 0–2 clo 之間，而本文使用 CLO 的目的並非進行高精度熱舒適判定，因此本研究將 $0.0 \leq CLO \leq 3.0$ 設為離群樣本重新推論後的驗收範圍。須說明的是，該範圍並非最終資料分布的硬性上限；若離群樣本重新推論後仍未通過驗收，系統會保留原始紀錄並累計失敗紀

錄，而不直接刪除或裁切該筆資料。被標記的離群值不直接等同於錯誤，而是作為重新推論或後續檢查的候選，以降低單次生成極端值對後續流程的影響。

D.3 CLO 推導與後處理流程

圖 D-1 說明本研究 CLO 推導與後處理流程。此流程可作為表 D-2 所列控管規則的操作化步驟，呈現從原始套裝資料輸入、模型推導、結構化解析、有效樣本判定、IQR 分布檢查，到離群樣本重新推論與驗收輸出的完整流程。

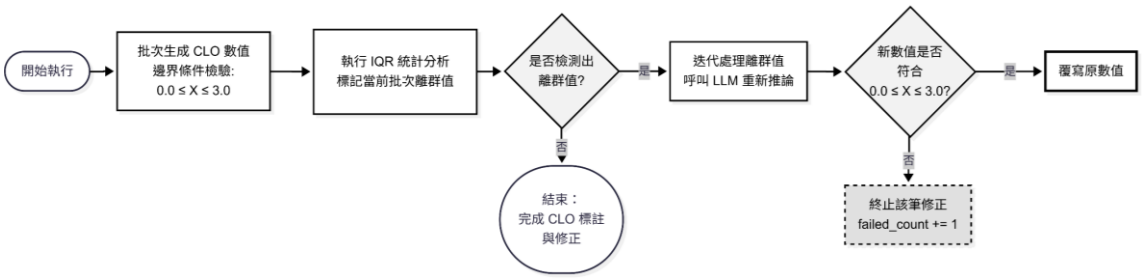


圖 D-1、CLO 推導與後處理流程

圖 D-1 顯示本研究的 CLO 推導與後處理流程。本研究首先批次生成套裝層級的 CLO 數值，並將模型輸出結果解析為結構化資料。完成批次生成後，系統讀取所有已產生的 CLO 值，將可轉換為數值且不小於 0 的結果視為有效樣本，並據此計算 IQR。本研究以 $Q1 - 1.5 \times IQR$ 與 $Q3 + 1.5 \times IQR$ 建立當前批次的離群值判定範圍；其中，由於 CLO 值不具負值意義，實際下邊界限制為不小於 0。接著，系統將低於下界或高於上界的樣本標記為候選離群值，並回溯原始穿搭資料逐筆呼叫 LLM 重新推論。若重新生成的 CLO 值符合 $0.0 \leq CLO \leq 3.0$，則以新值覆寫原數值；若重新生成失敗，或新值仍不符合上述驗收範圍，則保留原始紀錄並累計失敗紀錄。本研究可依據修正後結果視需要再次執行相同流程，以逐步降低極端輸出對整體分布的影響。須說明的是，此流程並非將所有 CLO 值強制裁切至 0–3 之間，而是透過離群值偵測與重新推論，使標註結果盡可能維持於合理且可解釋的範圍內。此流程可降低單次生成結果對後續熱舒適推估與條件化描述生成造成偏差的可能性，並提升 CLO 標註資料的一致性、可解析性與可追溯性。

D.4 CLO 個案檢視

為輔助說明 CLO 推導結果與穿搭圖像之間的對應關係，本研究保留少量樣本進行個案檢視。此處的個案檢視僅作為流程合理性的輔助說明，不作為正式量化評估結果；正式的分布檢查與資料品質評估仍以批次統計與後續生成資料品質評估為準。以下選取兩筆樣本，分別說明中等保暖程度與較高保暖程度穿搭在 CLO 推導結果上的差異。



圖 D - 2、範例一：中等保暖程度穿搭

圖 D - 2 為樣本編號 192259368 的 CLO 推導個案。該樣本模型輸出的總 CLO 值為 0.760，最接近的參考值為 0.74 clo，其參考組合為「長袖運動衫與運動長褲」(sweat pants, long-sleeve sweatshirt)。此類參考穿著通常具有上半身與下半身完整覆蓋的特徵，但並非厚外套或多層疊穿結構，因此可視為日常或輕活動情境中的中等保暖程度。從本樣本圖像觀察，該套裝包含無袖上衣、長版格紋外層、貼身長褲、帆布鞋與配件。雖然其單品形式不同於參考組合中的長袖運動衫與運動長褲，但兩者在熱舒適角度上具有相近的覆蓋與保暖結構：下半身皆由長褲提供完整覆蓋，上半身則由外層衣物或長袖運動衫提供主要保暖效果。因此，本樣本推導出 0.760 clo，與 0.74 clo 參考值相近，具有方向上的合理性。



圖 D - 3、範例二：較高保暖程度穿搭

圖 D - 3 為樣本編號 220721299 的 CLO 推導個案。該樣本模型輸出的總 CLO 值為 1.150，最接近的參考值為 1.14 clo，其參考組合為「長褲、長袖襯衫、西裝外套、背心與 T-shirt」(trousers, long-sleeve shirt plus suit jacket, vest, T-shirt)。此類參考穿著具有明顯的多層次結構：下半身由長褲完整覆蓋，上半身則由 T-shirt、背心、長袖襯衫與外套共同形成多層覆蓋，因此相較於單層長袖上衣或一般

輕便外層，整體保暖程度較高。從本樣本圖像觀察，該套裝主要由長袖牛仔材質洋裝構成，雖然並非參考組合中的典型多件式西裝穿搭，但其衣物覆蓋範圍包含上半身、手臂與腿部部分區域，且牛仔材質相較於一般輕薄布料具有較高厚度與結構感。因此，該樣本在整體保暖程度上高於圖 D-2 的格紋外層搭配長褲案例，模型推導出 1.150 clo 具有方向上的合理性。然而，由於本樣本與參考組合在單品形式與層次結構上仍有差異，尤其參考組合是由多件衣物疊穿形成保暖效果，而本樣本主要由單件長袖洋裝提供覆蓋與材質厚度，因此此數值應被視為條件尺度上的近似估計，而非精確的生理量測結果。此案例可說明模型推估總 CLO 值時，並非僅比對單品名稱，而是依據整體覆蓋面積、材質厚度、層次結構與保暖效果進行近似判斷。

由上述兩個案例可見，CLO 推導結果可大致反映穿搭中衣物覆蓋程度、材質厚度與保暖層次的差異。範例一以外層襯衫與長褲形成中等保暖層次，範例二則因長袖牛仔材質洋裝呈現較高保暖傾向。此類個案檢視的目的不在於證明每筆 CLO 標註均完全精準，而是用以確認模型推導結果在方向上能與視覺線索及參考資料形成合理對應。

D.5 CLO 標註分布穩定性檢查

除個案檢視外，本研究亦透過整體分布檢查，觀察 CLO 批次標註結果是否呈現合理集中趨勢，並確認是否仍存在需後續檢查的高值樣本。圖 D-4 顯示有效樣本的 CLO 分布情形，包含直方圖、不同資料切分的分布、IQR 邊界與箱型圖；表 D-3 則彙整 CLO 標註結果的描述性統計。此處所稱有效樣本，係指可成功解析為數值且不小於 0 的 CLO 結果，並不代表所有樣本皆被強制限制於 0–3 之間。

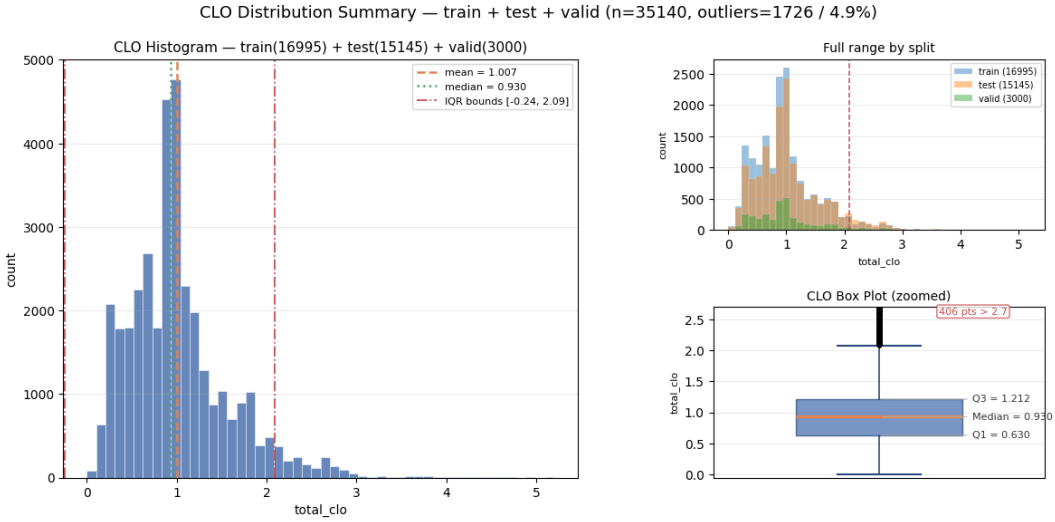


圖 D-4、CLO 標註分布摘要

圖 D-4 呈現本研究有效樣本的 CLO 分布情形。從直方圖可見，資料主要集中於 0.6 至 1.2 clo 左右，平均值約為 1.0 clo，中位數約為 0.93 clo，顯示多數樣本位於日常穿搭常見的中低至中等保暖範圍。右側雖存在長尾分布與少數高值樣本，但此類樣本可透過 IQR 規則標記為離群值，並作為重新推論或後續檢查的候選。由於本研究採取的是重新推論式修正，而非硬性裁切或刪除，因此最終分布中

仍可能保留少數未成功修正的高值紀錄。箱型圖亦顯示主要資料集中於箱體範圍內，說明整體標註結果並未呈現完全發散或大規模不合理偏移。

表 D - 3、CLO 標註分布統計摘要

欄位	數值 （Value）
總有效筆數	35,140
平均值	1.0066
標準差	0.5586
最小值	0
第一四分位數 （25%）	0.63
中位數 （50%）	0.93
第三四分位數 （75%）	1.2125
最大值	5.2
四分位距 （Q3 - Q1）	0.5825
IQR 下邊界	-0.2437
IQR 上邊界	2.0862
離群值數量	1,726

根據表 D - 3，CLO 標註結果共有 35,140 筆有效樣本，平均值為 1.0066，中位數為 0.9300，Q1 與 Q3 分別為 0.6300 與 1.2125，顯示主要樣本集中於 0.6 至 1.2 clo 左右。IQR 上界為 2.0862，超出此範圍的離群樣本共 1,726 筆。表中最大值為 5.2，表示資料中仍保留少數高值紀錄；此情形反映本研究採重新推論與驗收機制，而非將所有結果強制裁切至 0–3 clo。這些離群樣本不直接等同錯誤，而是作為後續檢查的候選，以降低極端標註值對後續流程的影響。

綜合圖 D - 4 與表 D - 3 可知，CLO 批次標註結果具有一定集中性與可解釋性。多數樣本分布於中低至中等保暖區間，與日常穿搭資料的預期特性相符；少數高值樣本則透過 IQR 規則被標記，以供重新推論與後續檢查。由於本研究並未對 CLO 結果進行硬性裁切，少數高值紀錄仍被保留於資料中，以維持修正流程與原始輸出的可追溯性。整體而言，此結果支持本文將 CLO 作為後續條件生成、熱舒適推估與推薦結果解釋的中介尺度。

D.6 小結

綜合表 D - 1 至表 D - 3 與圖 D - 1 至圖 D - 4 可知，本研究的 CLO 推導流程由初始自由生成逐步修正為具固定輸出格式、容錯解析、IQR 離群值檢查、重新推論驗收與批次紀錄保存的受控流程。表 D - 1 說明提示工程版本演進，表 D - 2 與圖 D - 1 說明異常值處理機制，圖 D - 2 與圖 D - 3 則透過個案檢視呈現模型輸出與穿搭保暖層次的對應關係。圖 D - 4 與表 D - 3 則呈現整體 CLO 標註分布的集中性、離群值檢查結果，以及少數高值樣本保留的情形。由於本文使用 CLO 作為條件生成與結果解釋的中介尺度，而非精確生理量測結果，因此 0–3 clo 主要作為離群樣本重新推論後的驗收標準，並非最終資料分布的強制裁切上限。整體而言，上述控管流程可提升 CLO 標註的一致性、可解析性與可追溯性，並作為正文第 3.4 節資料建構控管與可重現性的補充依據。

附錄 E

為提升本研究在活動代謝率標註上的一致性、可解釋性與批次執行穩定性，本研究於實作過程中歷經多次提示工程調整，逐步由初始的活動自由配對流程，修正為具候選活動清單限制、穿搭情境判斷、字串完全匹配、相似度輔助校正與錯誤重試機制的活動對應流程。本附錄旨在補充正文第 3.4 節所述的資料建構控管與可重現性內容，說明 MET 標註流程如何由原型階段發展為可持續執行的研究流程。

E.1 MET 標註目的與活動對應邏輯

本研究使用 MET 值的目的，在於為模型所判定的活動提供相對應且較為適切的活動強度數值，使不同穿搭情境下的活動結果具有可比較性與可解釋性。此處的 MET 並非直接作為描述生成目標，亦非追求個體層級的精確能量消耗估計，而是作為後續熱舒適推估與條件化描述生成的中介尺度。

與 CLO 推導不同，本研究中的 MET 值並非由模型直接自由生成，而是先由 LLM 根據套裝描述、單品資訊與圖片，從預先整理的活動清單中選出最貼切的活動，再透過活動對照表映射為相對應的 MET 數值。因此，在合理範圍上，MET 值受到活動參考表限制，不會出現任意生成或超出資料表定義範圍的情況；在異常處理上，真正需要控管的並非數值本身的離群，而是活動判定是否能與穿搭情境形成合理對應。若模型輸出的活動不在清單內、無法合法映射，或與穿搭在場合、環境及移動強度上明顯不一致，則視為異常結果並進行重新判定。

E.2 MET 提示工程版本演進

表 E-1 彙整本研究在 MET 活動對應流程中的提示工程版本演進。初始版本主要將任務設定為活動強度推估，模型容易將問題理解為一般熱舒適或運動強度判斷，而非穿搭所對應的日常場合與活動。後續版本逐步將任務修正為「穿搭與活動配對」，並加入活動清單限制、候選排序、活動清單前處理、場合正式度判斷、移動性判斷、環境配適，以及字串完全匹配與相似度輔助校正，使 MET 標註流程由自由活動聯想，逐步修正為受控的活動選擇與數值映射流程。

表 E-1、MET 提示工程版本演進

版本	版本資訊	PROMPT 改動	問題
v1	建立基本活動對應流程，輸入套裝描述、單品、活動清單與圖片，直接預測單一活動並以 JSON 輸出。	System Prompt：You are a clothing thermal comfort expert. Select the most relevant activity from the activity list. Output the result in JSON format: {"activity": "string from activity list"}	角色設定與任務不完全對齊。模型容易將問題理解為熱舒適或活動強度推估，而非穿搭所對應的場合與活動，因此常偏向 Bicycling、Aerobic 等運動類活動。

v2	將任務明確改寫為穿搭與活動配對，並要求模型先讀取完整活動清單，再根據套裝描述、單品文字與圖片進行判斷。	System Prompt：You are a fashion activity-matching expert. Carefully read and remember all options listed in Available Activities... Choose the single most relevant activity from the given list... Output exactly as {"activity": "string from activity list"}	修正任務定義，但未定義判斷邏輯。模型仍多半依賴表面語意聯想，容易受到清單排序影響，或選出過於泛化的活動 。
v3	加入可見推理、候選排序、活動清單前處理，以及正式穿搭需優先考慮場合型活動等限制。同一類型且 MET 值相同的活動僅保留一筆，以縮減候選空間。	System Prompt：要求模型讀取完整活動清單、忽略清單順序、依據套裝描述與圖片產生 TOP-5 候選，並最後以 JSON 輸出第一順位活動。	雖然加強了輸出控制與候選整理，但仍未真正改善判斷核心。模型仍可能落到 Sitting quietly, general、Sitting meetings... 等泛用活動，顯示仍缺少明確的穿搭判斷流程。
		User Prompt：加入 PART A 推理與 TOP-5，最後再輸出 PART B JSON。	
		Activity data：活動清單改為排序與篩選後版本。	
v4	將任務改寫為穿搭領域的決策流程，並加入驗證與重試機制，為成功率提升的關鍵版本。	System Prompt：要求模型以穿搭領域活動配對專家角度判斷，依序考量 Occasion Parity Gate 、Mobility Gate、Environment Gate，並優先選擇活動清單中字串完全相符的活動。	將 prompt 轉化為穿搭判斷流程：先以場合正式度過濾，再評估鞋款與可移動性，再判斷環境條件相符程度，最後經驗證後輸出可合理映射的活動。相較前三版，首次有效抑制了 generic sitting 類活動的過度吸附，也使結果更適合批次執行與錯誤重試。
		User Prompt ：則改由 create_user_prompt( ) 動態生成；輸出包含 PART A 推理與 PART B JSON，且若前一次 activity invalid，下一次不得重複相同錯誤答案。	

由表 E-1 可知，本研究的 MET 標註流程並非單純要求模型輸出活動名稱，而是經由多次提示工程修正，逐步建立活動清單限制與情境判斷規則，前兩個版本主要處理任務定義不清的問題，使模型由一般活動強度推估轉向穿搭與活動配對；版本三進一步透過候選排序與活動清單前處理降低重複候選干擾；最終的版本則將判斷流程規則化，要求模型依序檢查場合、移動性與環境條件，並於輸出前確認活動名稱能與清單項目完全對應。此一演進過程顯示，本文對 MET 的控管重點在於活動選擇過程，而非修正模型自由生成的數值。

E.3　活動清單控管與 MET 對應流程

本研究的 MET 標註流程係以候選活動清單作為合法輸出範圍，並透過穿搭情境判斷與活動對照表映射，建立可追溯的活動強度標註結果。與 CLO 推導不同，MET 值並非由大型語言模型直接生成，而是先由模型根據套裝描述、單品資訊與圖片判斷最可能對應的活動，再依據活動對照表映射為相對應的 MET 數值。因此，本文的控管重點不在於數值層面的離群修正，而在於活動選擇是否合理、是否存在於候選活動清單中，以及是否能正確映射至對應的 MET 值。為降低重複活動與相似候選造成的干擾，本文於活動對應前先進行活動排序、候選篩選，並針對同一類型中相同 MET 值的活動保留代表項目，使模型能更聚焦於場合正式度、鞋款可移動性、環境配適性與配件線索等穿搭語意。相關控管規則整理如表 E-2 所示。

表 E-2、MET 活動對應控管規則

控管項目	設定內容	目的
活動輸出限制	模型只能從 Available Activities 中選擇活動	避免模型自行創造活動名稱
合法對應規則	以活動名稱與候選活動清單的字串完全匹配作為主要判定方式；若無法完全匹配，則以字串相似度輔助修正至清單中語意最接近且合理的合法活動項目	確保活動能合法映射至對應 MET 值
活動清單前處理	對活動清單進行排序、篩選，並針對同類型且相同 MET 值的活動保留代表項目	降低重複活動與相似候選造成的判斷干擾
判斷依據	綜合考量場合正式度、鞋款與移動性、環境配適、配件與負重線索	使活動選擇更符合穿搭所隱含的實際使用情境
無效輸出處理	若活動不在清單內、無法映射，或與穿搭情境明顯不符，則重新判定	排除無法追溯或不合理的活動標註

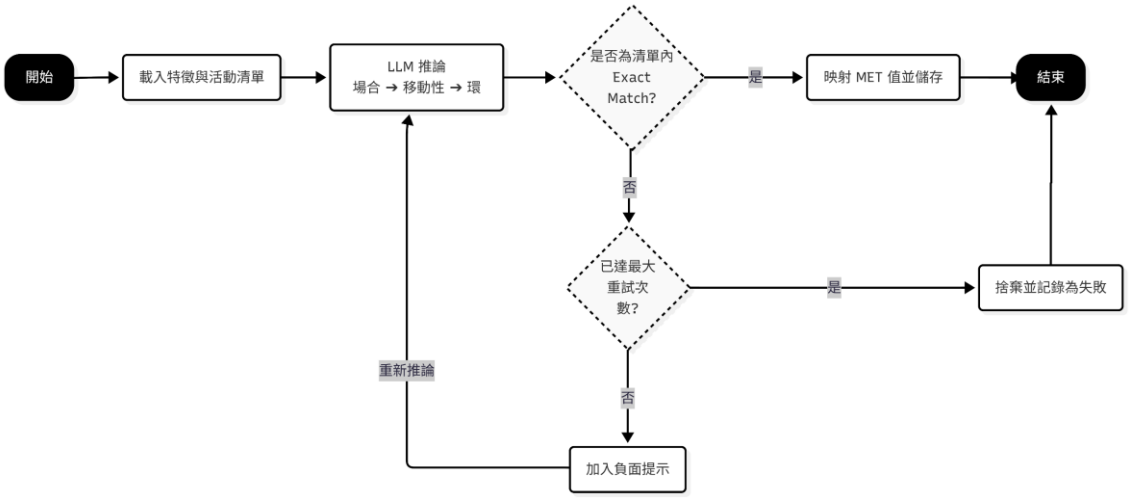


圖 E-1、MET 活動對應與後處理流程

圖 E-1 進一步呈現 MET 活動對應的實作流程。首先，系統載入穿搭特徵與候選活動清單，作為模型判斷依據。接著，模型依據場合、移動性與環境等線索推論最可能活動。若輸出活動能與候選活動清單完成字串完全匹配，或經相似度輔助校正後可對應至合法活動項目，則系統依活動對照表映射 MET 值並儲存結果；若無法匹配，則判斷是否已達最大重試次數。尚未達上限時，系統加入負面提示並重新推論；若已達上限，則放棄該筆樣本並記錄為失敗。

由表 E-2 與圖 E-1 可知，本文對 MET 的品質控管核心在於活動選擇與合法映射，而非模型自由生成數值。透過候選活動清單限制、字串完全匹配與相似度輔助校正、錯誤重試與失敗紀錄，本研究可保留活動語意、穿搭情境與活動強度之間的對應關係。

E.4 MET 個案檢視

為輔助說明 MET 活動對應流程，本研究保留部分樣本進行個案檢視，觀察模型能否依據穿搭圖像、鞋款、配件與場合線索，選出可與候選活動清單匹配的活動並映射為 MET 值。另因活動清單部分名稱包含特定場域，例如教堂、儀式或典禮等描述，本文採用時主要取其活動型態與活動強度意義，而非將樣本限定於該場域。



圖 E-2、範例一：正式場合與低活動強度

圖 E-2 為樣本編號 222313602 的 MET 活動對應案例。該套裝包含手拿包、高跟鞋、耳飾與條紋洋裝，整體呈現較正式、精緻且偏室內場合的穿搭特徵。從活動推論角度來看，高跟鞋與手拿包雖能支援短距離移動，但不適合長時間步行或高活動量情境；洋裝與配件則強化其正式場合屬性。因此，模型在推理過程中將活動強度判定為低至中等，並認為此穿搭較適合靜態或低移動性的正式活動。

在輸出結果中，模型選擇的活動為「參與儀式或典禮時安靜坐著」相關項目，原始活動名稱為 *Sitting in church, in service, attending a ceremony, sitting quietly*。該活動成功與候選活動清單精確匹配，並映射為 MET 1.0。此活動雖以教堂或典禮情境作為名稱，但其核心意義為正式場合中安靜坐著的低活動強度狀態。就穿搭語意而言，本案例的正式洋裝、高跟鞋與手拿包皆與低移動性、室內、儀式性場合相符，因此該 MET 對應結果具有合理性。



圖 E-3、範例二：商務休閒與中低活動強度

圖 E-3 為樣本編號 213647311 的 MET 活動對應案例。該套裝包含運動鞋、包款、上衣與長褲，整體呈現商務休閒與都市外出之間的穿搭特徵。從活動推論角度來看，運動鞋提供一定程度的步行與移動能力，包款亦暗示外出或通勤情境；然而，上衣與長褲的搭配仍帶有較正式或辦公情境線索，並非明顯運動或高活動量穿搭。因此，模型將活動強度判定為低至中等，並將場合屬性判定為中等正式，環境則較接近都市或辦公場景。

在輸出結果中，模型選擇的活動為「參與儀式或典禮時坐著，並有談話或歌唱等參與行為」相關項目，原始活動名稱為 *Sitting in church, talking or singing, attending a ceremony, sitting, active participation*。該活動成功與候選活動清單精確匹配，並映射為 MET 1.8。相較於圖 E-2 中安靜坐著的 MET 1.0，本案例因包含談話、歌唱或主動參與等輕度活動，因此對應至較高的 MET 值。此結果顯示，模型在判斷時同時考慮鞋款帶來的可移動性、服裝整體場合屬性與活動參與程度，使其活動強度高於靜態坐姿案例，但仍低於明顯步行或運動情境。

綜合上述兩個案例可見，MET 標註結果並非直接由模型生成數值，而是先依據穿搭圖像與單品線索推論活動情境，再由活動清單映射至對應 MET 值。兩個案例皆成功完成活動名稱逐字匹配，並能在活動強度上反映穿搭所暗示的移動程度與場合屬性。個案檢視的目的不在於證明每一筆 MET 標註皆完全精準，而是輔助確認模型是否能將穿搭語意合理對應至候選活動清單中的活動項目。

E.5 小結

綜合前述圖表可知，本研究的 MET 標註流程由初始活動自由配對，逐步修正為具候選活動清單限制、穿搭情境判斷、字串完全匹配、相似度輔助校正、錯誤重試與失敗紀錄保存的受控流程。表 E-1 說明提示工程版本演進，表 E-2 與圖 E-1 說明活動清單控管與 MET 對應流程，圖 E-2 與圖 E-3 則透過個案檢視，輔助說明模型如何根據穿搭圖像、鞋款、配件與場合線索推論活動情境。與 CLO 推導相比，MET 標註的主要風險不在於模型生成不合理的連續數值，而在於活動判斷是否符合穿搭情境。因此，本文對 MET 的控管重點在於活動選擇是否合理、是否能對應至候選活動清單中的合法活動項目，以及是否能透過活動對照表形成可追溯的 MET 標註。整體而言，上述流程可提升 MET 標註的一致性、可解釋性與可重現性，並作為正文第 3.4 節資料建構控管與可重現性的補充依據。

附錄 F

為提升本研究在套裝標題生成上的條件一致性、格式穩定性與批次執行可解析性，本研究於實作過程中歷經多次提示工程調整，逐步由初始的自由標題生成流程，修正為結合熱舒適條件、圖片視覺語意與固定輸出規格的條件化標題生成流程。本附錄旨在補充正文第 3.4 節所述的資料建構控管與可重現性內容，說明本研究如何將 CLO、MET 與熱舒適推估結果轉換為可供後續推薦模型使用的情境感知文字條件。

F.1 套裝描述改寫目的與條件來源

本研究進行套裝描述改寫的目的，在於將原始 Polyvore 套裝標題或描述，轉換為同時包含穿搭風格與情境感知條件的文字輸入，使後續推薦模型在訓練與推論時能接收更明確的天氣、場合與穿搭語意。此處的標題生成並非單純美化原始描述，也不是任意擴寫穿搭內容，而是將前階段資料工程所推導的 CLO、MET 與熱舒適條件，轉換為簡短且可被模型使用的條件化標題。本研究中，「套裝描述改寫」係指透過大語言模型將原始套裝標題或描述轉換為條件化文字的資料建構流程；而「套裝標題生成」則指此流程最終輸出的一行式條件化標題。換言之，前者強調改寫任務本身，後者強調生成後的資料形式。

標題生成流程可分為兩個階段。第一階段為 T_{sub} 主觀舒適溫度計算；其中，T_{sub} 表示在特定衣物保暖程度與活動強度條件下所對應的主觀舒適溫度，本研究以總 CLO 值與 MET 值作為輸入，計算每筆套裝樣本的 T_{sub}，並於程式欄位中記為 TSUB_target_C。此階段不使用大型語言模型。第二階段為套裝描述改寫，將套裝圖片、原始套裝資訊與 T_{sub}輸入 Gemini 或 Gemma 模型，使模型根據圖片中的風格、材質、層次、顏色與配件線索，生成符合溫度條件與穿搭氛圍的套裝標題。

表 F - 1、條件化標題生成階段

階段	名稱	方法	是否使用 LLM
1	主觀舒適溫度計算	使用總 CLO 值與 MET 值計算主觀舒適溫度，作為標題生成的溫度條件	否
2	套裝描述改寫	輸入套裝圖片、原始套裝資訊與主觀舒適溫度，由 Gemini 或 Gemma 生成條件化標題	是

由表 F - 1 可知，本研究並非直接要求模型自行推測適合溫度，而是先根據 CLO 與 MET 計算出具物理意義且可追溯的主觀舒適溫度，再將此結果作為標題生成的條件輸入。此設計可降低標題生成時對模型自由推測的依賴，使生成後標題能與衣物保暖指數、活動強度與熱舒適推估結果形成一致關係。

F.2 套裝描述改寫提示工程版本演進

表 F-2 彙整本研究在套裝描述改寫流程中的提示工程版本演進。初始版本主要要求模型根據圖片與原始套裝資訊產生自然標題，但輸出容易過於自由，包含解釋文字、描述段落或格式不一致等問題。後續版本逐步加入 T_{sub} 主觀舒適溫度、CLO 與熱舒適邏輯，以及圖片視覺語意判斷，使標題生成由自由命名逐步修正為具溫度條件、穿搭語意與固定輸出方向的流程。

表 F-2、套裝描述改寫提示工程版本演進

版本	版本資訊	PROMPT 改動	問題
v1	建立初始標題生成流程，輸入套裝圖片與原始套裝資訊，讓模型產生新的標題	初始 prompt 僅要求模型根據圖片與套裝資訊產生自然的服裝標題	輸出過於自由，模型容易產生解釋文字、描述段落，或格式不一致的標題，後續難以批次解析與存檔
v2	將 T_{sub} 主觀舒適溫度正式納入標題生成，並要求標題以溫度條件開頭	新增建議溫度條件，並要求標題以溫度開頭，使模型根據 T_{sub} 生成符合熱舒適條件的穿搭標題	標題開始與熱舒適條件產生關聯，但模型仍可能出現 °C / ℃ / ° C 等溫度格式不一致問題
v3	加入 CLO 與熱舒適邏輯推理，讓模型在生成標題前考慮溫度、CLO 與穿搭是否合理	新增 CLO，並要求模型反映溫度、CLO 值與套裝之間的實用邏輯，同時引導模型根據溫度、CLO 與圖片推測合理的穿搭情境	模型較能避免產生「高 CLO 卻描述成炎熱透氣」或「低 CLO 卻描述成寒冷保暖」這類矛盾標題
v4	強化圖片視覺語意與搜尋語句品質，形成最終 prompt 方向	新增要求模型根據圖片中的風格、材質、層次、顏色、配件判斷天氣感受、穿搭氛圍或隱含場景；避免列成單品清單，並只輸出最終標題	標題更接近使用者搜尋語句，也避免生成單品清單或多餘說明

由表 F-2 可知，本研究的套裝描述改寫流程並非一次性自由生成，而是經由多次提示詞修正後，逐步強化溫度格式、熱舒適邏輯與圖片語意控制。前兩個版本主要處理輸出格式與溫度條件納入問題，版本三進一步處理 CLO 與溫度語意矛盾，最終版本則強化圖片視覺語意，使標題更接近使用者可能輸入的查詢語句。

F.3 條件化標題生成與控管流程

本研究的條件化標題生成流程，以 T_{sub} 主觀舒適溫度作為情境感知條件，並結合套裝圖片與原始套裝資訊，使模型生成兼具溫度、風格與穿搭氛圍的標題。為避免標題變成單品羅列或一般描述段落，最終提示詞要求模型只輸出一行標題，並避免加入多餘解釋文字。標題需以統一溫度格式開頭，例如 26.1°C 或 16°C，以確保後續批次資料可解析與比較。

在生成邏輯上，模型需先根據 T_{sub} 判斷該套裝所對應的天氣感受，例如偏暖、溫和、涼爽或寒冷；接著結合 CLO 值所代表的衣物保暖程度，以及圖片中可觀察到的風格、材質、層次、顏色與配件線索，形成簡潔且符合穿搭情境的標題。此流

程的核心並非單純美化原始文字條件，而是使生成結果能反映「溫度條件、CLO 保暖程度與穿搭內容之間是否合理」。例如，高保暖程度的套裝不應被描述成炎熱透氣，低保暖程度的套裝也不應被描述成寒冷保暖。此外，本研究將標題生成視為一種受控的內隱推理流程。其設計邏輯可概括為：由於氣溫為 {temp:.1f}°C，可推測此時的天氣感受；在此溫度與天氣情境下，模型需參考圖片風格、套裝層次與 CLO 值，生成符合該溫度條件的穿搭標題。若原始資料、圖片語意或 MET 所代表的活動強度能支持特定活動或場合，模型可將其轉換為較概括的情境語意；若依據不足，則不得任意加入過度具體的場合、品牌、材質或人物身分等未受支持資訊。此推理過程僅作為標題生成時的內部依據，不得直接出現在最終輸出中。

為維持標題作為推薦模型文字條件的穩定性，最終標題應以整體風格、天氣感受與情境氛圍為主，而非逐一列出圖片中的所有單品。若需提及單品，應僅保留最能代表整體風格或熱舒適判斷的關鍵元素，避免標題退化為「上衣、裙子、鞋子、包包」等單品羅列。相關控管規則整理如表 F - 3 所示。

表 F - 3、套裝標題生成控管規則

控管項目	設定內容	目的
溫度條件輸入	使用 T_{sub} 作為標題生成的溫度條件	使標題與熱舒適推估結果產生關聯
溫度格式限制	標題以統一格式呈現，例如 26.1°C	避免 °C、℃、°C 等格式混用，提升批次解析穩定性
圖片語意判斷	根據風格、材質、層次、顏色與配件判斷穿搭氛圍	使標題反映圖像中的整體穿搭語意
熱舒適邏輯	標題需符合溫度、CLO 與穿搭保暖程度之間的合理關係	避免產生與熱舒適條件矛盾的標題
單品羅列限制	標題不得逐一列出多個具體單品，例如上衣、褲子、鞋子、包包等；若需提及單品，應僅保留最能代表整體風格的關鍵元素	避免標題退化為單品清單，使其更接近使用者查詢語句
情境推論限制	活動或場合需依據原始描述、圖片語意或 MET 所代表的活動強度輔助判斷；若依據不足，則使用較概括的情境語意	避免模型任意創造特定場合或活動，使標題推論更具依據
未受支持資訊限制	不得加入圖片或原始資料中無法支持的品牌、精確材質、特定場合、人物身分或過度具體情境	降低幻覺內容，維持標題與資料來源的一致性
輸出限制	僅輸出最終標題，不輸出解釋段落或單品清單	提升後續批次解析與模型訓練資料一致性
搜尋語氣	標題應接近使用者查詢語句，而非完整文章式描述或廣告文案	使生成後標題更適合作為推薦模型的文字條件

圖 F - 1 呈現套裝標題生成的整體流程。首先，系統讀取前階段產生的總 CLO 值與 MET 值，計算 T_{sub}主觀舒適溫度；接著將該溫度條件與套裝圖片、原始套

裝資訊一併輸入模型，由模型生成條件化標題。生成後，系統檢查標題是否符合溫度格式、是否僅輸出最終標題、是否避免單品羅列、是否存在未受支持資訊，以及是否存在明顯的熱舒適語意矛盾。符合條件者寫入最終資料；若不符合，則作為後續檢查或重新生成的候選。

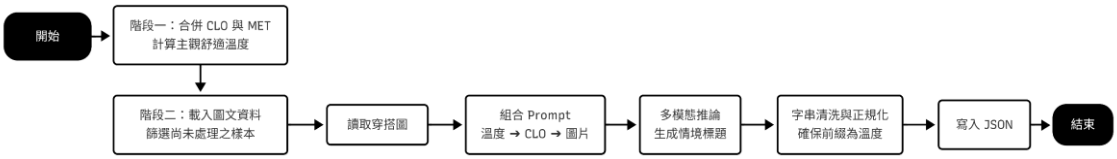


圖 F - 1、套裝標題生成與控管流程

F.4 套裝標題生成個案檢視

為輔助說明條件化標題生成結果，本研究保留部分樣本進行個案檢視。此處的個案檢視主要用以觀察生成後標題是否能同時反映溫度條件與穿搭視覺語意，而非作為正式量化評估結果。以下選取兩筆樣本，分別說明暖溫情境與涼爽秋季情境下的標題生成結果。

圖 F - 2 為樣本編號 127447981 的標題生成個案。該樣本原始描述為 Translucent Sunglasses，條件溫度為 26.1°C，生成後標題為 26.1°C, Effortless White Romance with Beachy Sparkle。從圖像內容觀察，該套裝包含白色包款、細跟鞋、白色上衣、白色裙裝、太陽眼鏡，以及具海洋或裝飾感的配件。整體色彩偏淺，材質與視覺氛圍較輕盈，與 26.1°C 的偏暖情境相符。生成後標題雖未逐一列出所有單品，但透過「白色浪漫」與「海灘感亮點」概括其視覺風格與配件語意，較原始描述更能反映整體套裝與環境條件。



圖 F - 2、範例一：暖溫情境與輕盈白色穿搭

圖 F - 3 為樣本編號 209492400 的標題生成個案。該樣本原始描述為 Fall Street Style，條件溫度為 16°C，生成後標題為 16°C, edgy urban fall vibes with a touch of rebellious cool。從圖像內容觀察，該套裝包含背包、長靴、白色裙裝與黑色外套，整體呈現較強的都市街頭感與秋季層次。相較於範例一的輕盈白色暖溫穿搭，本案例具有較明顯的外套、長靴與深色元素，更符合 16°C 涼爽情境。生成後標題保留原始秋季街頭風格，同時補入溫度條件與較具氛圍感的描述，使其更適合作為情境感知推薦模型的文字輸入。



圖 F - 3、範例二：涼爽秋季與都市風格穿搭

綜合上述兩個案例可見，條件化標題生成結果並非單純複製原始文字條件，而是根據熱舒適推估溫度與圖片視覺語意，重新形成具天氣感受與穿搭氛圍的文字條件。個案檢視的目的不在於證明每一筆標題皆完全精準，而是輔助確認模型是否能將溫度條件、穿搭風格與圖像線索整合為可用於推薦任務的簡潔標題。

F.5 小結

綜合前述，本研究透過套裝描述改寫進行條件化標題生成，其流程由初始自由生成，逐步修正為結合 *T*sub 主觀舒適溫度、CLO、MET、熱舒適邏輯、圖片視覺語意與固定輸出格式的受控流程。表 F - 1 說明條件化標題生成的兩階段架構，表 F - 2 說明提示工程版本演進，表 F - 3 與圖 F - 1 則說明標題生成控管規則與實作流程，圖 F - 2 與圖 F - 3 透過個案檢視呈現生成標題與溫度條件、穿搭風格的對應關係。整體而言，本研究並非僅要求模型生成自然標題，而是透過提示詞限制控制模型輸出範圍，包括溫度格式、單行輸出、避免單品羅列、避免未受支持的具體情境，以及不得輸出推理過程等規則。透過上述限制，標題生成結果得以維持為簡潔、可解析且較符合使用者查詢語氣的條件化文字。透過溫度格式控制、熱舒適邏輯檢查、圖片語意整合與輸出格式限制，本研究得以提升標題生成結果的一致性、可解釋性與可重現性，並作為正文第 3.4 節資料建構控管與可重現性的補充依據。

附錄 G

為補充正文第 3.5 節生成資料品質評估與第 4.2 節資料生成品質評估結果之方法依據，本附錄整理本研究所採用之 LLM-as-a-Judge 評估流程、提示工程版本演進、評分控管規則與個案檢視。由於套裝描述改寫屬於開放式生成任務，並不存在唯一標準答案，若僅依賴文字流暢度或單一整體分數進行判斷，將難以確認生成描述是否同時符合圖片內容、情境條件與使用者查詢語氣。因此，本研究透過檢核清單方式，要求模型根據套裝圖片與生成描述進行逐項判斷，以提升生成資料品質評估的一致性、可解釋性與可追溯性。

G.1 LLM-as-a-Judge 評估目的與流程

本研究使用 LLM-as-a-Judge 的目的，在於檢查生成後套裝描述是否符合圖片內容、環境條件與使用者查詢語氣。評估重點包含圖片和文字語意一致性、天氣與場合適切性、穿搭風格表達、查詢式語氣，以及是否避免加入圖片無法支持的幻覺內容。如圖 G - 1 所示，整體流程分為三個階段。第一階段建立一般檢核清單 C，由模型根據穿搭圖片與查詢式描述範例產生通用 yes/no 檢核項目。第二階段將 C 轉換為個人化且帶權重的檢核清單 C*，使評估標準更符合本研究需求。第三階段根據 C* 對每筆生成描述進行逐項評分，並輸出 decisions、feedback 與 rewrite。其中，decisions 用於呈現各檢核項目的 YES／NO 判斷，feedback 用於指出主要問題，rewrite 則作為可解釋性輔助輸出，用以呈現模型認為可如何修正描述，而非直接作為最終替換結果。

透過上述流程，本研究將開放式生成描述的品質評估轉換為可逐項檢查、可計算分數且具回饋依據的評估機制，使後續能更一致地判斷生成描述是否符合圖片內容與情境感知穿搭推薦需求。

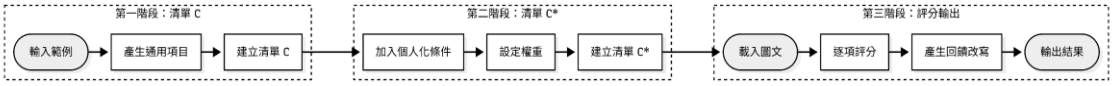


圖 G - 1、LLM-as-a-Judge 評分流程

G.2 LLM-as-a-Judge 版本演進

本研究之 LLM-as-a-Judge 流程經多次提示工程修正，主要分為兩部分：前兩階段的 Checklist 建立，以及第三階段的評分 prompt 設計。前者用於建立並權重化評估標準，後者用於控制模型如何根據 C* 進行評分、回饋與可解釋性改寫。

G.2.1 Checklist C 與個人化 Checklist C* 版本演進

表 G - 1 彙整一般檢核清單 C 與個人化檢核清單 C* 的提示工程版本演進。此階段修正重點在於將初始通用評估面向，逐步調整為符合本研究需求的加權檢核清單。由表 G - 1 可知，Checklist 建立流程由初始通用檢核項目，逐步修正為以圖片和文字語意一致性、天氣、風格與場合為主要依據的個人化加權檢核清單。

表 G - 1、Checklist C 與個人化 Checklist C* 提示工程版本演進

版本	版本資訊	PROMPT 改動	問題
v1	建立一般檢核清單 C	根據參考論文的 checklist 生成概念，先以 Factuality / Grounding 、 Coverage 、 Coherence、Clarity & Fluency 與 Query-style Register 作為上位評估準則，要求模型從多組穿搭圖片與查詢式描述範例中產生通用 yes/no 檢核清單	初始版本僅建立通用評估面向，尚未針對本研究所需的天氣、風格、場合、顏色與單品重要性進行權重區分
v2	建立個人化檢核清單 C*	將任務設定為由模型把一般檢核清單 C 轉換為個人化且帶有權重的 C*，為每個項目指定權重與分配語意類別	初始 C* 產生流程雖能建立權重，但尚未明確反映本研究對環境條件與穿搭情境的評估重點
v3	修正單品在評估中的角色	調整評估觀念：使用者查詢穿搭推薦時，不一定會知道或輸入具體單品，因此單品不應被視為核心條件，而應作為輔助性細節	若將單品列舉視為主要評分依據，會使任務偏向商品搜尋，而非根據天氣、風格與場合進行穿搭推薦
v4	釐清風格、顏色與品項的差異	將風格理解為整體視覺偏好或氛圍，例如單一色系、黑白金、柔和或酷帥；將顏色視為中等重要的視覺線索；將品項限定為具體服裝或配件	原先容易將風格、顏色與單品混在一起，導致檢核項目的語意層級與權重分配不清
v5	重新調整 C* 權重方向	將圖片和文字語意一致性設定為最高重要度，用以檢查描述是否貼合圖片內容，並避免加入圖片中無法支持的單品、顏色、圖案、材質或屬性；天氣、風格與場合設定為主要情境條件；顏色／主色調設定為中等重要；單品與設計細節則降為低重要度	需要避免模型因描述未列出具體單品而過度扣分，同時仍保留對圖片與文字是否一致、是否出現幻覺內容的檢查

G.2.2 評分 Prompt 版本演進

表 G - 2 彙整評分 prompt 的版本演進。此階段修正重點在於使模型能根據 C* 權重進行評分、回饋與改寫，並避免生成描述中出現圖片無法支持的內容。由表 G - 2 可知，Phase 3 評分流程由初始 yes/no 判斷，逐步修正為具權重感知、圖片依據與受控改寫的評估流程。此設計可降低模型將低重要度問題過度放大的情況，並提升評分結果與套裝圖片內容之間的一致性。

表 G - 2、階段三評分 Prompt 提示工程版本演進

版本	版本資訊	PROMPT 改動	問題
v1	建立初始評分流程	根據個人化 Checklist C*，要求模型針對套裝圖片與使用者查詢式描述進行 YES／NO 評分，並輸出 decisions、feedback 與 rewrite	初始版本僅要求模型依檢核清單評分，尚未明確規範模型應如何根據權重決定回饋與改寫幅度
v2	加入權重感知改寫規則	在 rewrite 規則中加入權重優先順序，要求模型優先修正高權重問題，例如圖片和文字語意不一致、天氣／風格／場合不足；低權重問題則僅需小幅修正	原本模型會將所有 NO 項目視為同等重要，導致低重要度的單品或細節問題也被大幅改寫
v3	限制模型過度補充單品	在 rewrite 中加入限制，要求模型避免列出過多具體單品或配件；若需補充顏色、圖案或服裝類型，必須是圖片中清楚可見的內容	模型容易將改寫結果變成單品清單，例如補入大量洋裝、鞋子、包包或配件，使描述偏離使用者查詢語氣
v4	強化圖片和文字語意一致性	在評分規則中明確要求所有 YES／NO 判斷必須以圖片可見內容為依據；若描述中出現圖片無法支持的單品、顏色、圖案、材質或屬性，則不得判定為一致	部分描述雖然語句自然，但可能加入圖片中不存在的元素，導致模型仍給出過高分數
v5	加入先觀察圖片的評分步驟	在 prompt 中要求模型先觀察套裝圖片，確認可見服裝、顏色與設計特徵，再閱讀描述並依 Checklist C* 評分	模型雖具備圖片理解能力，但在正式評分時可能未穩定將圖片內容作為判斷依據
v6	回到參考論文式 prompt 結構	將 prompt 調整回較接近參考論文的格式，保留 Task、Consistency definition、Checklist 的結構，並將一致性定義改為描述與套裝圖片之間的「圖片和文字語意一致性」	前一版本雖然較明確，但形式上與參考論文中的 LLM-as-a-Judge prompt 差距較大
v7	在 User Prompt 補強內部觀察流程	在 user_text 中加入兩步驟：先只根據圖片於內部辨識主要服裝、顏色與設計細節，再根據此觀察結果與文字描述進行 checklist 評分	僅在 System Prompt 要求模型看圖仍不夠穩定，因此於 User Prompt 再次強化「先觀察圖片，再評分」的流程

G.3 LLM-as-a-Judge 評分規則

本研究以個人化檢核清單 C* 作為評分依據，將生成描述品質轉換為逐項 YES／NO 判斷。此階段的評估重點在於確認描述是否符合圖片內容、情境感知條件與查詢語氣，並避免圖片無法支持的幻覺內容出現。可由表 G - 3 觀察到本研究之 LLM-as-a-Judge 評分並非單純判斷文字是否流暢，而是透過檢核清單與權重設定，將圖片和文字語意一致性、情境條件與查詢語氣納入結構化評估。此設計可降低模型僅依語句自然度給分的情況，使評分結果更能反映生成描述是否真正符合套裝圖片與推薦情境。

表 G - 3、LLM-as-a-Judge 評分控管規則

控管項目	設定內容	目的
評估依據	以套裝圖片、生成描述與個人化檢核清單 C* 作為評估依據	使評估同時考量圖像內容、文字語意與任務需求
圖片和文字語意一致性	描述不得加入圖片無法支持的單品、顏色、圖案、材質、品牌或屬性	降低生成描述中的幻覺內容
情境條件檢核	檢查描述是否包含合理的天氣／溫度、穿搭風格與使用場合	確認描述能回應情境感知穿搭推薦需求
權重化評分	依檢核項目重要性給予不同權重；圖片和文字語意一致性最高，天氣／風格／場合次之，顏色與查詢語氣為中等，單品與語句細節較低	使評分結果符合本研究重視情境與語意一致性的目標
單品細節限制	單品與配件僅作為輔助性細節，不作為主要評分依據	避免評估結果過度偏向單品列舉
回饋輸出	若檢核項目判定為 NO，模型需提供簡短修正建議，並優先指出高權重問題	協助判讀低分原因，作為後續人工檢視依據
可解釋性改寫	若描述存在不符合項目，模型產生一段小幅 rewrite，呈現可能的修正方向；此 rewrite 僅作為評分解釋，不直接替換原始資料	增強模型評分結果的可解釋性，使研究者能理解模型為何判定該描述需要修正
輸出格式限制	評估結果以固定結構輸出，包含逐項判斷、回饋與改寫結果	提升批次評估結果的一致性與可解析性

G.4 檢核清單展示

本段落分別展示 Qwen3-VL-32B-Instruct 與 Gemma-3-27B-it 所產生的原始檢核清單(表 G - 4 與表 G - 6)，以及依據研究評估需求進一步整理的加權檢核清單(表 G - 5 與表 G - 7)。原始檢核清單保留各模型產生的檢核項目與編號，用以呈現不同評分模型對描述品質的關注面向；加權檢核清單則將相關項目歸納為「視覺依據一致性」、「天氣、風格與場合」、「查詢口吻」及「清晰度與流暢度」四類，並依各類項目對本研究評估目標的重要程度給予不同權重。各檢核項目保留原始英文內容，以維持實際評估時所使用的清單形式。

表 G - 4、Qwen3-VL-32B-Instruct 原始檢核清單 C

編號	檢核項目
C1	Does the description include the temperature or weather condition relevant to the outfit?
C2	Does the description specify the overall style or theme of the outfit (e.g., beach chic, gothic, sporty)?
C3	Does the description mention the primary color scheme or key colors present in the outfit?
C4	Does the description indicate the occasion or context for which the outfit is suitable (e.g., date, wedding, night out)?
C5	Does the description capture the mood or aesthetic tone (e.g., effortless, glamorous, sophisticated)?
C6	Does the description reference the main garment or item that defines the outfit (e.g., dress, bikini, vest)?
C7	Does the description use concise, query-style language appropriate for a search or request?
C8	Does the description avoid introducing elements or details not visually present in the outfit collage?
C9	Does the description logically connect the visual elements into a coherent outfit narrative?
C10	Is the description grammatically correct and fluent, with natural phrasing for a user query?

表 G - 5、 Qwen3-VL-32B-Instruct 加權檢核清單 C^*

編號	檢核項目	權重	類別
C8	Does the description avoid introducing elements or details not visually present in the outfit collage?	4	視覺依據一致性
C1	Does the description include the temperature in °C and a qualitative thermal feeling (e.g., cool, warm, hot) relevant to the outfit?	3	天氣、風格與場合
C2	Does the description specify the overall style or theme of the outfit (e.g., beach chic, gothic, sporty)?	3	

C4	Does the description indicate the occasion or context for which the outfit is suitable (e.g., date, wedding, night out)?	3	
C3	Does the description mention the primary color scheme or key colors present in the outfit?	2	查詢口吻
C5	Does the description capture the mood or aesthetic tone (e.g., effortless, glamorous, sophisticated)?	2	
C7	Does the description use concise, query-style language appropriate for a search or request?	2	
C6	Does the description reference the main garment or item that defines the outfit (e.g., dress, bikini, vest)?	1	清晰度與流暢度
C9	Does the description logically connect the visual elements into a coherent outfit narrative?	1	
C10	Is the description grammatically correct and fluent, with natural phrasing for a user query?	1	

表 G - 6、Gemma-3-27B-it 原始檢核清單 *C*

編號	**檢核項目**
C1	Does the description mention key colors present in the outfit?
C2	Does the description identify the overall style or aesthetic of the outfit (e.g., casual, formal, bohemian)?
C3	Does the description include a temperature or season that aligns with the outfit's suitability?
C4	Does the description use adjectives that accurately reflect the outfit's mood or vibe?
C5	Does the description avoid making claims about the outfit that aren't visually apparent?
C6	Does the description use language a user would employ when searching for similar outfits?
C7	Does the description highlight any prominent textures or patterns in the outfit?
C8	Does the description suggest a potential occasion or activity suitable for the outfit?
C9	Is the description concise and avoids unnecessary details?
C10	Is the description grammatically correct and easy to understand?
C11	Does the description focus on the outfit as a whole, rather than individual items?
C12	Does the description avoid overly generic terms that could apply to many outfits?
C13	Does the description use descriptive words that are relevant to fashion and clothing?

C14	Does the description avoid subjective opinions (e.g., 'beautiful', 'ugly') and focus on observable features?
C15	Does the description accurately represent the overall impression of the outfit in the image?

表 G - 7、Gemma-3-27B-it 加權檢核清單 C^*

編號	檢核項目	權重	類別
C5	Does the description avoid making claims about the outfit that aren't visually apparent?	4	視覺依據一致性
C15	Does the description accurately represent the overall impression of the outfit in the image?	4	
C3	Does the description include a temperature or season that aligns with the outfit's suitability?	3	天氣、風格與場合
C8	Does the description suggest a potential occasion or activity suitable for the outfit?	3	
C2	Does the description identify the overall style or aesthetic of the outfit (e.g., casual, formal, bohemian)?	3	
C16	Does the description mention a specific temperature in °C?	3	
C6	Does the description use language a user would employ when searching for similar outfits?	2	查詢口吻
C1	Does the description mention key colors present in the outfit?	2	
C7	Does the description highlight any prominent textures or patterns in the outfit?	2	
C4	Does the description use adjectives that accurately reflect the outfit's mood or vibe?	2	
C10	Is the description grammatically correct and easy to understand?	1	清晰度與流暢度
C9	Is the description concise and avoids unnecessary details?	1	
C11	Does the description focus on the outfit as a whole, rather than individual items?	1	
C13	Does the description use descriptive words that are relevant to fashion and clothing?	1	
C12	Does the description avoid overly generic terms that could apply to many outfits?	1	

由表 G - 4 至表 G - 7 可知，兩個評分模型所產生的原始檢核清單在項目數量與關注內容上有所不同。Qwen3-VL-32B-Instruct 的原始清單包含 10 項，主要涵蓋天氣、風格、色彩、場合、主要服飾、查詢口吻、視覺一致性及語句流暢度；Gemma-3-27B-it 的原始清單則包含 15 項，除上述面向外，亦進一步檢查材質或圖樣、描述具體程度、整體穿搭表達及主觀用語等內容。

在加權清單 (C*) 中，與影像內容是否一致的項目具有最高權重，以降低評分模型接受未受到穿搭影像支持之描述的可能性；天氣、風格與場合相關項目次之，

用以檢查情境感知描述是否包含本研究所關注的核心條件；色彩、氛圍與查詢表達等項目用於確認描述是否適合作為穿搭查詢；清晰度與流暢度相關項目則用於檢查描述的完整性及語言品質。

此外，Gemma-3-27B-it 的加權清單未納入原始清單中的 C14，並新增 C16「Does the description mention a specific temperature in °C?」，以明確檢查描述是否包含攝氏溫度資訊。

G.5 個案檢視

為進一步說明 LLM-as-a-Judge 評估結果之可解釋性，本研究選取一筆高分樣本與一筆低分樣本進行個案檢視。高分樣本用以說明描述與圖片、溫度、風格及場合條件一致時的評分結果；低分樣本則說明模型如何辨識圖片不一致、情境矛盾或幻覺內容。



圖 G - 2、高分樣本：套裝 ID 223051514 之套裝圖片

表 G - 8、高分樣本評分資訊

項目	內容
評分模型	Gemma-3-27B-it
套裝 ID	223051514
評分結果	Score = 1.0000
生成描述	23.6°C, Effortless Summer Days in a Floral Midi Dress
評分情形	YES = 15，NO = 0
Feedback	None
Rewrite	None

圖 G - 2 為高分樣本之套裝圖片，表 G - 8 則整理該樣本的模型評分資訊。此樣本由 Gemma 3 評為滿分，生成描述為 “23.6°C, Effortless Summer Days in a Floral Midi Dress”。由圖 G - 2 可見，該套裝以花卉洋裝為核心，搭配粉色包款、藍色綁帶高跟鞋與藍色耳環，整體呈現輕盈、明亮且具有夏日感的穿搭氛圍。此案例中，模型將所有檢核項目皆判定為 YES，顯示該生成描述在圖片內容、環境條件、穿搭風格與查詢式表達上具有良好一致性。其中，“Floral Midi Dress” 能直接對應圖中的主要服裝元素，且未加入圖片無法支持的品牌、材質或具體情境，因此符合圖片和文字語意一致性要求。描述中的 23.6°C 與 “Summer Days” 能合理對應圖片中輕盈、明亮且具夏日感的穿搭氛圍；“Effortless Summer Days” 亦能以整體風格概括套裝，而非逐一列出所有單品。雖然描述未完整列出粉色、藍色等配色細節，

但已能透過花卉洋裝與夏日語意指向主要視覺特徵，並維持自然的查詢式語氣。因此，模型未提出 feedback，也未產生 rewrite。

整體而言，此案例說明當生成描述能準確概括圖片核心服裝，並合理連結溫度、季節與整體風格時，LLM-as-a-Judge 能給予一致的高分評估，可作為本研究合格描述之代表案例。



圖 G - 3、低分樣本：套裝 ID 186249502 之套裝圖片

表 G - 9、低分樣本評分資訊

項目	內容
評分模型	Qwen3-VL-32B-Instruct
套裝 ID	186249502
評分結果	Score = 0.0000
生成描述	25.1°C, Cozy Winter Vibes: Layered Comfort for a Festive Ice Skating Day
評分情形	YES = 0，NO = 10
Feedback	The description contradicts the image by claiming winter vibes and ice skating while showing cold-weather gear, yet citing 25.1°C, which is warm. It also invents a festive occasion and mood not supported by visuals. Fix temperature-feeling mismatch and add one concrete winter occasion.
Rewrite	25.1°C, chilly despite warmth, gray coat with cream knit layers for a cold rainy commute

圖 G - 3 為低分樣本之套裝圖片，表 G - 9 則整理該樣本的模型評分資訊。此案例為低分樣本，模型將所有檢核項目皆判定為 NO，代表該生成描述在圖片內容、溫度條件、場合語意、風格描述與查詢式表達上皆存在明顯問題。從圖片可見，該套裝包含米色包款、毛絨短靴、米色針織長版上衣或洋裝、米色針織手套、灰色褲款與灰色連帽外套，整體視覺明顯偏向寒冷天氣或保暖穿搭。

首先，在圖片和文字語意一致性方面，描述中的 **“Cozy Winter Vibes”** 雖然部分呼應圖片中的保暖單品，但後續加入 **“Festive Ice Skating Day”** 則屬於圖片中無法直接支持的場合想像。圖片呈現的是保暖日常穿搭，但沒有任何溜冰、節慶或戶外活動線索。因此，模型判定該描述加入了圖片無法支持的情境內容，屬於語意不一致或潛在幻覺。其次，在環境條件方面，描述標示 **25.1°C**，但同時使用 **“Cozy Winter Vibes”** 與 **“Ice Skating Day”** 等偏冷天氣語意。25.1°C 通常較接近溫暖或偏熱條件，與冬季保暖穿搭及溜冰場景存在明顯衝突。此處問題不只是溫度數值本身，而是「溫度條件」與「穿搭語意」無法合理對應，因此模型指出 temperature-feeling mismatch。第三，在場合與情境描述方面，**“Festive Ice Skating Day”** 過於具體，但圖片中沒有節慶、冰場、運動或溜冰相關符號。這表示描述把一個未由圖片支持的具體情境加入標題中，降低了圖片和文字語意一致性。相較之下，若描述改為 “cold rainy commute” 或 “cold-weather casual outing” 這類較貼近日常保暖穿搭的場合，會更符合圖片可見內容。第四，在查詢式語氣與描述聚焦方面，原句雖然形式上像查詢式描述，但其內容同時包含溫暖溫度、冬季氛圍、層次保暖與節慶溜冰，使語意方向混雜。模型因此不僅判定圖片語意不一致，也判定風格與場合描述不穩定，無法形成清楚的穿搭需求。

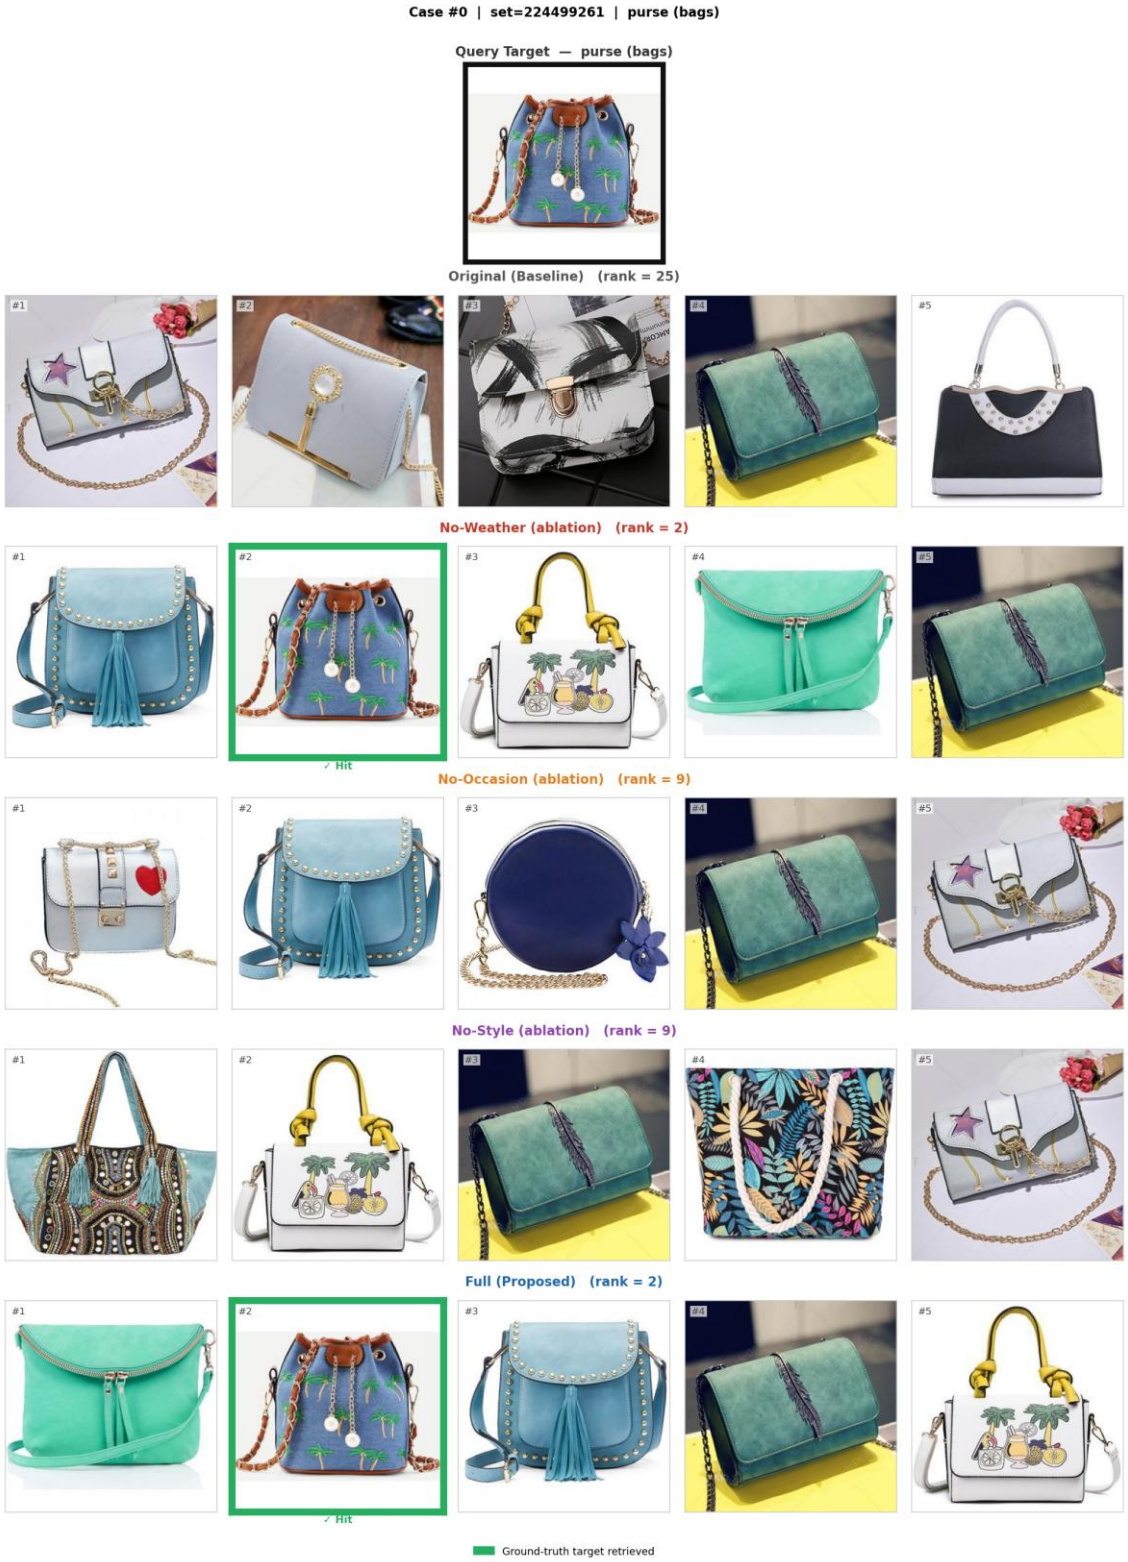
模型產生的 rewrite 為：“25.1°C, chilly despite warmth, gray coat with cream knit layers for a cold rainy commute”。此 rewrite 並非用於直接替換原始生成描述，而是作為可解釋性輔助輸出，用以呈現模型判斷該描述可如何被修正。由 rewrite 可看出，模型嘗試保留原始溫度 25.1°C，同時指出其與寒冷穿搭之間的語意張力，並將原本圖片無法支持的 “Festive Ice Skating Day” 調整為較貼近日常保暖穿搭的情境。

整體而言，此案例能清楚展示本研究方法的功能：模型不只是判斷文字是否流暢，而是能進一步檢查描述是否與圖片內容、溫度條件與場合語意一致。當生成描述加入圖片無法支持的具體場合，或使溫度與穿搭語意產生矛盾時，LLM-as-a-Judge 能透過逐項檢核反映為低分，並透過 feedback 與 rewrite 提供可解釋的判斷依據。此案例可作為本研究「不合格描述」與「可解釋性評分輸出」的代表案例。因此，這兩個案例分別呈現「符合條件會被判定為高品質」與「語意衝突會被辨識並透過 feedback／rewrite 提供解釋」兩種情況，能有效支援本研究以圖片和文字語意一致性、環境條件與查詢式語氣作為生成描述品質評估依據的設計。

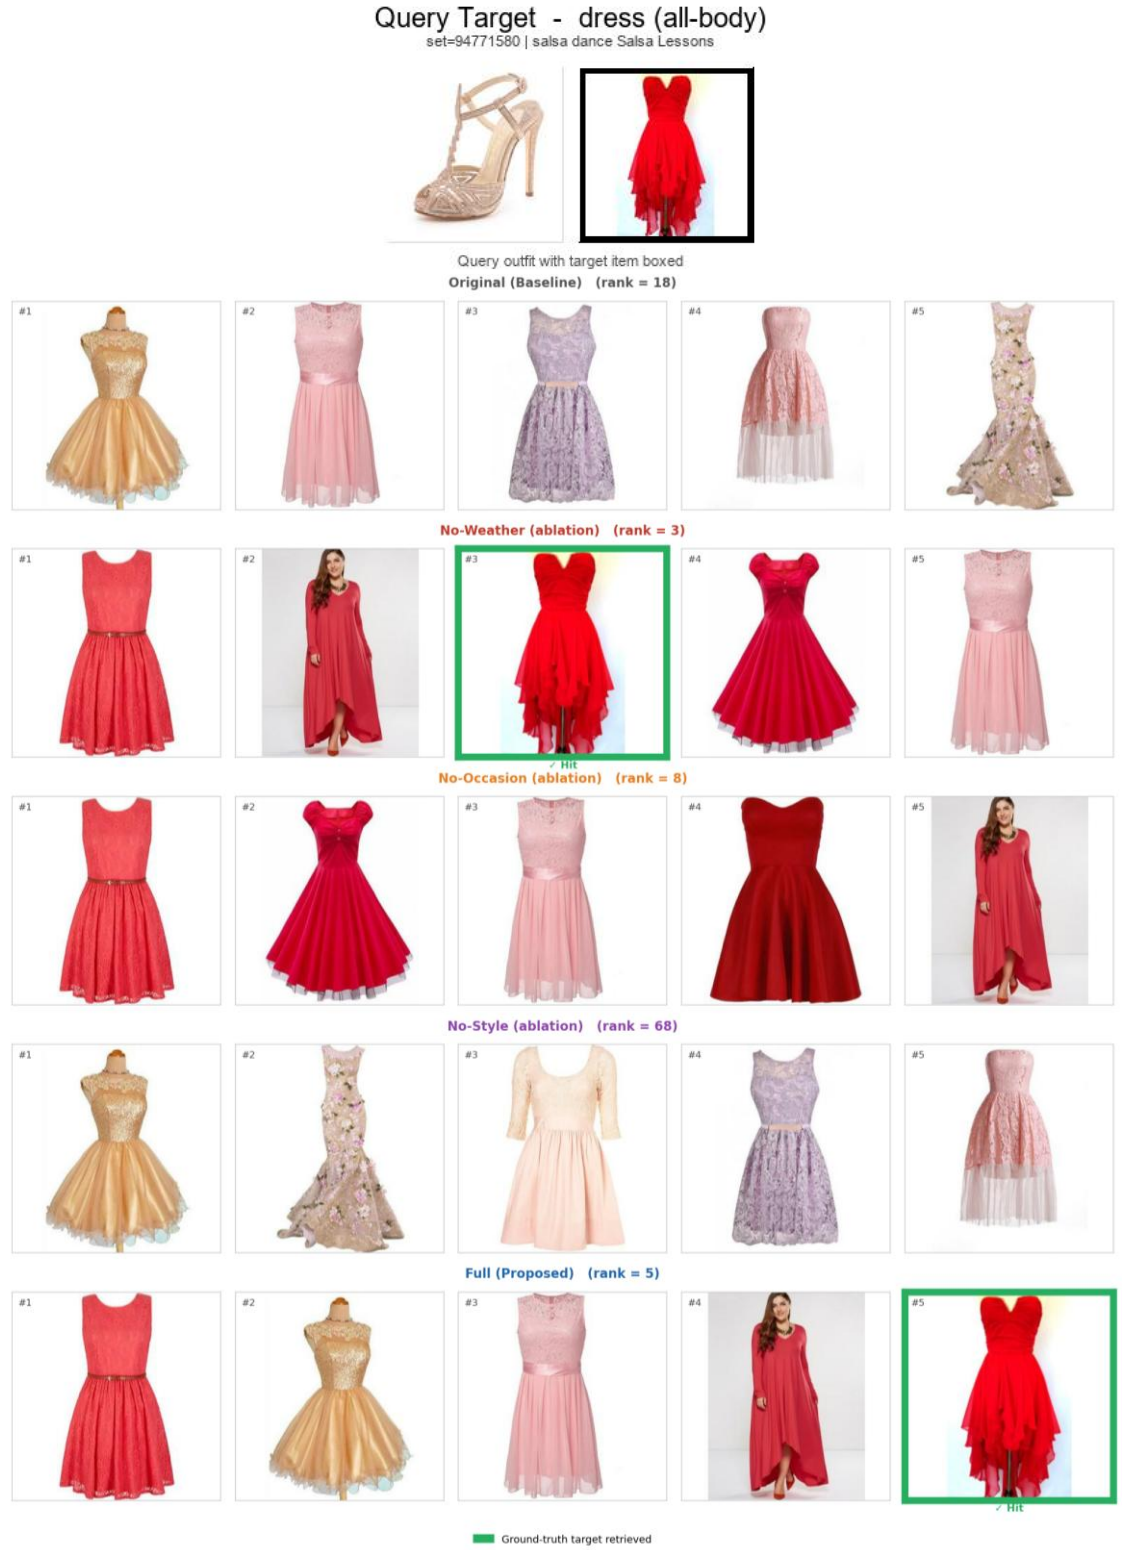
G.6 小結

綜合上述，本研究之 LLM-as-a-Judge 評估流程由一般檢核清單 C，延伸為具個人化權重的檢核清單 C*，並應用於套裝描述之結構化評分。此流程能從圖片和文字語意一致性、天氣條件、穿搭風格、使用場合與查詢語氣等面向檢查生成描述品質。評分結果中的 decisions 用於呈現逐項判斷，feedback 用於指出主要問題，rewrite 則作為可解釋性輔助輸出，用以呈現模型判斷該描述可如何被修正，而非直接作為最終替換結果。附錄 G 補充說明正文第 3.5 節所述生成資料品質評估的實作基礎，並支援第 4.2 節對評分結果、雙評分者比較與低分樣本辨識穩定性的分析。

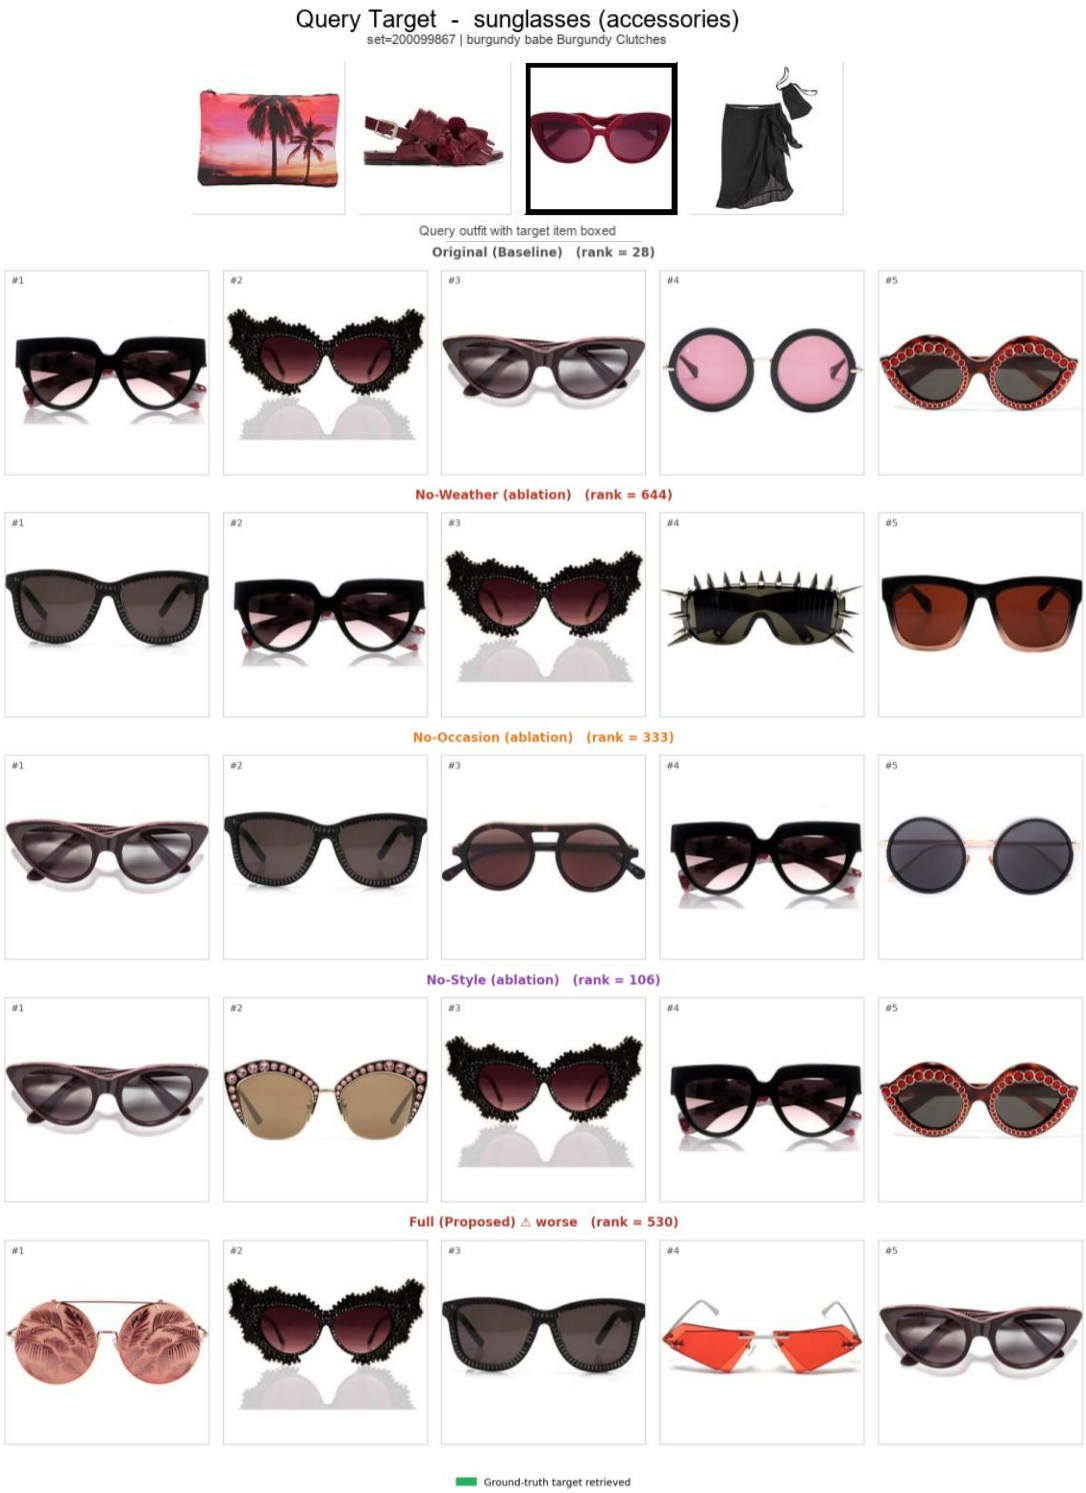
附錄 H


Case #0 | set=224499261 | purse (bags)
Query Target — purse (bags)
Original (Baseline) (rank = 25)
No-Weather (ablation) (rank = 2)
✓ Hit
No-Occasion (ablation) (rank = 9)
No-Style (ablation) (rank = 9)
Full (Proposed) (rank = 2)
✓ Hit
Ground-truth target retrieved

附錄 I


Query Target - dress (all-body)
set=94771580 | salsa dance Salsa Lessons
Query outfit with target item boxed
Original (Baseline) (rank = 18)
No-Weather (ablation) (rank = 3)
✓ Hit
No-Occasion (ablation) (rank = 8)
No-Style (ablation) (rank = 68)
Full (Proposed) (rank = 5)
✓ Hit
Ground-truth target retrieved

附錄 J


Query Target - sunglasses (accessories)
set=200099867 | burgundy babe Burgundy Clutches
Query outfit with target item boxed
Original (Baseline) (rank = 28)
No-Weather (ablation) (rank = 644)
No-Occasion (ablation) (rank = 333)
No-Style (ablation) (rank = 106)
Full (Proposed) ⚠ worse (rank = 530)
Ground-truth target retrieved